Tema 1: Prognoza prețului PZU din România, pentru un birou de ofertare

Prognoze punctuale și probabilistice, teste de acuratețe și volatilitate — cursurile 1–3

De completat de profesor: Termen: **TODO** • Pondere în nota finală: **TODO** • Individual sau echipe de cîte 2: **TODO** • Programarea susținerilor orale: **TODO** • Regula pentru întîrzieri: **TODO**. Predarea se face pe Moodle.

Situația

Lucrați la biroul de ofertare pentru ziua următoare al unei companii energetice din România: un furnizor, un producător sau un consumator mare. În fiecare zi, înainte de ora 12:00 CET (ora Europei Centrale) din ziua $d-1$, biroul trimite oferte pe piața pentru ziua următoare (PZU; în engleză *day-ahead market*, operată de OPCOM, operatorul pieței de energie electrică și de gaze naturale din România) pentru fiecare oră a zilei d. Astăzi biroul își stabilește ofertele cu „prețul de ieri” (o regulă naivă). Managerul vă pune trei întrebări. (1) Înlocuim regula naivă cu un model statistic, măcar în orele care contează cel mai mult pentru noi (*blocul dumneavoastră de interes*)? (2) Cît de mare este incertitudinea pe care trebuie să o comunicăm odată cu fiecare prognoză? (3) Este piața acum într-un regim de volatilitate ridicată, care justifică o rezervă mai mare de credit sau de garanții? Răspundeți cu un notebook reproductibil și cu un memoriu de două pagini care se încheie cu o decizie clară.

1 Ce predați

D1 **Notebook-ul** `A1_<ID>.ipynb`, construit pornind de la `A1_starter_RO.ipynb`. Trebuie să ruleze cu *Restart & Run All* din dosarul de date al cursului, fără erori, în cel mult 30 de minute pe un laptop obișnuit.

D2 **Fișierul de numere** `my_numbers_A1_<ID>_personal.json`, scris de notebook (ultima celulă a notebook-ului de pornire).

D3 **Memoriul** (PDF, 11 pt, cel mult 2 pagini): pagina 1 este recomandarea pentru manager; pagina 2 este anexa (tabelele principale și tabelul de reconciliere manuală). Structura este în sarcina 8.

D4 **Susținerea orală** (circa 10 minute): profesorul alege o zi și o oră din fereastra dumneavoastră de test și o întrebare dificilă; explicați numerele din propriul notebook.

2 Parametrii dumneavoastră personali

Fiecare student (sau echipă) primește alți parametri. Ei sînt calculați din numărul matricol printr-o regulă fixă (o sămînță obținută cu algoritmul de hash SHA-256, *Secure Hash Algorithm*), deci obțineți mereu aceleași valori și nimeni altcineva nu are același set. Îi obțineți în oricare dintre aceste două moduri:

- ☐ `python make_assignment.py --id <ID> --assignment 1` (dosarul `repo/assignments`); echipă: `--id "ID1+ID2"`;
- ☐ sau prima celulă a notebook-ului de pornire (`STUDENT_ID = ...`).

Parametru	Semnificație
`test_start, test_end`	fereastra dumneavoastră de test, de 365 de zile (începe în prima zi a unei luni între sept. 2024 și nov. 2025)
`burn_in_days`	112 zile dinaintea ferestrei de test, pe care le prognozați de asemenea; erorile lor alimentează prognozele probabilistice (sarcina 6)
`focus_hours`	orele care contează pentru biroul dumneavoastră (CET): noapte, rampa de dimineață, orele solare sau vîrful de seară
`arx_windows`	cele șase ferestre de calibrare: 56, 84, 112, 714, 721, 728 de zile (aceleași pentru toți)
`lear_window`	fereastra dumneavoastră de calibrare pentru LEAR: 364, 546 sau 728 de zile
`error_window`	W: numărul de zile anterioare ale căror erori se folosesc pentru intervalele HS și CP: 56, 84 sau 112
`garch_years`	lungimea eșantionului de estimare GARCH dinainte de test_start: 3, 4 sau 5 ani
`check_days, check_hour`	două zile și o oră pe care trebuie să le reconciliați manual (sarcina 8)

Copiați blocul afișat, nemodificat, în anexa memoriului. Un memoriu cu parametrii altcuiva primește 0 puncte.

3 Date, timp și notație

Toate datele sînt în `repo/data/clean/` (sursele și data descărcării în `repo/data/SOURCES.md`). Folosiți modulul `emqa_assign.py`; nu descărcați alte date și nu modificați fișierele de date.

Obiect	Apel	Conținut
$P_{d,h}$	`ea.panel("RO")[0]`	prețul PZU al României, ziua d, ora h (EUR/MWh)
$L_{d,h}$	`ea.panel("RO")[1]`	consumul realizat al României (MW medii în oră)
$R_{d,h}$	`ea.panel("RO")[2]`	producția eoliană + solară realizată a României (MW)
$\bar{P}_d$	`ea.daily_prices()["RO"]`	prețul zilnic de bază: media tuturor intervalelor de tranzacționare ale zilei CET

- **Zile și ore.** Un rînd pe zi de livrare d în ora CET (ora Europei Centrale, fusul orar al cuplării unice a piețelor pentru ziua următoare, SDAC); coloanele `h00`–`h23` sînt ore CET, $h = 0, \ldots, 23$. Ora României (EET, ora Europei de Est) este cu o oră mai tîrziu: `h00` înseamnă 01:00–02:00 la București.
- **Intervalul de tranzacționare de 15 minute (MTU, *market time unit*).** Din ziua de livrare 1 octombrie 2025 prețurile se stabilesc pentru 96 de sferturi de oră pe zi. În matricea orară, fiecare oră de după această dată este media celor patru sferturi de oră. Prognozați și evaluați valori orare.
- **Setul de informații (închiderea porții, *gate closure*).** Prognoza pentru ziua d se face la 12:00 CET în ziua $d-1$. În acel moment:
  - *prețurile*: toate prețurile pînă în ziua $d-1$ sînt cunoscute (licitația pentru ziua $d-1$ s-a încheiat în ziua $d-2$);
  - *consumul L și producția eoliană+solară R realizate*: numai valorile deja măsurate, adică pînă la sfîrșitul zilei $d-2$; ziua $d-1$ *nu* este încă încheiată;
  - *combustibilii și certificatele de emisii*: ultima cotație de închidere dinainte de ora 12:00 din ziua $d-1$, în practică cea din ziua $d-2$;
  - *transformările, standardizările și pragurile*: estimate numai pe aceste date.

  Un birou real ar folosi prognozele operatorului de transport și sistem (OTS, Transelectrica); datele noastre gratuite conțin doar valori realizate. **Regulă:** folosiți L și R realizate din ziua $d-2$ (aceeași oră) ca substitut (proxy) pentru ziua d, iar $d-3$ și $d-7$ ca decalaje suplimentare. `ea.leakage_check` verifică respectarea acestei reguli.
- **Ora de vară (DST).** Ziua CET are 23 de ore în martie și 25 în octombrie. Modulul păstrează 24 de coloane: ora lipsă este media orelor vecine, ora dublată este mediată (coloana `dst` marchează aceste zile).

4 Sarcinile

Rezolvați sarcinile în ordine. Fiecare sarcină spune ce calculați, pe ce date, cu ce metodă și ce arătați. Punctele însumează 100.

Sarcina 1 — Cunoașteți-vă fereastra de test [8 puncte]

Pe cele 365 de zile de test calculați media, abaterea standard, minimul și maximul lui $P_{d,h}$; numărul de ore cu preț negativ; numărul intervalelor de tranzacționare (MTU) cu preț negativ din `ea.quarter_hours("RO")` (rînduri orare înainte de 1 octombrie 2025, sferturi de oră după; filtrați după data CET a indexului); ponderea zilelor de test cu MTU de 15 minute. Reprezentați grafic prețul zilnic de bază de la 1 ianuarie 2023 pînă la sfîrșitul ferestrei de test și hașurați fereastra. În trei propoziții, numiți evenimentele de piață din fereastra dumneavoastră (de exemplu separarea prețurilor România–Ungaria (RO–HU) din vara 2024, anul hidrologic secetos 2025, prețurile negative din primăvară și vară, MTU de 15 minute din octombrie 2025).

Arătați: tabelul T1 (o coloană); figura cu axa x „data”, axa y „EUR/MWh”, legenda sub grafic.

Sarcina 2 — Două modele naive de referință [6 puncte]

Pentru fiecare zi din perioada de rodaj (*burn-in*) + test (`fdays`) și fiecare oră:

$$\hat{P}^{\text{naive}}_{d,h} = \begin{cases} P_{d-7,h}, & d = \text{luni, sîmbătă, duminică} \\ P_{d-1,h}, & d = \text{marți–vineri} \end{cases} \qquad \hat{P}^{(7)}_{d,h} = P_{d-7,h}. \tag{1}$$

Primul este modelul naiv de referință din literatura de prognoză a prețului energiei electrice (EPF, *electricity price forecasting*) [11, 5]; al doilea este modelul naiv sezonier. Toate modelele următoare sînt evaluate în raport cu $\hat{P}^{\text{naive}}$.

Arătați: ambele prognoze salvate în `F` (`DataFrame`, rînduri `fdays`, coloane `h00`..`h23`); testul `ea.leakage_check` reușit.

Sarcina 3 — Modelul expert ARX, ferestre glisante și medierea pe ferestre [12 puncte]

Transformarea. Prețurile au salturi și valori negative, deci nu logaritmați niciodată prețurile. Folosiți transformarea de stabilizare a variației (VST, *variance-stabilising transformation*) din [10]:

$$Y_{d,h} = \operatorname{asinh}\left(\frac{P_{d,h} - m}{s}\right), \qquad \operatorname{asinh}(x) = \ln\left(x + \sqrt{x^2+1}\right), \qquad P_{d,h} = m + s\,\sinh(\hat{Y}_{d,h}), \tag{2}$$

unde m este mediana și s abaterea absolută mediană (MAD, înmulțită cu 1,4826) a prețurilor numai din fereastra de calibrare.

Modelul. Pentru fiecare oră h separat (24 de regresii pe zi) estimați prin metoda celor mai mici pătrate (OLS, *ordinary least squares*) modelul expert ARX (model autoregresiv cu variabile exogene) din [13]:

$$\begin{aligned} Y_{d,h} = \beta_{h,0} + \beta_{h,1}Y_{d-1,h} + \beta_{h,2}Y_{d-2,h} + \beta_{h,3}Y_{d-7,h} + \beta_{h,4}Y_{d-1,23} + \beta_{h,5}Y^{\min}_{d-1} + \beta_{h,6}Y^{\max}_{d-1} \\ + \beta_{h,7}\tilde{L}_{d,h} + \beta_{h,8}\tilde{R}_{d,h} + \beta_{h,9}D^{\text{Mon}}_d + \beta_{h,10}D^{\text{Sat}}_d + \beta_{h,11}D^{\text{Sun}}_d + \varepsilon_{d,h} \end{aligned} \tag{3}$$

unde $Y_{d-1,23}$ este ultima oră a zilei precedente; $Y^{\min}_{d-1}, Y^{\max}_{d-1}$ sînt minimul și maximul celor 24 de ore din ziua $d-1$; $\tilde{L}_{d,h} = L_{d-2,h}$ și $\tilde{R}_{d,h} = R_{d-2,h}$ sînt substitutele (ultima zi măsurată; standardizate cu media și abaterea standard din fereastra de calibrare, rîndurile pînă în $d-2$); D sînt variabile 0/1 pentru luni, sîmbătă și duminică; $\varepsilon_{d,h}$ este eroarea.

Calibrarea glisantă. Pentru fiecare zi de prognoză d și fiecare lungime de fereastră $T \in \{56, 84, 112, 714, 721, 728\}$, estimați pe cele T zile-țintă $d-T, \ldots, d-1$, apoi prognozați ziua d;

avansați o zi și reestimați (recalibrare zilnică). **Medierea.** Prognoza combinată este media simplă pe cele șase ferestre, $\hat{P}^{\mathrm{AW}}_{d,h} = \frac{1}{6}\sum_T \hat{P}^{(T)}_{d,h}$ [3].

Arătați: șapte prognoze în `F`: ARX(56), …, ARX(728) și AW-ARX; testul `ea.leakage_check` reușit pentru ARX(56).

Sarcina 4 — LEAR, modelul de referință puternic [10 puncte]

LEAR (autoregresie estimată cu LASSO; LASSO = *least absolute shrinkage and selection operator*) [9, 5] folosește mulți regresori candidați și lasă penalizarea LASSO să-i anuleze pe cei inutili. Pentru fiecare oră h:

$$\hat{\boldsymbol{\beta}}_h = \arg\min_{\boldsymbol{\beta}} \Big\{ \sum_{d\in\mathrm{cal}} \big(Y_{d,h} - \mathbf{x}_d^{\top}\boldsymbol{\beta}\big)^2 + \lambda_h \sum_j |\beta_j| \Big\}, \tag{4}$$

unde $\mathbf{x}_d$ are 247 de elemente: $Y_{d-k,0},\ldots,Y_{d-k,23}$ pentru $k = 1, 2, 3, 7$ (96); substitutele de consum și eolian+solar din $d-2, d-3, d-7$ pentru toate cele 24 de ore, după aceeași transformare asinh (144); 7 variabile pentru ziua săptămînii. Toate coloanele se standardizează cu mediile și abaterile standard din fereastra de calibrare. $\lambda_h \geq 0$ se alege cu criteriul informațional Akaike (AIC): `LassoLarsIC(criterion="aic")` din `scikit-learn`. Folosiți `lear_window`; recalibrați zilnic (recalibrarea săptămînală este permisă dacă o declarați și raportați timpul de rulare).

Arătați: prognozele LEAR în `F`; numărul de coeficienți nenuli pentru ora `check_hour` în prima zi de test.

Sarcina 5 — Acuratețe și testele Diebold–Mariano [16 puncte]

Numai pe fereastra de test (niciodată pe rodaj), cu erorile $e_{d,h} = P_{d,h} - \hat{P}_{d,h}$ și N numărul de perechi (zi, oră):

$$\mathrm{MAE} = \frac{1}{N}\sum |e_{d,h}|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum e_{d,h}^2}, \qquad \mathrm{rMAE} = \frac{\mathrm{MAE}_{\mathrm{model}}}{\mathrm{MAE}_{\mathrm{naive}}}. \tag{5}$$

MAE este eroarea absolută medie, RMSE rădăcina erorii pătratice medii, rMAE eroarea absolută medie relativă [5] (sub 1: mai bun decît modelul naiv). Nu folosiți eroarea procentuală absolută medie (MAPE): crește necontrolat cînd prețurile sînt aproape de zero. Raportați toate modelele: (a) toate cele 24 de ore, (b) blocul de interes, (c) fiecare an calendaristic din fereastră, (d) fiecare trimestru pentru Naive, AW-ARX și LEAR.

Testul Diebold–Mariano (DM) [1], varianta multivariată [13]. Pentru modelele A și B și fiecare zi de test d:

$$\Delta_d = \frac{1}{|H|}\sum_{h\in H} |e^A_{d,h}| - \frac{1}{|H|}\sum_{h\in H} |e^B_{d,h}|, \qquad \mathrm{DM} = \frac{\bar{\Delta}}{\sqrt{\hat{\sigma}^2_{\mathrm{NW}}/n}}, \qquad p = 1 - \Phi(\mathrm{DM}), \tag{6}$$

unde H este mulțimea orelor (toate 24 sau blocul de interes), n numărul de zile de test, $\bar{\Delta}$ media lui Δ_d, $\hat{\sigma}^2_{\mathrm{NW}}$ varianța Newey–West (robustă la heteroscedasticitate și autocorelare, HAC) a lui Δ_d cu 7 decalaje, iar Φ funcția de repartiție normală standard. Un p mic (de exemplu sub 0,05) înseamnă: B este semnificativ mai precis decît A. Arătați două matrice 6×6 de valori p (toate orele; blocul de interes) pentru Naive, naiv sezonier, ARX(56), ARX(728), AW-ARX, LEAR.

Arătați: tabelul T5 (rînduri = modele; coloane MAE, RMSE, rMAE total, bloc de interes, pe ani); tabelul MAE pe trimestre; cele două matrice DM; două propoziții: care model cîștigă și este cîștigul semnificativ?

Sarcina 6 — Prognoze probabilistice: simulare istorică și predicție conformală [14 puncte]

Transformați o prognoză punctuală în 99 de cuantile $\hat{q}^{\tau}_{d,h}$, $\tau = 0{,}01, \ldots, 0{,}99$, folosind erorile aceleiași ore din cele W zile anterioare (`error_window`), $e_{d-W,h}, \ldots, e_{d-1,h}$ [7, 6]:

$$\text{HS:} \quad \hat{q}^{\tau}_{d,h} = \hat{P}_{d,h} + Q_{\tau}(e_{d-W,h}, \ldots, e_{d-1,h}), \tag{7}$$

$$\text{CP:} \quad \hat{q}^{\tau}_{d,h} = \hat{P}_{d,h} + \operatorname{sign}(\tau - 0{,}5)\; Q_{|2\tau-1|}(|e_{d-W,h}|, \ldots, |e_{d-1,h}|), \tag{8}$$

unde $Q_a(\cdot)$ este cuantila empirică de ordin a (`numpy.quantile`, interpolare liniară implicită). HS (simularea istorică, *historical simulation*) folosește erorile cu semn, deci intervalul poate fi asimetric; CP (predicția conformală, *conformal prediction*) folosește erorile în valoare absolută, deci intervalul este simetric în jurul lui $\hat{P}_{d,h}$. Aplicați HS și CP pentru Naive, AW-ARX și LEAR (6 combinații). **Scorul pinball** pentru nivelul τ și prețul realizat y, și media lui, scorul pinball mediu (APS, *average pinball score*):

$$\mathrm{PS}(\hat{q}^{\tau}, y, \tau) = (\mathbf{1}\{y < \hat{q}^{\tau}\} - \tau)(\hat{q}^{\tau} - y), \qquad \mathrm{APS} = \frac{1}{99\,N} \sum_{d,h} \sum_{\tau} \mathrm{PS}(\hat{q}^{\tau}_{d,h}, P_{d,h}, \tau), \qquad \mathrm{CRPS} \approx 2 \cdot \mathrm{APS}, \tag{9}$$

unde $\mathbf{1}\{\cdot\}$ este 1 dacă este adevărată condiția și 0 altfel; CRPS este scorul probabilistic continuu ordonat (*continuous ranked probability score*) [2]. Mai mic înseamnă mai bine. **Acoperirea**: ponderea perechilor (zi, oră) cu $P_{d,h}$ în intervalul de 50% $[\hat{q}^{0{,}25}, \hat{q}^{0{,}75}]$ și în cel de 90% $[\hat{q}^{0{,}05}, \hat{q}^{0{,}95}]$. **Testul Kupiec** [4] pe blocul de interes, pentru intervalul de 90%, cu x ratări din n cazuri și rata nominală de ratare $p_0 = 0{,}10$:

$$\mathrm{LR}_{\mathrm{UC}} = -2 \ln \frac{(1-p_0)^{n-x} p_0^{x}}{(1-\hat{p})^{n-x} \hat{p}^{\,x}}, \qquad \hat{p} = x/n, \qquad \mathrm{LR}_{\mathrm{UC}} \sim \chi^2_1 \text{ sub } H_0. \tag{10}$$

Arătați: tabelul T6 (rînduri = 6 combinații; coloane APS, APS pe bloc, acoperire 50%, acoperire 90%, acoperire 90% pe bloc, valoarea p Kupiec, lățimea medie a intervalului de 90% pe bloc); o figură: o săptămînă de test, prețul realizat și benzile de 50% și 90% ale celei mai bune combinații.

Sarcina 7 — Volatilitate: GARCH, GJR-GARCH, EGARCH [12 puncte]

GARCH este modelul autoregresiv generalizat cu heteroscedasticitate condiționată (*generalised autoregressive conditional heteroskedasticity*); GJR-GARCH este varianta asimetrică Glosten–Jagannathan–Runkle; EGARCH este GARCH exponențial. Folosiți prețurile zilnice de bază. Deoarece prețurile pot fi zero sau negative, nu folosiți randamente logaritmice; folosiți

$$r_t = 100\,[\,\operatorname{asinh}(\bar{P}_t) - \operatorname{asinh}(\bar{P}_{t-1})], \qquad \varepsilon_t = r_t - \mu - \delta_{\mathrm{dow}(t)} = \sigma_t z_t, \quad z_t \sim t_{\nu} \text{ (standardizată)}, \tag{11}$$

unde $\delta_{\mathrm{dow}(t)}$ este media lui r în acea zi a săptămînii, calculată numai pe eșantionul de estimare (o scădeți înainte de estimare), σ_t este volatilitatea condiționată, iar ν numărul gradelor de libertate. Estimați prin metoda verosimilității maxime (pachetul `arch`) pe cei `garch_years` ani dinaintea lui `test_start`:

$$\text{GARCH(1,1):} \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \tag{12}$$

$$\text{GJR(1,1,1):} \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 \mathbf{1}\{\varepsilon_{t-1} < 0\} + \beta \sigma_{t-1}^2, \tag{13}$$

$$\text{EGARCH(1,1,1):} \quad \ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2. \tag{14}$$

În GJR, $\gamma > 0$ înseamnă că scăderile cresc mai mult volatilitatea („efect de levier”, obișnuit la acțiuni); $\gamma < 0$ înseamnă că salturile de preț cresc mai mult volatilitatea („efect de levier invers”, des raportat pentru gaze și energie electrică). În EGARCH semnificația semnelor este inversă: $\gamma < 0$ = scăderile cresc mai mult volatilitatea. **Testați, nu presupuneți**: raportați γ și valoarea p. Persistența este $\alpha + \beta + \gamma/2$ (GJR), $\alpha + \beta$ (GARCH), β (EGARCH); timpul de înjumătățire

$= \ln 0{,}5 / \ln(\text{persistență})$ zile. Apoi, cu parametrii fixați, aplicați filtrul pe fereastra de test și comparați prognozele de varianță pentru o zi înainte, $\hat{\sigma}_t^2$, cu substitutul ε_t^2 prin funcția de pierdere de cvasi-verosimilitate $\text{QLIKE} = \frac{1}{n}\sum_t \left(\ln \hat{\sigma}_t^2 + \varepsilon_t^2/\hat{\sigma}_t^2\right)$ (mai mic înseamnă mai bine) [8]. La final traduceți în bani prognoza pentru o zi înainte $\hat{\sigma}_T$ a ultimei zile de test T: creșterea aproximativă a prețului de bază într-o zi, la cuantila de 99%, $\bar{P}_{T-1}\left[\exp(z_{0,99}\hat{\sigma}_T/100) - 1\right]$, unde $\bar{P}_{T-1}$ este prețul de bază realizat în ziua precedentă, iar $z_{0,99} = t_\nu^{-1}(0{,}99)\sqrt{(\nu-2)/\nu}$ este cuantila de 99% a repartiției t_ν standardizate.

Arătați: tabelul T7 (rînduri = 3 modele; coloane $\omega, \alpha, \gamma, \beta, \nu$, log-verosimilitate, AIC, BIC (criteriul informațional bayesian), persistență, timp de înjumătățire, valoarea p pentru γ, QLIKE pe test); figura cu $|\varepsilon_t|$ și cele trei $\hat{\sigma}_t$ pe fereastra de test; creșterea la cuantila de 99%, în EUR/MWh.

Sarcina 8 — Memoriul: decizie, reconciliere, compania dumneavoastră [22 puncte]

Pagina 1 (recomandarea, cel mult 450 de cuvinte):

(a) **Decizia** în primele două rînduri: ce model să folosească biroul pentru blocul de interes, de la ce dată și ce înlocuiește.

(b) **Dovezile** (trei enumerări, fiecare cu un număr din notebook): cîștigul de acuratețe față de modelul naiv (rMAE, EUR/MWh), valoarea p DM, lățimea intervalului de 90% și acoperirea lui.

(c) **Riscul**: ce spune rezultatul GARCH despre regimul actual și recomandarea privind rezerva, în EUR/MWh.

(d) **Limitele**: substitutul pentru consum/regenerabile, o perioadă în care modelul a eșuat și ce ați adăuga în continuare.

(e) **Cum se aplică în compania mea** (cel mult 120 de cuvinte). Numai informații publice: nu folosiți și nu divulgați date confidențiale. Exemplu: „furnizorul nostru cumpără circa X% din portofoliu pe PZU la vîrful de seară" este acceptabil numai dacă X este public; altfel descrieți mecanismul fără cifre.

Pagina 2 (anexa): blocul de parametri; extrase din T5, T6, T7; și **tabelul de reconciliere manuală**: pentru fiecare dintre cele două `check_days` la `check_hour`, scrieți de mînă prețul realizat, prognozele Naive, AW-ARX și LEAR, fiecare eroare absolută, cuantilele de 5% și 95% LEAR+CP, dacă prețul a fost în interval și scorul pinball la $\tau = 0{,}95$, cu calculul arătat (de exemplu $(0-0{,}95)(278{,}9-394{,}9) = 110{,}2$).

5 Convenții exacte (răspunsuri la întrebările frecvente ale studenților)

C1 **Numele din `F`** (un `dict` Python de `DataFrame`-uri, rînduri `fdays`, coloane `h00`..`h23`): `"Naive (Weron)"`, `"Seasonal naive d-7"`, `"ARX(56)"`, ..., `"ARX(728)"`, `"AW-ARX(6 windows)"`, `"LEAR(<lear_window>)"`. Coloanele T5 pe ani: `MAE_2025`, `RMSE_2025`, `rMAE_2025`.

C2 **VST**: m și s se calculează o dată pentru fiecare zi de prognoză și fereastră, *comun pentru toate cele 24 de ore* ale rîndurilor de preț $d-T-7, \ldots, d-1$ (ținte plus rîndurile decalajelor; de aceea 63 de zile în exemplul rezolvat pentru $T = 56$) și se folosesc pentru fiecare oră. **Variabilele exogene ARX**: L și R se standardizează cu o singură medie și o singură abatere standard, comune pentru aceleași rînduri și ore, dar numai pînă la rîndul $d-2$ (fără asinh). **Variabilele exogene LEAR**: L și R primesc propria transformare asinh (mediană/MAD proprii, aceleași rînduri pînă în $d-2$), apoi fiecare dintre cele 247 de coloane, inclusiv variabilele zilei, se standardizează cu mediile și abaterile standard din calibrare. Pentru $h = 23$, regresorul ARX $Y_{d-1,23}$ apare de două ori: eliminați dublura (11 regresori).

C3 **Ani și trimestre**: ani și trimestre calendaristice intersectate cu fereastra (perioadele parțiale sînt permise; raportați numărul de zile). rMAE se împarte întotdeauna la MAE naiv pe aceeași submulțime (aceleași zile, aceleași ore).

C4 **Matricea DM**: celula din rîndul A, coloana B conține $p = 1 - \Phi(\text{DM})$ cu $\Delta_d = \text{media } |e^A| - \text{media } |e^B|$; diagonala este goală.

C5 **Kupiec pe blocul de interes**: n = zile de test × numărul orelor de interes; x = perechile (zi, oră) în afara lui $[\hat{q}^{0{,}05}, \hat{q}^{0{,}95}]$, de oricare parte; „în interval" include capetele; dacă $x = 0$ folosiți $0 \cdot \ln 0 = 0$. Perechile din aceeași zi nu sînt independente: menționați acest lucru. **Cea mai bună combinație** (pentru figură) = APS minim pe fereastra de test; orice săptămînă de test. Raportați CRPS $\approx 2\cdot$APS ca o coloană suplimentară.

C6 GARCH în `arch`: `garch_years` sînt ani calendaristici (`test_start - pd.DateOffset(years=g)`). Scădeți mediile pe zile ale săptămînii din eșantionul de estimare din toate valorile r_t (estimare și test). Estimați `arch_model(r, mean="Constant", vol="GARCH", p=1, o=0 sau 1, q=1, dist="t")` pe seria pînă la `test_end` cu `.fit(last_obs=test_start)` (parametrii folosesc doar eșantionul de estimare), apoi `.forecast(horizon=1, start=<ultima zi de estimare>, reindex=False)`: prognoza făcută în ziua t este varianța zilei $t+1$. Pentru EGARCH folosiți `vol="EGARCH"`. Valoarea p pentru γ este „n/a" la GARCH(1,1).

C7 Verificarea scurgerii: rulați `ea.leakage_check` cel puțin pentru Naive, ARX(56) și LEAR în prima zi de test. **Unde lucrați**: păstrați notebook-ul în `repo/assignments/A1/`, lîngă cel de pornire (importă `emqa_assign` din dosarul părinte). `MODE="latest"`: se cere doar o rulare fără erori; tabelele pot avea celule goale (de exemplu un singur trimestru). **Reconcilierea manuală**: calculele tastate sînt acceptate; scorul pinball este cel al cuantilei LEAR+CP $\hat{q}^{0,95}$.

6 Exemplu rezolvat (date reale): fereastra glisantă și un interval HS/CP

Ziua de prognoză d = marți, 4 martie 2025, ora `h19` (19:00–20:00 CET), momentul-limită al informației: 3 martie 2025, ora 12:00 CET.

(1) Fereastra de calibrare pentru ARX(56).

Element	Date	De ce
zile-țintă (56)	2025-01-07 … 2025-03-03	$d-56,\ldots,d-1$
cel mai vechi rînd de preț folosit	2024-12-31	decalajul 7 al primei ținte
m, s ale VST	prețurile 2024-12-31 … 2025-03-03	niciodată ziua de test
L, R (substitute, standardizare)	rîndurile pînă la 2025-03-02	$d-1$ nu este încă măsurată
pasul următor	ținte 2025-01-08 … 2025-03-04	prognoza pentru 5 martie

(2) Regresorii zilei d pentru ora h19 (înainte de VST), din datele cursului.

$P_{d-1,19}$	$P_{d-2,19}$	$P_{d-7,19}$	$P_{d-1,23}$	$P^{\min}_{d-1}$	$P^{\max}_{d-1}$	$L_{d-2,19}$	$R_{d-2,19}$	$D^{\text{Mon}}, D^{\text{Sat}}, D^{\text{Sun}}$	realizat $P_{d,19}$
198,18	178,86	438,63	151,23	46,34	286,21	7 119 MW	843 MW	0/0/0	231,65

Prognoza naivă este $P_{d-1,19} = 198{,}18$ (marțea folosește $d-1$), eroarea $231{,}65 - 198{,}18 = 33{,}47$ EUR/MWh.

(3) Un interval de 80% din ultimele $W = 10$ erori naive la h19 (22 feb. – 3 mar. 2025; $W = 10$ numai ca exemplul să fie scurt):

erorile sortate	−246,5	−159,4	−66,0	−16,8	−13,3	55,1	64,3	66,0	81,1	140,7
$\lvert e\rvert$ sortate	13,3	16,8	55,1	64,3	66,0	66,0	81,1	140,7	159,4	246,5

HS: $Q_{0,10}(e) = -168{,}1$ și $Q_{0,90}(e) = 87{,}0$ (interpolare liniară), deci intervalul este $[198{,}2 - 168{,}1,\ 198{,}2 + 87{,}0] = [30{,}1,\ 285{,}2]$. CP: $Q_{0,80}(|e|) = 144{,}4$, deci $[198{,}2 - 144{,}4,\ 198{,}2 + 144{,}4] = [53{,}7,\ 342{,}6]$. Valoarea realizată 231,65 este în ambele. Scorul pinball la $\tau = 0{,}90$ pentru HS: $\hat{q} = 285{,}2 > y = 231{,}65$, deci $\text{PS} = (1 - 0{,}9)(285{,}2 - 231{,}65) = 5{,}36$.

(4) DM într-un rînd. Dacă într-o zi de test media lui $|e|$ pe orele de interes este 30 pentru Naive (A) și 22 pentru LEAR (B), atunci $\Delta_d = +8$: LEAR a fost mai bun în acea zi. Testul verifică dacă media acestor diferențe zilnice este semnificativ peste zero.

7 Reguli: reproductibilitate și folosirea instrumentelor de inteligență artificială

R1 Rulează complet: *Restart & Run All* funcționează pe datele cursului cu pachetele mediului cursului (`numpy`, `pandas`, `scikit-learn`, `statsmodels`, `arch`, `matplotlib`).

R2 Fără date sau numere introduse direct în cod (*hard-coded*): datele calendaristice vin din `p`. Profesorul rulează din nou fiecare notebook cu `MODE = "latest"` pe date descărcate după termen (un set de verificare nevăzut); trebuie să ruleze.

R3 Versiunea datelor: notebook-ul afișează `ea.data_version()` (amprentele fișierelor).

R4 Fără informații din viitor: `ea.leakage_check` trece pentru fiecare model raportat.

R5 Fiecare număr din memoriu se află în `MY_NUMBERS`. Un număr care nu este acolo sau care diferă de notebook costă 2 puncte (pînă la 10).

R6 Instrumentele de inteligență artificială (ChatGPT, Claude, Copilot, ...) sînt permise pentru cod, cu declarare: adăugați o celulă „Folosirea AI" care numește instrumentul și ce a făcut. Nu au voie să scrie numerele sau concluziile memoriului. Trebuie să puteți explica fiecare linie la susținerea orală.

Dacă notebook-ul nu rulează (R1), sarcinile 1–7 sînt plafonate la 50%. Dacă nu puteți explica un rezultat la susținerea orală, profesorul poate acorda 0 puncte pentru acea sarcină.

8 Greșeli frecvente

- ⊡ **Scurgerea de informație din viitor**: folosirea lui $L_{d,h}$ sau $R_{d,h}$ din ziua prognozată; estimarea VST, a standardizării sau a LASSO pe date care includ ziua d; alegerea modelului pe fereastra de test și raportarea acurateței pe același test ca și cum ar fi în afara eșantionului.
- ⊡ **Logaritmarea prețurilor** sau randamentele logaritmice: România a avut 196 de ore cu prețuri negative numai în 2025. Folosiți asinh.
- ⊡ **MAPE** cu prețuri apropiate de zero; ștergerea prețurilor negative ca erorile să pară mai mici.
- ⊡ **Amestecarea datelor de 15 minute cu cele orare** sau a orelor UTC cu cele CET (un decalaj de o oră strică modelele orare).
- ⊡ **Ajustarea în eșantion raportată drept acuratețe a prognozei**; R^2 în loc de MAE/RMSE pe fereastra de test.
- ⊡ **Citirea inversă a testului DM**: valoarea noastră p este pentru „coloana mai bună decît rîndul".
- ⊡ **Text generic**: „prețurile energiei sînt volatile" nu aduce puncte. Fiecare afirmație are nevoie de un număr din fereastra dumneavoastră.

9 Înainte de predare: lista de verificare

☐ Blocul de parametri afișat în notebook și copiat în anexa memoriului.

☐ *Restart & Run All* funcționează; timpul de rulare notat; și `MODE = "latest"` rulează.

☐ `ea.data_version()` afișat; testul `ea.leakage_check` reușit pentru Naive, ARX(56), LEAR.

☐ Tabelele T1, T5, T6, T7, cele două matrice DM, trei figuri (axe cu unități, legenda dedesubt).

☐ Memoriul $\leq$ 2 pagini; decizia în primele două rînduri; fiecare număr se regăsește în `MY_NUMBERS`.

☐ Tabelul de reconciliere manuală cu calcule; celula „Folosirea AI"; fără date confidențiale ale companiei.

10 Întrebări frecvente

Ce fus orar?
CET/CEST peste tot (fișierele sînt deja convertite). Ora Bucureștiului = CET + 1 h. Nu le mai convertiți.

Pot prognoza cele 96 de sferturi de oră?
Nu este obligatoriu. Modelele și notarea folosesc matricea orară. O analiză pe 15 minute este binevenită ca figură suplimentară, dar nu aduce puncte în plus.

Ce fac cu prețurile negative și cu limita minimă?
Le păstrați; sînt reale. Prețul minim armonizat de echilibru (*clearing*) al cuplării pentru ziua următoare (SDAC) este −500 EUR/MWh și a devenit −600 EUR/MWh pentru livrările de la 29 mai 2026 (anunțul OPCOM din 7 mai 2026).

Există zile lipsă?
Nu în `ea.panel()` începînd cu 2022 (verificat). Dacă codul găsește un gol, probabil ați amestecat fusurile orare. Zilele dinainte de 2019 au goluri; nu aveți nevoie de ele.

De ce perioada de rodaj?
HS și CP au nevoie de W erori de prognoză anterioare. Fără cele 112 zile de rodaj, primele zile de test nu ar avea interval. Acuratețea se măsoară numai pe fereastra de test.

LEAR merge încet. Ce pot face?
Circa 1 minut pe 8 nuclee cu `joblib.Parallel` pe zile; 10–20 de minute pe un singur nucleu. Recalibrarea săptămînală este permisă dacă o declarați.

Pot adăuga XGBoost, Prophet sau o rețea neurală?
Da, în plus față de modelele cerute (nu în locul lor), cu aceeași schemă glisantă. Nu aduce puncte în plus la tema 1; învățarea automată este notată la tema 2.

Valoarea p DM este 1,000. Este o eroare?
Nu. Înseamnă că modelul de pe coloană este clar *mai slab* decît cel de pe rînd; citiți celula simetrică.

Ce convenție pentru cuantile?
Cea implicită din `numpy.quantile` (liniară). Diferențele mici față de alte convenții nu se depunctează.

De ce asinh **pentru GARCH și nu randamente procentuale?**
Variațiile procentuale explodează cînd $\bar{P}_{t-1}$ este aproape de zero. Pentru prețuri mult peste 1 EUR/MWh, $\operatorname{asinh}(P) \approx \ln(2P)$, deci r_t se comportă ca un randament logaritmic.

γ din GJR este pozitiv, dar la curs s-a vorbit de „levier invers”.
Raportați ce arată datele și discutați de ce (de exemplu prețuri zilnice de bază după ajustarea pentru ziua săptămînii vs. salturi orare). Nu există un „semn corect” pentru notă.

Pot folosi R sau Excel?
Notebook-ul notat trebuie să fie Python (TODO: profesorul poate permite R).

Lucru în echipă?
Dacă este permis (vezi caseta de pe pagina 1), folosiți `--id "ID1+ID2"`; ambii membri susțin oral și trebuie să explice orice parte.

11 Grila de notare (100 de puncte)

Sarcina	Pct.	Excelent (90–100%)	Adecvat (50–70%)	Slab (0–30%)
1 Fereastra de test	8	T1 complet, inclusiv intervalele MTU negative; figură curată; evenimente numite și datate din date	tabel complet, evenimente generice	fereastră greșită sau tabel lipsă
2 Naive	6	ambele reguli exacte (logica zilelor), verificarea scurgerii trecută	o regulă greșită în unele zile	lipsește sau folosește ziua d
3 ARX + mediere	12	regresori exacți, VST estimat în fereastră, 6 ferestre glisante, recalibrare zilnică, AW	fereastră fixă sau lipsesc unii regresori	doar ajustare în eșantion sau scurgere de informație
4 LEAR	10	247 de regresori, λ ales prin AIC pentru fiecare oră, glisant, numărul de coeficienți raportat	mai puțini regresori sau λ fix	nu este glisant / nu rulează
5 Acuratețe, DM	16	toate măsurile pe ani, trimestre și bloc; ambele matrice DM HAC; citire corectă; semnificația discutată	măsuri corecte, o matrice DM lipsă sau citită greșit o dată	măsuri pe rodaj, MAPE, fără DM
6 Probabilistic	14	6 combinații, HS/CP corecte, APS, acoperire, Kupiec, figură; calibrarea vs. precizia discutate	numai HS sau CP, fără Kupiec	intervale din reziduuri în eșantion sau din erori viitoare

Sarcina	Pct.	Excelent (90–100%)	Adecvat (50–70%)	Slab (0–30%)
7 Volatilitate	12	3 modele cu erori t, γ testat și interpretat, persistență, QLIKE în afara eșantionului, creșterea la cuantila de 99% în EUR	numai în eșantion sau fără traducere în bani	randamente logaritmice ale prețurilor; fără fereastră de estimare
8a Decizia	10	decizie clară la început; 3 numere; limite și perioada de eșec onest prezentate	decizie vagă sau numere fără semnificație	text generic, fără decizie
8b Reconciliere	6	ambele zile de mînă, calcule arătate, coincid cu notebook-ul	o zi sau calcule lipsă	lipsă sau inconsistent
8c Compania mea	6	mecanism concret în postul studentului, numai date publice	plauzibil, dar generic	lipsă sau date confidențiale

Penalizări și condiții: R1 (nu rulează) plafonează sarcinile 1–7 la 50%; R5 costă 2 puncte pentru fiecare număr care nu se regăsește (pînă la 10); parametri personali greșiți = 0. Susținerea orală scurtă confirmă paternitatea lucrării și poate reduce, niciodată crește, punctajul unei sarcini.

12 Lecturi suplimentare (articole ale titularului de curs și ale coautorilor)

- ⊡ A.-V. Andrei, G. Velev, F.-M. Toma, D.T. Pele, S. Lessmann (2024). *Energy Price Modelling: A Comparative Evaluation of four Generations of Forecasting Methods*, arXiv:2411.03372 — sarcinile 2–5.
- ⊡ *Explainable AI-Based Early Warning System for Electricity Price Spikes: Evidence from the Romanian Market*, PICBE 2026, doi:10.2478/picbe-2026-0352 — sarcinile 1 și 7.
- ⊡ *Evaluating Intervention Effectiveness during Extreme Price Events: Romania's 2024 Energy Crisis*, PICBE 2026, doi:10.2478/picbe-2026-0013 — sarcina 1.

Bibliografie

[1] F.X. Diebold, R.S. Mariano (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics* 13(3), 253–263.

[2] T. Gneiting, A.E. Raftery (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association* 102, 359–378.

[3] K. Hubicka, G. Marcjasz, R. Weron (2019). A note on averaging day-ahead electricity price forecasts across calibration windows. *IEEE Transactions on Sustainable Energy* 10(1), 321–323.

[4] P. Kupiec (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives* 3, 73–84.

[5] J. Lago, G. Marcjasz, B. De Schutter, R. Weron (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy* 293, 116983 (`epftoolbox`).

[6] A. Lipiecki, B. Uniejewski, R. Weron (2024). Postprocessing of point predictions for probabilistic forecasting of day-ahead electricity prices: The benefits of using isotonic distributional regression. *Energy Economics* 139, 107934.

[7] J. Nowotarski, R. Weron (2018). Recent advances in electricity price forecasting: A review of probabilistic forecasting. *Renewable and Sustainable Energy Reviews* 81, 1548–1568.

[8] A.J. Patton (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics* 160, 246–256.

[9] B. Uniejewski, J. Nowotarski, R. Weron (2016). Automated variable selection and shrinkage for day-ahead electricity price forecasting. *Energies* 9, 621.

[10] B. Uniejewski, R. Weron, F. Ziel (2018). Variance stabilizing transformations for electricity spot price forecasting. *IEEE Transactions on Power Systems* 33(2), 2219–2229.

[11] R. Weron (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting* 30(4), 1030–1081.

[12] R. Weron (2025). *Electricity Price Forecasting*, IIF Distinguished Lectures, parts I–II, ISEA 2025, and *Machine learning for electricity price forecasting*, keynote, AIDA 2026, Bucharest.

[13] F. Ziel, R. Weron (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics* 70, 396–420.