

Analiza cantitativă a piețelor de energie

Cursul 2: Prognoza prețurilor energiei electrice

Prof. dr. Daniel Traian PELE

Academia de Studii Economice din București, Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

Obiectivele cursului

- Construirea unei prognoze pentru piața pentru ziua următoare (PZU)
  - Licitația se închide la ora 12:00 a Europei Centrale (CET) în ziua dinaintea livrării
  - Prognoza poate folosi numai datele disponibile înainte de acest moment
- Măsurarea acurateței prognozelor
  - Eroarea absolută medie (MAE), rădăcina erorii pătratice medii (RMSE) și MAE relativă (rMAE), adică eroarea modelului împărțită la eroarea unui model naiv
  - Testul Diebold–Mariano (DM) arată dacă diferența dintre două modele este semnificativă
- Estimarea modelelor expert
  - Modelul autoregresiv cu variabile exogene (ARX), cîte o regresie pentru fiecare oră
  - Aceeași regresie, cu penalizarea operatorului de contracție și selecție în normă absolută (LASSO), devine autoregresia estimată cu LASSO (LEAR)
- Combinarea prognozelor și construirea intervalelor de prognoză
  - Media mai multor modele, inclusiv modele de învățare automată (ML)
  - Cuantile ale prețului obținute prin medierea prin regresie cuantilică (QRA)
- Testarea cointegrării, anunțată în cursul 1
  - Prețurile din România și din Ungaria
  - Prețul energiei electrice, prețul gazelor și producția hidro

Abrevieri (1/2)

ADF	testul Dickey–Fuller augmentat
AI	inteligență artificială
AIC	criteriul informațional Akaike
ARX	model autoregresiv cu variabile exogene
AW	medierea prognozelor obținute pe mai multe ferestre de calibrare
AW-ARX	ARX mediat pe ferestre de calibrare
AW-LEAR	LEAR mediat pe ferestre de calibrare
CET	ora Europei Centrale
CP	predicție conformală
CRPS	scorul de probabilitate ordonat continuu (continuous ranked probability score)
CVaR	valoarea la risc condiționată (conditional value at risk)
DE-LU	zona de ofertare Germania–Luxemburg
DM	testul Diebold–Mariano
DNN	rețea neuronală profundă
DST	ora de vară
ECM	model cu corecția erorii
ENTSO-E	Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică
EPEX	bursa europeană de energie EPEX SPOT
ETC	titlu tranzacționat la bursă, garantat cu mărfuri (exchange-traded commodity)
EUA	certificat de emisii al UE (1 t CO_2)
EUPHEMIA	algoritmul comun de cuplare a piețelor europene (Pan-European Hybrid Electricity Market Integration Algorithm)
EUR	euro
GBM	gradient boosting (ansamblu de arbori de decizie construiți secvențial)
HS	simulare istorică
HU	Ungaria (zonă de ofertare)
HUPX	bursa de energie din Ungaria
ISE	Institutul Fraunhofer pentru Sisteme de Energie Solară
LARS	regresia unghiului minim (least angle regression)
LASSO	operatorul de contracție și selecție în normă absolută

Abrevieri (2/2)

LEAR	autoregresie estimată cu LASSO
LR	raportul de verosimilitate
MAD	abaterea absolută mediană
MAE	eroarea absolută medie
MAPE	eroarea procentuală absolută medie
ML	învățare automată
MLP	perceptron multistrat (rețea neuronală directă)
MTU	intervalul de tranzacționare (market time unit)
MW	megawatt
MWh	megawatt-oră
OLS	metoda celor mai mici pătrate
OPCOM	operatorul pieței de energie electrică și de gaze naturale din România
PS	scorul pinball
PZU	piața pentru ziua următoare
QRA	medierea prin regresie cuantilică
ReLU	unitate liniară rectificată (rectified linear unit)
rMAE	MAE relativă (MAE a modelului / MAE a modelului naiv)
RMSE	rădăcina erorii pătratice medii
RO	România (zonă de ofertare)
RSS	suma pătratelor reziduurilor
SDAC	cuplarea unică a piețelor pentru ziua următoare
sMAPE	MAPE simetrică
TSO	operator de transport și de sistem
TTF	Title Transfer Facility (hub olandez de gaze)
TWh	terawatt-oră
UC	acoperire necondiționată
UE	Uniunea Europeană
VST	transformare de stabilizare a variației

Prognozăm prețul orar PZU din România, numai cu date reale

Seria	Frecvența	Sursa
Variabila prognozată: prețul energiei electrice pe piața pentru ziua următoare (PZU) din România (RO)	orară	operatorul pieței de energie electrică și de gaze naturale din România (OPCOM), prin energy-charts.info (Fraunhofer ISE) și Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică (ENTSO-E)
Consumul; producția eoliană, solară, hidro și nucleară; fluxurile transfrontaliere	orară, zilnică	ENTSO-E (date Transelectrica pentru România), prin energy-charts.info
Prețul certificatului de emisii (EUA) al Uniunii Europene (UE), aproximat	zilnică	Yahoo Finance: SparkChange, titlu tranzacționat la bursă și garantat fizic cu certificate EUA (ETC)
Piețe vecine: Ungaria (HU), Germania–Luxemburg (DE-LU); gaze naturale: hubul olandez Title Transfer Facility (TTF)	zilnică, lunară	bursa de energie din Ungaria (HUPX) și bursa europeană de energie (EPEX SPOT), prin energy-charts.info; Banca Mondială, Pink Sheet (TTF)

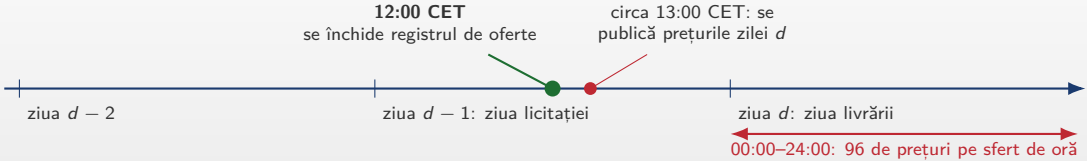
- **Perioada analizată**: 1 ianuarie 2022 – 31 octombrie 2026 (1 765 de zile complete)
  - Date descărcate la 4 noiembrie 2026
- **Perioada de test**: ultimele 365 de zile (1 noiembrie 2025 – 31 octombrie 2026)
  - **Rodajul (burn-in)**: cele 182 de zile dinainte, folosite numai pentru calibrarea intervalelor
- **Ora de vară (DST)**: 24 de ore pe zi, ca în tema 1
  - Ora lipsă din martie și ora dublată din octombrie se înlocuiesc cu medii
  - Cele 2 zile cu schimbarea orei din anul de test rămîn în analiză

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Cuprins

- Problema de prognoză și modelele de referință
  - Piața pentru ziua următoare
  - Informațiile disponibile și orizontul
  - Modele naive de referință și măsuri ale erorii
  - Testarea acurateței prognozelor
- Modele expert: ARX și LEAR
- Ferestre, combinații și învățare automată
- Prognoze probabilistice și cointegrare
- Studii de caz pe date recente din România

PZU: licitația din ziua $d-1$ fixează cele 96 de prețuri ale zilei d



- **Ce este**
  - Licitația zilnică a cuplării unice a piețelor pentru ziua următoare (SDAC); în România o organizează OPCOM
  - Cumpărătorii și vînzătorii depun oferte (cantitate, preț) pentru fiecare interval al zilei următoare
- **Cum se formează prețul**
  - La ora 12:00 CET din ziua $d-1$ se închide registrul de oferte
  - Un algoritm comun, Pan-European Hybrid Electricity Market Integration Algorithm (EUPHEMIA), echilibrează cererea și oferta în limita capacităților transfrontaliere; rezultatele se publică de regulă în jurul orei 13:00 CET
- **Intervalele de livrare**
  - Din ziua de livrare 1 octombrie 2025: 96 de prețuri pe sfert de oră (înainte: 24 de prețuri orare)
  - În datele noastre, prețul orar = media celor patru sferturi de oră; tot anul de test folosește aceste medii

(NEMO Committee, 2025, 2026; OPCOM)

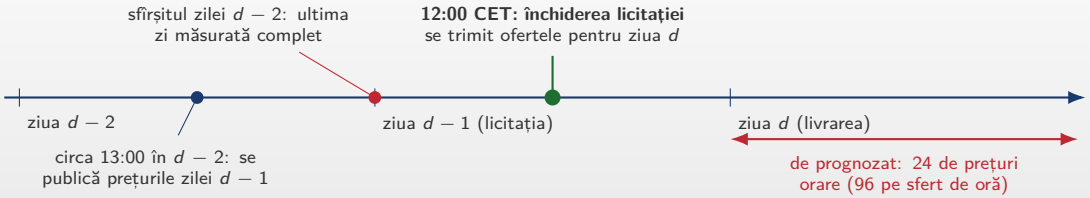
Notația și regula pe care o respectă toate prognozele din acest curs

- **Notația**
  - d = ziua livrării; $d-1$ = ziua dinainte, în care are loc licitația; $d-2$ = cu două zile înainte
  - $h = 0, \ldots, 23$ = ora livrării (CET); $P_{d,h}$ = prețul PZU al orei h din ziua d, în EUR/MWh; $\hat{P}_{d,h}$ = prognoza acestui preț
- **Regula**
  - Prognoza pentru ziua d se face înainte de ora 12:00 CET din ziua $d-1$, deci poate folosi numai ce se cunoaște în acel moment
  - Permis: toate cele 24 de prețuri ale zilei $d-1$ (stabilite prin licitația din ziua $d-2$); prognozele de consum și de producție eoliană și solară pentru ziua d, publicate de operatorul de transport și de sistem (TSO) înainte de 12:00
  - Interzis: orice valoare realizată în ziua d și valorile zilei $d-1$ care nu sînt încă măsurate
- **Ce prognozăm și cum evaluăm**
  - Cele 24 de prețuri orare PZU din România, pentru fiecare zi a anului de test
  - Eroarea $P_{d,h} - \hat{P}_{d,h}$ se cunoaște abia după livrarea din ziua d

- **În practică:** aceeași regulă se aplică oricărui birou de tranzacționare
  - Un model care o încalcă nu poate fi rulat la 12:00.

(NEMO Committee, 2025; Lago et al., 2021, APEN)

Prognoza zilei d folosește doar datele cunoscute la 12:00 CET în ziua $d-1$



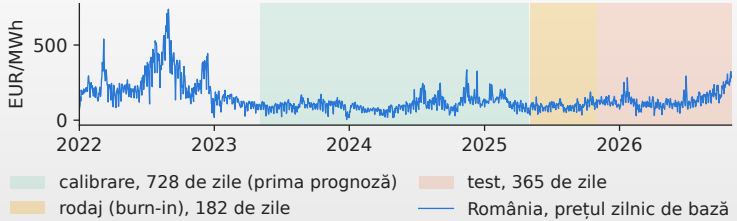
- **Ce folosesc modelele noastre**
  - Prețurile pînă în ziua $d-1$; consumul, producția și fluxurile realizate pînă în ziua $d-2$; prețul carbonului la închiderea din $d-2$
- **Ce nu avem în date**
  - Prognozele TSO de consum și de producție regenerabilă pentru ziua d

- **În practică:** o testare retrospectivă cu consumul realizat în ziua $d-1$ pare excelentă, dar la 12:00 acest consum nu se cunoaște.

(tema 1; OPCOM; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Datele se împart cronologic în calibrare, rodaj și test, fără amestecare



Sursa: energy-charts.info (Fraunhofer ISE); prețurile PZU ale OPCOM pentru România, prin ENTSO-E. Date: preț zilnic de bază, 2022-01-01 - 2026-10-31, zile de livrare CET.

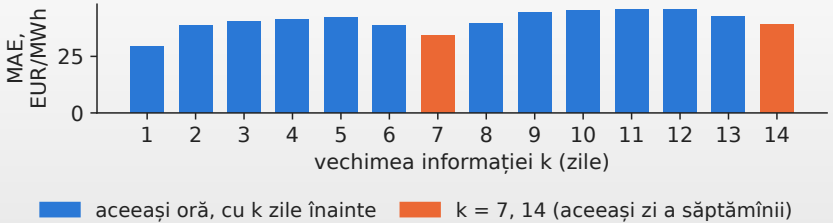
- Calibrare = estimarea modelului, rodaj = prognoze folosite doar pentru intervale, test = măsurarea erorii
  - Reestimare zilnică pe fereastra încheiată în $d-1$, fără K-fold aleator.

- **În practică:** cereți furnizorului o testare retrospectivă (backtest) pe fereastră glisantă, nu ajustarea pe datele de estimare.

(Weron, 2014, IJF; Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

EMQA_L2_split_timeline

Prețul mai vechi dă erori mai mari, cu excepția celui de acum o săptămînă



Sursa: energy-charts.info (Fraunhofer ISE); prețurile PZU ale OPCOM pentru România, prin ENTSO-E. Date: anul de test 2025-11-01 - 2026-10-31, date orare.

- Prognoza $\hat{P}_{d,h} = P_{d-k,h}$ (prețul aceleiași ore de acum k zile)
  - MAE 29,37 EUR/MWh pentru $k = 1$, 38,52 pentru $k = 2$, doar 34,41 pentru $k = 7$ (aceeași zi a săptămînii)

- **În practică:** prognoza de la 12:00 din ziua $d - 1$ privește următoarele 12–36 de ore
  - Cel mai recent preț cunoscut este cel al zilei $d - 1$.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L2_horizon_naive

Prognozele punctuale, probabilistice și de traiectorie răspund la întrebări diferite

- **Pe scurt:** Prognoza punctuală dă un preț pentru fiecare oră, cea probabilistică dă distribuția prețului, iar cea de traiectorie dă scenarii pentru toate cele 24 de ore.

$$\underbrace{\hat{P}_{d,h}}_{\text{punctuală}} \qquad \underbrace{\hat{q}^{\tau}_{d,h}:\ \Pr(P_{d,h} \leq \hat{q}^{\tau}_{d,h}) = \tau}_{\text{cuantilă}} \qquad \underbrace{\{\hat{P}^{(s)}_{d,0}, \ldots, \hat{P}^{(s)}_{d,23}\}_{s=1}^{S}}_{\text{traiectorii}}$$

- **unde**
  - d = ziua livrării
  - h = ora (CET)
  - $\hat{q}^{\tau}_{d,h}$ = cuantila de nivel $\tau \in (0,1)$
  - s = scenariul
  - S = numărul de scenarii.

- **Pe datele din România**
  - Corelația erorilor de prognoză între orele 12 și 13: 0,96
  - Între orele 3 și 19: doar 0,13

- **Cine folosește fiecare tip**
  - Furnizorul de energie care cumpără un bloc de ore: prognoza punctuală
  - Managerul de risc: cuantilele (cursul 4)
  - Operatorul unei baterii: traiectoriile, deoarece cumpără energie într-o oră și o vinde în alta

- **În practică:** înainte de a cumpăra o prognoză, stabiliți de care dintre cele trei tipuri are nevoie decizia dumneavoastră.

(Nowotarski & Weron, 2018, RSER)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Modelul naiv: prețul de ieri sau, lunea și în weekend, prețul de acum 7 zile

- **Pe scurt:** Orice model trebuie să fie mai precis decît regula simplă pe care un trader ar aplica-o fără niciun model.

$$\hat{P}^{\text{naive}}_{d,h} = \begin{cases} P_{d-7,h}, & \text{lun., sîm., dum.} \\ P_{d-1,h}, & \text{mar.–vin.} \end{cases}$$
$$\hat{P}^{(7)}_{d,h} = P_{d-7,h}$$

- **unde**
  - $P_{d,h}$ = prețul zilei d, ora h (EUR/MWh)
  - $\hat{P}^{(7)}$ = modelul naiv sezonier: aceeași oră, cu o săptămînă în urmă.

- **De ce se schimbă regula** (MAE, EUR/MWh)
  - Luni, sîmbătă, duminică: $d-7$ dă 29,87, $d-1$ dă 33,48
  - Marți–vineri: $d-1$ dă 26,27, $d-7$ dă 37,83
- **Anul de test**
  - MAE: modelul naiv 27,82, naiv sezonier 34,41 EUR/MWh
  - Prețul mediu este 134,46 EUR/MWh, deci eroarea naivă reprezintă circa o cincime din preț

- **În practică:** cereți oricărui furnizor de prognoze rMAE față de această regulă naivă, calculată pe orele care vă interesează.

(Nogales et al., 2002, IEEE TPWRS; Weron, 2014, IJF)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Patru măsuri ale erorii și rMAE, care compară modelul cu cel naiv

- **Pe scurt:** Erorile absolute sînt în EUR/MWh, cele pătratice penalizează salturile, rMAE compară cu modelul naiv.

$$\text{MAE} = \frac{1}{N}\sum |e_{d,h}|, \quad \text{RMSE} = \sqrt{\frac{1}{N}\sum e_{d,h}^2}$$

$$\text{sMAPE} = \frac{1}{N}\sum \frac{2|e_{d,h}|}{|P_{d,h}|+|\hat{P}_{d,h}|}, \quad \text{rMAE} = \frac{\text{MAE}_{\text{model}}}{\text{MAE}_{\text{naive}}}$$

- **unde**
  - $e_{d,h} = P_{d,h} - \hat{P}_{d,h}$ = eroarea
  - N = numărul perechilor (zi, oră)
  - Eroarea procentuală absolută medie simetrică (sMAPE) $\in [0, 200\%]$
  - Valoare rMAE < 1 = mai precis decît modelul naiv.

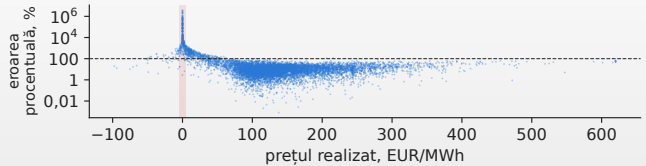
- **Pe datele din România**, anul de test 1 noiembrie 2025 – 31 octombrie 2026
  - Modelul naiv: MAE 27,82, RMSE 44,54, sMAPE 34,5%
  - LEAR mediat pe ferestre de calibrare (AW-LEAR, secțiunea 3): MAE 22,53, RMSE 36,35, rMAE 0,810
  - Cel mai bun, ansamblul de 4 modele: rMAE 0,795, adică o eroare cu 20,5% mai mică decît a modelului naiv
- MAE este minimă pentru prognoza mediană, RMSE pentru cea medie.

- **În practică:** raportați biroului de tranzacționare MAE în EUR/MWh, iar conducerii rMAE, calculate pe aceleași ore.

(Hyndman & Koehler, 2006, IJF; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Erorile procentuale nu funcționează la prețuri apropiate de zero sau negative



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

- Eroarea procentuală absolută medie (MAPE) $= \frac{1}{N}\sum |e_{d,h}|/|P_{d,h}|$
  - AW-LEAR: 5 777,7%, dar doar 32,4% fără cele 387 de ore cu $|P| < 5$ EUR/MWh.
- Aceste puține ore generează 99,5% din valoarea MAPE.

- **În practică:** nu acceptați MAPE pentru prețurile energiei electrice
  - Cereți MAE și rMAE.

(Hyndman & Koehler, 2006, IJF; Weron, 2014, IJF)

EMQA_L2_mape_fail

Testul Diebold–Mariano arată dacă un model este cu adevărat mai precis decît altul

- **Pe scurt:** Comparăm, zi de zi, eroarea medie a două modele; dacă diferența medie este mare față de variabilitatea ei, avantajul unui model nu se datorează întîmplării.

$$\Delta_d = \underbrace{\tfrac{1}{24}\sum_h |e^A_{d,h}|}_{\text{modelul A}} - \underbrace{\tfrac{1}{24}\sum_h |e^B_{d,h}|}_{\text{modelul B}}, \qquad \mathrm{DM} = \frac{\bar{\Delta}}{\sqrt{\hat{\sigma}^2_{\Delta}/n}}$$

- **unde**
  - Δ_d = diferența de eroare din ziua d
  - n = numărul zilelor de test
  - $\hat{\sigma}^2_{\Delta}$ = varianța Newey–West cu 7 decalaje
  - Valoarea $p = 1 - \Phi(\mathrm{DM})$ sub 0,05 = B este semnificativ mai precis decît A.

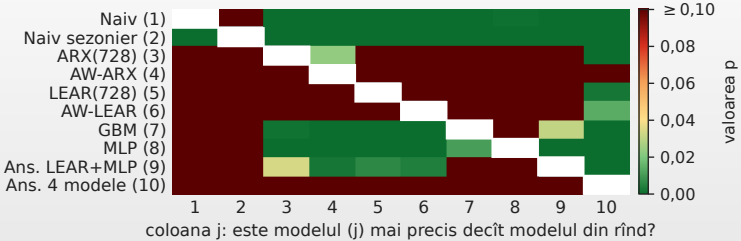
- **Pe datele din România**, 365 de zile de test
  - Modelul naiv față de AW-LEAR: DM 7,32, p <0,001
  - ARX mediat pe ferestre (AW-ARX) față de AW-LEAR: DM −0,83, $p = 0{,}797$, diferență nesemnificativă statistic
  - AW-LEAR față de ansamblul de 4 modele: DM 2,21, $p = 0{,}014$
- Media pe zi elimină corelația dintre cele 24 de ore ale aceleiași zile (varianta multivariată a testului).

- **În practică:** schimbați modelul numai dacă îmbunătățirea este semnificativă pe orele care vă interesează.

(Diebold & Mariano, 1995, JBES; Ziel & Weron, 2018, ENEECO)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Matricea testelor DM: care modele sînt semnificativ mai precise în România



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; producție și fluxuri: ENTSO-E (date Transelectrica); Yahoo Finance (SparkChange EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31, 365 de zile; valori p unilaterale.

- 8 dintre celelalte 9 modele sînt semnificativ mai precise decît modelul naiv, la pragul de 5%
  - O celulă verde = modelul din coloană este semnificativ mai precis decît cel din rînd.

- **În practică:** citiți fiecare coloană de sus în jos
  - Multe celule verzi indică un model pentru care merită să plătiți.

(Ziel & Weron, 2018, ENEECO; Lago et al., 2021, APEN)

EMQA_L2_dm_matrix

Cuprins

- Problema de prognoză și modelele de referință
- Modele expert: ARX și LEAR
  - Modelul expert ARX
  - Transformări de stabilizare a variației
  - Autoregresia estimată cu LASSO
- Ferestre, combinații și învățare automată
- Prognoze probabilistice și cointegrare
- Studii de caz pe date recente din România

Modelul expert ARX: prețuri recente, calendar și variabile fundamentale

- **Pe scurt:** O regresie liniară pentru fiecare oră, cu variabilele urmărite de un trader.

$$Y_{d,h} = \beta_0 + \underbrace{\beta_1 Y_{d-1,h} + \beta_2 Y_{d-2,h} + \beta_3 Y_{d-7,h}}_{\text{autoregresie}} + \underbrace{\beta_4 Y_{d-1,23} + \beta_5 Y^{\min}_{d-1} + \beta_6 Y^{\max}_{d-1}}_{\text{forma zilei precedente}} + \underbrace{\beta_7 \tilde{L}_{d,h} + \beta_8 \tilde{R}_{d,h}}_{\text{fundamentale din } d-2} + \underbrace{\sum_j \delta_j D^j_d}_{\text{lun., sîm., dum.}} + \varepsilon_{d,h}$$

- **Estimare**
  - Metoda celor mai mici pătrate (OLS), separat pentru fiecare h
  - 12 regresori pentru fiecare oră, ca în tema 1
- **Pe datele din România**, ARX(728)
  - Reestimat zilnic pe ultimele 728 de zile
  - MAE 22,72 EUR/MWh, rMAE 0,817

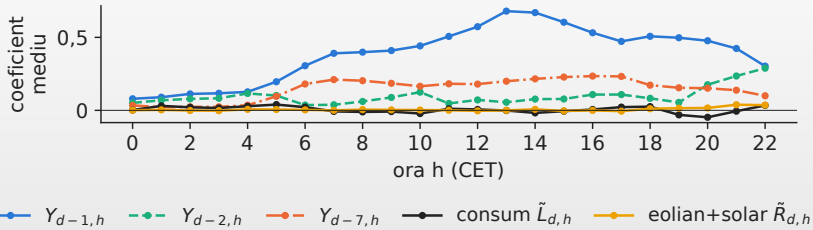
- **unde**
  - Y = prețul transformat asinh
  - $\tilde{L}_{d,h} = L_{d-2,h}$ = consumul, $\tilde{R}_{d,h}$ = producția eoliană și solară din $d-2$, standardizate.

- **În practică:** acesta este modelul de depășit înainte să cumpărați o rețea neuronală.

(Ziel & Weron, 2018, ENEECO; Weron, 2014, IJF)

Exerciții practice: notebook-ul Jupyter, secțiunea 3

Coeficienții modelului ARX diferă de la o oră la alta



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: ARX(728), media celor 365 de estimări zilnice din anul de test.

- $Y_{d-1,h}$ (aceeași oră, ieri) are coeficientul maxim la ora 13 (0,68) și minim la ora 0 (0,08)
  - Noaptea contează mai mult ultima oră a zilei $d-1$ (pînă la 0,73).
- Consumul și producția eoliană și solară au coeficienți apropiați de zero: datele din $d-2$ adaugă puțin.

- **În practică:** cîte un model pe oră permite ca vîrful de seară să depindă de alți factori decît noaptea.

(estimare proprie, ARX(728))

EMQA_L2_arx_coef

Variabilele fundamentale din ziua $d-2$ aproape că nu îmbunătățesc prognoza

ARX(728), anul de test	MAE	RMSE	rMAE
numai prețuri și calendar	22,63	36,49	0,813
+ consum, producție eoliană și solară din $d-2$	22,72	36,62	0,817
+ hidro, nuclear, import net, EUA din $d-2$	22,72	36,50	0,817

- Valorile lipsă ale variabilelor fundamentale se înlocuiesc cu ultima valoare observată (pentru nuclear, în 29 de zile).
- EUA = prețul de închidere al titlului SparkChange din ziua $d-2$, folosit ca aproximare a prețului certificatului de emisii.

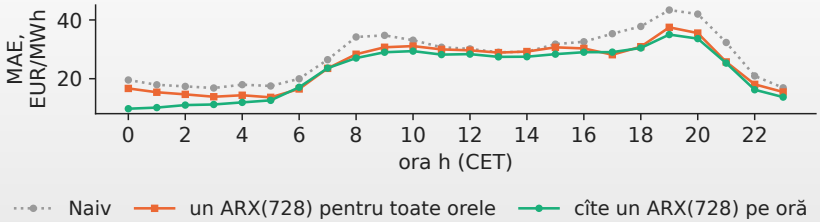
- **De ce atît de puțin**
  - Informația din ziua $d-2$ este deja inclusă în prețul zilei $d-1$
  - De exemplu, opririle centralei nucleare de la Cernavodă intră în model cu două zile întîrziere
- **Ce ar ajuta**
  - Prognozele de consum și de producție eoliană și solară pentru ziua d (ENTSO-E, Transelectrica)
  - Sînt publicate înainte de 12:00 în ziua $d-1$, deci pot fi folosite, dar nu fac parte din datele noastre gratuite

- **În practică:** cumpărați prognozele TSO de consum și de producție regenerabilă pentru ziua următoare înainte de a plăti pentru un model mai complex.

(estimare proprie; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 3

Cîte un model pentru fiecare oră este mai precis decît un model comun



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: anul de test 2025-11-01 - 2026-10-31.

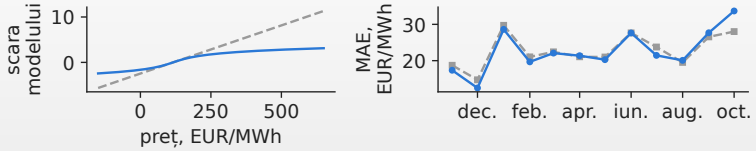
- MAE: 22,72 cu cîte un model pe oră, 24,54 EUR/MWh cu un model comun (constantă proprie fiecărei ore, pante comune)
  - Modelul comun este mai slab în 21 din 24 de ore.

- **În practică:** din 1 octombrie 2025 se tranzacționează sferturi de oră, deci aceeași alegere apare pentru cele 96 de intervale ale zilei.

(Ziel & Weron, 2018, ENEECO)

EMQA_L2_per_hour_single

Transformarea asinh atenuează salturile și acceptă prețuri negative



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: stînga, mediana și scala din ultima fereastră; dreapta, anul de test 2025-11-01 - 2026-10-31.

- Transformarea de stabilizare a variației (VST): $Y = \text{asinh}((P - m)/s)$
  - m = mediana, $s = 1{,}4826 \times$ abaterea absolută mediană (MAD), ambele din fereastra de calibrare.
- MAE pentru ARX(728): 22,86 pe prețuri netransformate, 22,72 cu asinh
  - Pentru RMSE ordinea se inversează (35,85 față de 36,62).

- **În practică:** funcția asinh este definită și pentru valori negative, unde logaritmul nu poate fi folosit.

(Uniejewski, Weron & Ziel, 2018, IEEE TPWRS)

EMQA_L2_vst

LEAR pornește de la 247 de regresori, iar LASSO îi elimină pe cei mai mulți

- **Pe scurt:** O penalizare a mărimii coeficienților îi face zero pe cei inutili, deci datele aleg regresorii.

$$\hat{\beta}_h = \arg\min_{\beta} \left\{ \underbrace{\sum_{d \in \text{cal}} (Y_{d,h} - \mathbf{x}_d^\top \beta)^2}_{\text{ajustare}} + \underbrace{\lambda_h \sum_j |\beta_j|}_{\text{penalizare}} \right\}$$

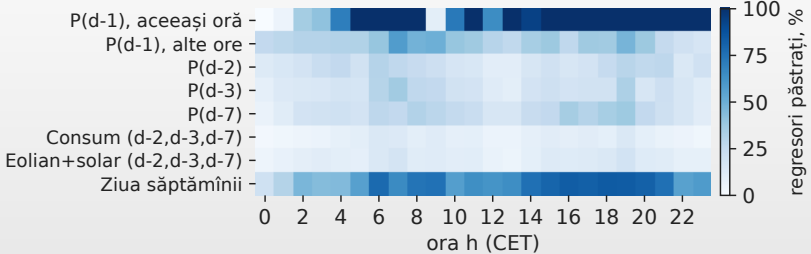
- **unde**
  - $\mathbf{x}_d = 247$ de regresori: cele 24 de prețuri din $d-1, d-2, d-3, d-7$ (96), consumul și producția eoliană și solară din $d-2, d-3, d-7$ (144), 7 indicatori ai zilei
  - $\lambda_h =$ intensitatea penalizării, aleasă zilnic prin criteriul informațional Akaike (AIC).

- **Pe datele din România**, LEAR(728)
  - Rămîn în medie 42 din 247 (17%), între 8 și 121
  - MAE 22,62; media prognozelor estimate pe 364, 546 și 728 de zile (AW-LEAR): 22,53 EUR/MWh
- **Cum se alege corect** λ
  - Printr-un criteriu informațional sau pe un bloc de validare care se încheie înaintea zilei prognozate
  - Niciodată pe anul de test

- **În practică:** un model LASSO este ușor de interpretat: regresorii păstrați arată ce influențează prețul în fiecare oră.

(Tibshirani, 1996; Uniejewski, Nowotarski & Weron, 2016; Lago et al., 2021) **Exercițiu practic:** notebook-ul Jupyter, secțiunea 4

LEAR păstrează prețul aceleiași ore de ieri și ziua săptămînii



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: LEAR(728), 365 de estimări zilnice din anul de test.

- Procentul mediu al regresorilor păstrați din fiecare grupă: $P_{d-1,h}$ (aceeași oră, ieri) 79%, ziua săptămînii 64%, consum 9%, producție eoliană și solară 11%.

- **În practică:** pentru cîștiguri reale aveți nevoie de prognoze ale variabilelor fundamentale pentru ziua d.

(estimare proprie, LEAR(728), anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L2_lear_sel

Cuprins

- Problema de prognoză și modelele de referință
- Modele expert: ARX și LEAR
- Ferestre, combinații și învățare automată
  - Ferestre de calibrare
  - Combinarea prognozelor
  - Învățarea automată: introducere la cursul 7
- Prognoze probabilistice și cointegrare
- Studii de caz pe date recente din România

Ferestrele scurte se adaptează, cele lungi sînt stabile: mediați prognozele

- **Pe scurt:** În loc să ghiciți lungimea optimă a ferestrei de calibrare, estimați modelul pe mai multe ferestre și faceți media prognozelor.

$$\hat{P}^{\mathrm{AW}}_{d,h} = \frac{1}{|\mathcal{T}|} \sum_{T \in \mathcal{T}} \underbrace{\hat{P}^{(T)}_{d,h}}_{\text{fereastră de } T \text{ zile}}$$

- **unde**
  - $\hat{P}^{(T)}_{d,h}$ = prognoza estimată pe ultimele T zile (fereastră glisantă)
  - ARX: $\mathcal{T} = \{56, 84, 112, 714, 721, 728\}$
  - LEAR: $\mathcal{T} = \{364, 546, 728\}$
  - Medierea pe ferestre de calibrare (AW).

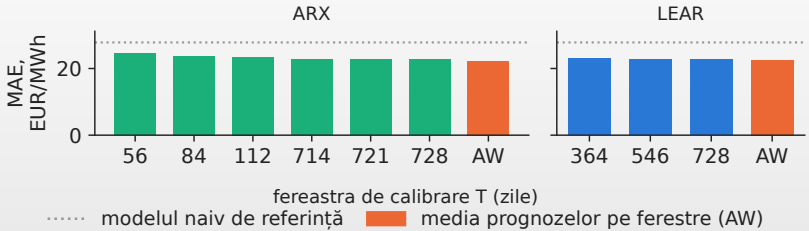
- **Pe datele din România**, MAE în EUR/MWh
  - ARX(56) 24,44, ARX(112) 23,41, ARX(728) 22,72
  - AW-ARX 22,30, mai precis decît modelul estimat pe oricare fereastră
  - LEAR(364) 22,96, LEAR(728) 22,62, AW-LEAR 22,53
- Combinarea ferestrelor scurte (56–112 zile) cu cele lungi (714–728 de zile) aduce atît adaptare, cît și stabilitate.

- **În practică:** cînd piața își schimbă regimul (2022, 2024), ferestrele scurte reacționează primele
  - Păstrați-le în medie.

(Hubicka, Marcjasz & Weron, 2019; Marcjasz, Serafin & Weron, 2018)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Media pe ferestre este mai precisă decît cea mai bună fereastră



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: anul de test 2025-11-01 - 2026-10-31.

- MAE: AW-ARX 22,30, față de 22,68 pentru cea mai bună fereastră, ARX(714)
  - Linia punctată = modelul naiv, 27,82 EUR/MWh.

- **În practică:** nu trebuie să știți dinainte care fereastră este potrivită
  - Faceți media prognozelor obținute pe o fereastră scurtă și pe una lungă.

(Hubicka, Marcjasz & Weron, 2019, IEEE TSTE)

EMQA_L2_windows

Combinarea modelelor: erorile care nu coincid se compensează

- **Pe scurt:** Dacă două modele greșesc în zile diferite, media simplă a prognozelor lor greșește mai rar decît fiecare dintre ele.

$$\hat{P}^{\text{ens}}_{d,h} = \frac{1}{K}\sum_{k=1}^{K} \hat{P}^{(k)}_{d,h}, \quad \text{Var}(\bar{e}) = \frac{\bar{\sigma}^2}{K}\left(1 + (K-1)\bar{\rho}\right)$$

- **unde**
  - K = numărul de modele
  - $\bar{\sigma}^2$ = varianța medie a erorilor
  - $\bar{\rho}$ = corelația medie a erorilor
  - Cu cît $\bar{\rho}$ e mai mic, cu atît cîștigul e mai mare
  - Ponderile egale nu se estimează.

- **Pe datele din România**, ansamblul de 4 modele
  - AW-ARX, AW-LEAR, un model gradient boosting (GBM) și un perceptron multistrat (MLP), ponderi egale
  - MAE 22,13 EUR/MWh, rMAE 0,795, cel mai bun dintre toate modelele
  - Mai bun decît AW-LEAR în 8 din 12 luni și în 15 din 24 de ore
  - Testul DM față de AW-LEAR: $p = 0{,}014$
- Cei doi membri mai slabi (GBM, MLP) ajută totuși, deoarece erorile lor diferă.

- **În practică:** cereți furnizorilor de prognoze serii pe care să le puteți combina cu ale dumneavoastră, nu un singur model „cel mai bun".

(Bates & Granger, 1969; Nowotarski & Weron, 2015)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Clasamentul modelelor pe anul de test în România

Model	MAE	RMSE	sMAPE, %	rMAE
Naiv	27,82	44,54	34,5	1,000
Naiv sezonier	34,41	55,48	39,4	1,237
ARX(56)	24,44	40,09	30,0	0,879
ARX(728)	22,72	36,62	27,8	0,817
AW-ARX	22,30	36,34	27,6	0,802
ARX(728), model comun	24,54	37,97	29,5	0,882
ARX(728), fără VST	22,86	35,85	28,4	0,822
LEAR(364)	22,96	36,80	28,1	0,825
LEAR(728)	22,62	36,36	27,7	0,813
AW-LEAR	22,53	36,35	27,7	0,810
GBM	24,05	37,73	28,7	0,864
MLP	25,54	40,05	29,8	0,918
Ansamblu LEAR+MLP	23,12	36,95	28,1	0,831
Ansamblu de 4 modele	22,13	35,76	27,4	0,795

- Anul de test 1 noiembrie 2025 – 31 octombrie 2026, 8 760 de ore; verde = mai precis, roșu = mai puțin precis, separat pe fiecare coloană.
- Fără cele 2 zile cu schimbarea orei, MAE pentru AW-LEAR este 22,48; clasamentul nu se schimbă.

(Weron, 2014, IJF; Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

Exerciții practic: notebook-ul Jupyter, secțiunea 5

Gradient boosting: mulți arbori mici, fiecare corectîndu-i pe cei anteriori

- **Pe scurt:** Arborii surprind praguri și interacțiuni (de exemplu, vînt slab și consum mare seara), pe care un model liniar nu le vede.

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\, f_m(\mathbf{x})$$

$$f_m = \arg\min_f \sum_i \left(r_i^{(m)} - f(\mathbf{x}_i)\right)^2$$

- **unde**
  - f_m = un arbore de regresie mic
  - $r_i^{(m)} = Y_i - F_{m-1}(\mathbf{x}_i)$ = reziduul curent
  - $\nu = 0{,}05$ = rata de învățare
  - 500 de arbori.

- **Modelul nostru de gradient boosting (GBM)**
  - Un singur model pentru toate orele, ora fiind o variabilă; 20 de variabile, toate cunoscute la 12:00 în ziua $d-1$
  - Reestimat la începutul fiecărei luni de test (12 reestimări), pe toate zilele anterioare
- **Rezultat**
  - MAE 24,05, rMAE 0,864; pe ansamblul anului, mai puțin precis decît AW-LEAR
  - Dar cel mai bun model individual în săptămîna de criză (MAE 34,35)

- **În practică:** arborii merită incluși într-un ansamblu, chiar dacă nu sînt cei mai buni luați separat.

(Friedman, 2001, Ann. Stat.; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 6

Rețele neuronale: 24 de prețuri dintr-un singur vector de intrare

- **Pe scurt:** O rețea cu 24 de ieșiri prognozează toată ziua deodată, ca rețeaua neuronală profundă (DNN) din Lago et al.

$$\hat{\mathbf{Y}}_d = W_3\,\phi\Big(W_2\,\phi(W_1\mathbf{x}_d + b_1) + b_2\Big) + b_3 \in \mathbb{R}^{24}$$

- **unde**
  - $\mathbf{x}_d$ = cei 247 de regresori LEAR și 4 variabile fundamentale din $d-2$
  - ϕ = unitatea liniară rectificată (ReLU)
  - Straturi ascunse de 128 și 64 de neuroni
  - Perceptron multistrat (MLP).

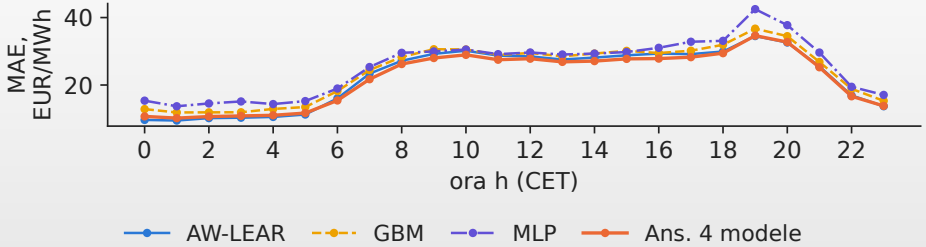
- **Disciplina seriilor de timp**
  - Numărul de epoci, ales pe ultimele 15% din zile (mediana: 20)
  - Media a 4 inițializări; reestimare lunară; standardizare pe zilele de antrenare
- **Rezultat**
  - MAE 25,54, rMAE 0,918; o rețea mică, neoptimizată, nu depășește LEAR
  - Rețeaua DNN optimizată de Lago et al. (2021) obține rezultate mai bune (cursul 7)

- **În practică:** o rețea neuronală cere ani de date și o calibrare atentă
  - Altfel, păstrați LEAR.

(Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 6

Pe ore, învățarea automată ajută în cadrul ansamblului, nu luată separat



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; producție și fluxuri: ENTSO-E (date Transelectrica); Yahoo Finance (SparkChange EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31; modelele ML reestimate lunar.

- GBM este mai precis decît AW-LEAR în 0 ore, MLP în 0, iar ansamblul de 4 modele în 15 din 24 de ore.
- Ora cea mai dificilă este 19 CET, cînd prețul urcă abrupt seara (MAE AW-LEAR 34,52 EUR/MWh).

- **În practică:** alocați cel mai bun analist orelor de seară, unde se pierd cei mai mulți bani.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L2_ml_hour

Studiul de caz C2: pentru consumul din România, învățarea automată dă cele mai mici erori

- **Ce a făcut lucrarea** (Proșcanu, Proșcanu, Pele & Costea, 2025)
  - Date și metode: consumul național orar al României, 2022–2024; modele sezoniere clasice comparate cu rețele neuronale
  - Rezultat: o rețea neuronală are o eroare net mai mică decît modelul autoregresiv sezonier
- **Replicarea noastră** (studiul de caz C2, cu aceeași regulă: date pînă la 12:00 în ziua $d-1$)
  - 217 zile de test, începînd cu 27 mai 2024; consumul măsurat pînă în ziua $d-2$
  - MAPE: gradient boosting 4,09%, modelul fundațional Chronos-Bolt 4,16%, MLP 4,58%
  - Regresie liniară 4,85%, model autoregresiv sezonier 8,03%, modelul naiv (consumul de acum două zile) 10,17%
- **De ce rezultatul diferă de cel pentru prețuri**
  - Consumul variază lin și nu se apropie de zero: MAPE are sens, iar modelele neliniare găsesc regularități
  - Prețurile au salturi și devin negative: aici, un model liniar bine construit este greu de depășit
- Cifrele C2 sînt calculate cu notebook-ul Jupyter al studiului de caz C2, pe datele noastre; rezultatele lucrării sînt prezentate în fișa studiului de caz.

- **În practică:** prognozați consumul propriu cu modele ML, iar prețul cu LEAR și un ansamblu de modele.

(Proșcanu, Proșcanu, Pele & Costea, 2025, RJEF; studiul de caz C2)

Cuprins

- Problema de prognoză și modelele de referință
- Modele expert: ARX și LEAR
- Ferestre, combinații și învățare automată
- Prognoze probabilistice și cointegrare
  - Medierea prin regresie cuantilică
  - Cointegrarea: prețuri care evoluează împreună
- Studii de caz pe date recente din România

Medierea prin regresie cuantilică: de la prognoze punctuale la cuantile

- **Pe scurt:** Regresăm prețul realizat pe mai multe prognoze punctuale, separat pentru fiecare nivel al cuantilei; rezultatul este o distribuție a prețului.

$$\hat{q}^{\tau}_{d,h} = \beta^{\tau}_{0,h} + \beta^{\tau}_{1,h}\hat{P}^{\text{AW-ARX}}_{d,h} + \beta^{\tau}_{2,h}\hat{P}^{\text{AW-LEAR}}_{d,h}$$

$$\text{PS}_{\tau}(q, y) = \big(\mathbb{1}\{y < q\} - \tau\big)(q - y)$$

- **unde**
  - $\hat{q}^{\tau}_{d,h}$ = cuantila de nivel τ a prețului
  - β^{τ}_{h} minimizează scorul pinball (PS) pe prognozele din ultimele 182 de zile, cu reestimare săptămînală
  - $\tau = 0{,}01, \ldots, 0{,}99$.

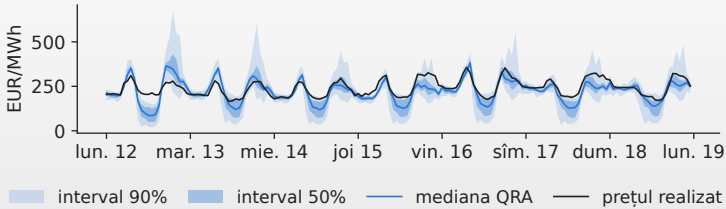
- **Pe datele din România**, scorul pinball mediu (mai mic = mai bine)
  - QRA 8,33; predicție conformală (CP) 8,47; simulare istorică (HS) 8,41
  - CP și HS folosesc erorile AW-LEAR din ultimele 112 zile, ca în tema 1
- **Acoperirea intervalului de 90%**
  - QRA 85,7%, CP 87,0%, HS 85,8%; lățimea medie a intervalului QRA: 93,0 EUR/MWh
  - Toate sub 90%; testul Kupiec respinge ipoteza unei acoperiri corecte

- **În practică:** o bandă de 90% care conține doar 86% din prețuri subestimează riscul poziției deschise.

(Koenker & Bassett, 1978; Nowotarski & Weron, 2015)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

O săptămînă de intervale QRA în România: largi seara, înguste noaptea



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: săptămîna 2026-10-12 - 2026-10-18, date orare.

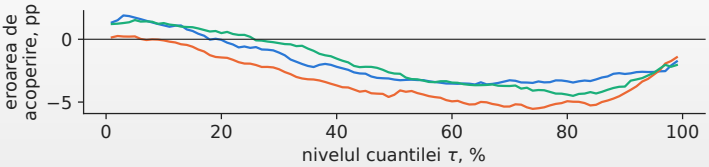
- Săptămîna 12 octombrie 2026 – 18 octombrie 2026
  - Intervalul este larg seara, cînd prețul este incert, și îngust noaptea.
- Mediana QRA are MAE 22,14 EUR/MWh, la fel de precisă ca cea mai bună prognoză punctuală.

- **În practică:** ofertați în intervalul de 50% volumele pe care trebuie să le cumpărați, iar în cozi pe cele pe care le puteți muta.

(Nowotarski & Weron, 2015, Comput. Stat.)

EMQA_L2_qra_week

Toate cele trei metode subestimează cozile distribuției prețului



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; consum, producție eoliană și solară: ENTSO-E (date Transelectrica).
Date: anul de test 2025-11-01 - 2026-10-31, 99 de cuantile.

- Eroarea de acoperire = ponderea prețurilor sub cuantila de nivel τ minus τ (0 = calibrare perfectă)
  - Peste 0 în stînga și sub 0 în dreapta = cozi prea înguste.
- Statistica Kupiec pentru intervalul de 90%: QRA 162,9, CP 83,3, HS 154,1 (valoarea critică la 5% este 3,84).

- **În practică:** lărgiți cozile înainte de a folosi cuantilele pentru calculul garanțiilor (cursul 4).

(Kupiec, 1995, J. Derivatives; Gneiting & Raftery, 2007, JASA)

EMQA_L2_prob_rel

Două prețuri sînt cointegrate dacă diferența dintre ele revine spre echilibru

- **Pe scurt:** Fiecare preț poate fi nestaționar, dar, dacă o combinație liniară a lor este staționară, abaterea se închide, iar regresia nu este spurioasă.

$$\underbrace{P_t^{\mathrm{RO}} = \alpha + \beta P_t^{\mathrm{HU}} + u_t}_{\text{pasul 1, OLS}}$$

$$\underbrace{\Delta \hat{u}_t = \rho\, \hat{u}_{t-1} + \sum\nolimits_j \gamma_j \Delta \hat{u}_{t-j} + \eta_t}_{\text{pasul 2, rădăcină unitară în } \hat{u}}$$

- **unde**
  - Engle–Granger: H_0 = fără cointegrare ($\rho = 0$), valori critice MacKinnon
  - Johansen: testul urmei pentru rangul r (numărul relațiilor de cointegrare).

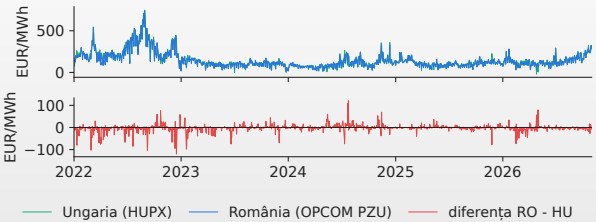
- **România și Ungaria**, zilnic, din 1 ianuarie 2022
  - $\hat{\beta} = 0{,}963$; Engle–Granger $-10{,}58$ (critic la 5%: $-3{,}34$): cointegrate
  - Un șoc asupra diferenței de preț se înjumătățește în 0,8 zile
- **Testul urmei Johansen**
  - $r = 0$: 139,7 față de 15,49; $r \leq 1$: 6,21 față de 3,84
  - Rangul 2: nivelurile sînt aproape staționare din 2022 (testul Dickey–Fuller augmentat (ADF), $p = 0{,}064$)

- **În practică:** o poziție pe diferența de preț RO–HU se închide în cîteva zile, nu în luni.

(Engle & Granger, 1987; Johansen, 1991; MacKinnon, 1996)

Exercițiu practic: notebook-ul Jupyter, secțiunea 8

România și Ungaria: piețe cuplate, cu o diferență de preț care se închide repede



Sursa: energy-charts.info (Fraunhofer ISE); prețurile OPCOM (RO), HUPX (HU) și EPEX SPOT (DE-LU), prin ENTSO-E. Date: prețuri zilnice de bază, 2022-01-01 - 2026-10-31.

- Diferența RO − HU: media −2,07, abaterea standard 15,08 EUR/MWh
  - Pentru România și Germania–Luxemburg: 21,06 și 37,79.
- În anul de test, prețurile din RO și HU au fost identice în 10,1% din ore
  - În restul orelor, interconexiunea a fost congestionată.

- **În practică:** folosiți prețul din Ungaria ca regresor sau ca verificare a prognozei pentru România.

(Engle & Granger, 1987, Econometrica)

EMQA_L2_coint_daily

Prețul energiei revine spre nivelul dat de gaze: model cu corecția erorii

- **Pe scurt:** Dacă prețurile energiei și gazelor sînt cointegrate, prețul energiei revine lunar spre nivelul dat de gaze, iar producția hidro îl abate temporar.

$$\Delta P_t = c + \underbrace{\alpha\,(P_{t-1} - a - \beta\,\mathrm{TTF}_{t-1})}_{\text{corecția erorii}} + \gamma\,\Delta\mathrm{TTF}_t + \delta\,H_t + \varepsilon_t$$

- **unde**
  - P_t = prețul mediu lunar al energiei electrice din România
  - TTF = prețul gazelor, în EUR/MWh
  - H_t = producția hidro minus media lunii calendaristice (TWh), staționară
  - $\alpha < 0$ = viteza de revenire spre echilibru.

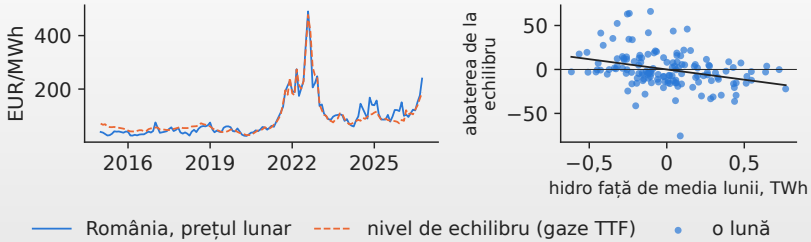
- **Pe datele din România**, 2015-01 – 2026-10
  - Engle–Granger $-5{,}64$ (valoarea critică la 5%: $-3{,}38$); rangul Johansen: 1
  - $\hat{\beta} = 1{,}95$, ca și cum prețul ar fi stabilit de o centrală pe gaze cu randament de circa 51%
- **Modelul cu corecția erorii (ECM)**
  - $\hat{\alpha} = -0{,}452$; timpul de înjumătățire: 1,2 luni
  - $\hat{\delta} = -12{,}80$ EUR/MWh pentru fiecare TWh suplimentar de producție hidro ($t = -3{,}10$)

- **În practică:** într-o lună secetoasă, un producător hidro se poate aștepta la prețuri peste nivelul dat de gaze timp de una sau două luni.

(Engle & Granger, 1987; Johansen, 1991, Econometrica)

Exercițiu practic: notebook-ul Jupyter, secțiunea 8

Prețul energiei, gazele și hidro: regresia din cursul 1 nu este spurioasă



Sursa: energy-charts.info (prețuri OPCOM; producția hidro ENTSO-E, date Transelectrica); Banca Mondială, Pink Sheet (TTF). Date: lunar, 2015-01 - 2026-10.

- În stînga, prețul lunar urmează nivelul de echilibru dat de prețul gazelor
  - În dreapta, în lunile cu producție hidro peste medie, prețul este sub acest nivel.

- **În practică:** interpretați un an hidrologic secetos ca o primă de preț peste nivelul dat de gaze, nu ca un nou nivel al prețului.

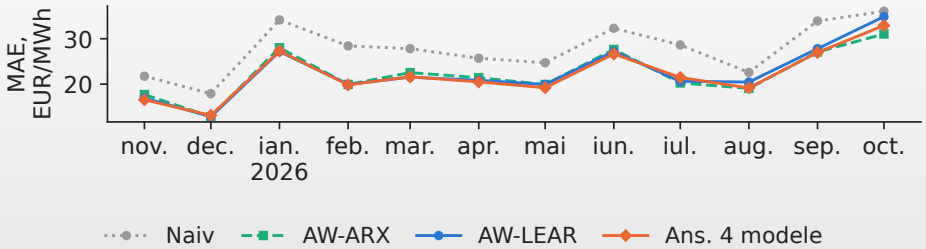
(cursul 1, studiul de caz hidro; estimare proprie)

EMQA_L2_coint_monthly

Cuprins

- Problema de prognoză și modelele de referință
- Modele expert: ARX și LEAR
- Ferestre, combinații și învățare automată
- Prognoze probabilistice și cointegrare
- Studii de caz pe date recente din România
  - (a) Un an de prognoze
  - (b) O săptămînă de criză
  - (c) Intervalul de tranzacționare de 15 minute
  - (d) Valoarea economică a prognozei
  - Cercetare și practică: conferința AIDA 2026

Studiul de caz (a): acuratețea diferă mult de la o lună la alta



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; producție și fluxuri: ENTSO-E (date Transelectrica); Yahoo Finance (SparkChange EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31.

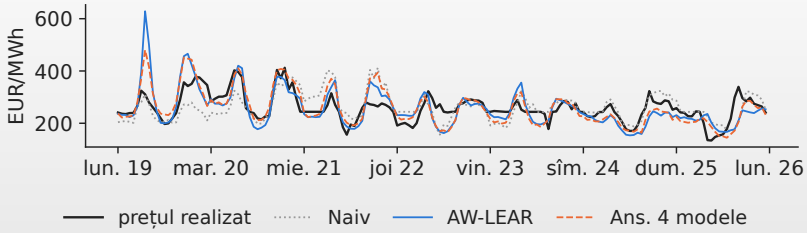
- AW-LEAR este mai precis decît modelul naiv în 12 din 12 luni
  - MAE variază între 12,84 (decembrie 2025) și 34,88 EUR/MWh (octombrie 2026).

- **În practică:** raportați acuratețea lună de lună: o MAE anuală bună poate ascunde o toamnă slabă.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L2_monthly_mae

Studiul de caz (b): în săptămîna de criză, modelele întîrzie o zi



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; producție și fluxuri: ENTSO-E (date Transelectrica); Yahoo Finance (SparkChange EUA ETC). Date: săptămîna 2026-10-19 - 2026-10-25, date orare.

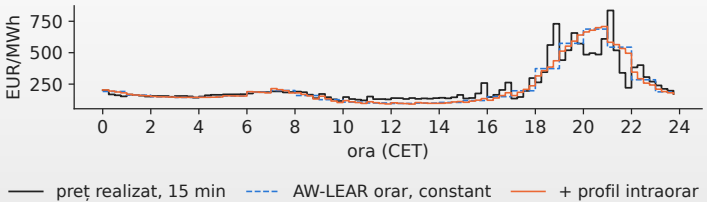
- Prețul mediu 258,59, maximul 412,35 EUR/MWh
  - MAE: modelul naiv 40,19, AW-LEAR 36,54, GBM 34,35, ansamblul 34,95.

- **În practică:** toate modelele reacționează la un salt de nivel cu o zi întîrziere
  - Acoperiți riscul orelor de seară.

(calcule proprii; OPCOM)

EMQA_L2_stress_week

Studiul de caz (c): sferturile de oră cer un profil în interiorul orei



Sursa: energy-charts.info (Fraunhofer ISE); prețuri PZU pe 15 minute (OPCOM), prin ENTSO-E. Date: 2026-07-01, 96 de sferturi de oră (CET).

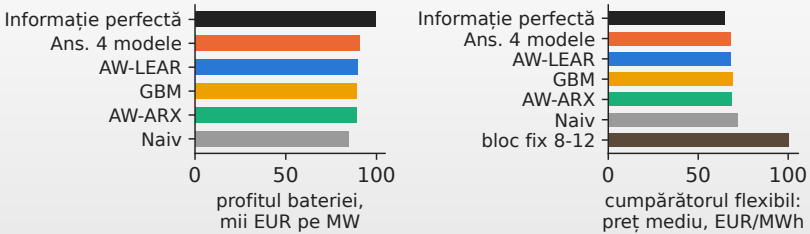
- Intervalul de tranzacționare (MTU) are 15 minute
  - Prognoza = AW-LEAR orar + profilul intraorar mediu din ultimele 28 de zile.
- MAE pe sfert de oră în 363 de zile: 26,02 constant, 24,53 EUR/MWh cu profil.

- **În practică:** o baterie licitează pe sferturi de oră
  - Folosiți profilul intraorar, nu o valoare constantă.

(calcule proprii; OPCOM; trecerea SDAC la 15 minute, 1 oct. 2025)

EMQA_L2_mtu15

Studiul de caz (d): cît valorează, în bani, o prognoză mai bună



Sursa: energy-charts.info (Fraunhofer ISE); prețuri OPCOM; producție și fluxuri: ENTSO-E (date Transelectrica); Yahoo Finance (SparkChange EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31; 1 MW / 2 MWh, randament 90%.

- Baterie de 1 MW / 2 MWh, un ciclu pe zi, 363 de zile fără schimbarea orei
  - 90 738 EUR pe MW cu ansamblul (91,0% din profitul cu informație perfectă), 84 623 cu modelul naiv.
- Consum flexibil de 4 ore: 67,87 EUR/MWh cu AW-LEAR, față de 100,59 pentru blocul fix 8–12 CET.

- **În practică:** transformați rMAE în EUR înainte de a plăti pentru o prognoză.

(calcule proprii; randament de încărcare–descărcare presupus: 90%)

EMQA_L2_battery

O prognoză se acceptă numai după o listă de verificări; testul nostru arată că nu folosim informație din viitor

- **Înainte să aveți încredere într-o testare retrospectivă**
  - Fiecare variabilă de intrare este publicată înainte de ora 12:00 CET din ziua $d - 1$
  - Standardizările, transformările, λ și pragurile se estimează numai pe fereastra de calibrare
  - Validarea este cronologică, iar anul de test este folosit o singură dată
- **Apoi raportați**
  - MAE și rMAE față de modelul naiv, valorile p ale testelor DM, acoperirea intervalelor
  - Rezultate pe luni și pe ore, nu doar o cifră anuală
- **Autoverificarea noastră** (scriptul de analiză, secțiunea 7)
  - 9 364 de verificări ale momentului publicării: fiecare variabilă este disponibilă cu cel puțin 12 h înainte de ora 12:00
  - 17 serii de prognoză recalculate în 14 zile; GBM și MLP, în prima zi a fiecăreia dintre cele 12 reestimări
  - Datele ulterioare au fost șterse sau înlocuite cu valori absurde: prognozele au rămas identice, pînă la rotunjire
  - Rezultat: verificare trecută

În practică: includeți testul de folosire a informației din viitor în orice evaluare a unui model, ca în tema 1.

(tema 1; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 10

AIDA 2026: prognozele probabilistice se judecă după banii pe care îi aduc

- **R. Weron**, 4 iunie 2026 (diapozitive)
  - Cîte un model pe oră (ca ARX și LEAR) sau un model comun pentru 24 de ore; medierea pe ferestre și LEAR rămîn reperele
- **Ce au găsit lucrările prezentate**
  - Ofertele pe cuantile au adus cu 19–34% mai mult profit decît cele pe prognoze punctuale (Uniejewski & Weron, 2021)
  - În 2025, scorul de probabilitate ordonat continuu (CRPS): 3,56 pentru transformerul TabPFN (versiunea 3), 4,71 pentru LEAR + CP
- **A. Petukhina**, cu G. Mazzon, D. Marazzina (3 iunie 2026, diapozitive)
  - Marea Britanie, în afara SDAC: două licitații orare (EPEX SPOT, Nord Pool); cumpărați într-una, vindeți în cealaltă
  - Prognoză comună a celor două prețuri și a prețului de dezechilibru (copulă); test mar. – sep. 2022
- **Ce a găsit**
  - EPEX: MAE 47,884 față de 27,926 (LASSO + QRA), dar CRPS 16,852 față de 32,605
  - Strategia medie – valoarea la risc condiționată (CVaR): 22 001 EUR, față de 6 283,3 și −3 005,1 EUR (LASSO + QRA)

În practică: judecați prognoza după decizia pe care o susține: modelul cu MAE mai mare a cîștigat mai mult.

(diapozitivele AIDA 2026; lucrări: Uniejewski & Weron, 2021, ENEECO; Agakishiev et al., 2025, ENEECO)

AIDA 2026: ordinea de merit, estimată din date, dă distribuția prețului

- **P. Ghelasi**, cu J. Browell, F. Ziel (3 iunie 2026, diapozitive)
  - Prețul = ordinea de merit (centrale ordonate după costul variabil) la nivelul consumului; model fundamental, interpretabil
  - Randamentele și intensitățile de CO_2, estimate din prețuri trecute, între limite date de experți
- **Germania, prognoze punctuale**
  - Estimare 1 oct. 2022 – 1 oct. 2023, test 1 oct. 2023 – 1 oct. 2024, fără reestimare
  - MAE, EUR/MWh: 11,83 pentru acest model; 13,11 LASSO, 13,96 gradient boosting, 16,36 ordinea de merit clasică, 24,96 naiv
- **Ordinea de merit probabilistică**
  - Distribuția prognozată a fiecărei intrări (consum, solar, vînt, combustibili); fiecare scenariu simulat trece prin ordinea de merit
  - Parametrii minimizează CRPS a prețurilor rezultate
- **Ce a găsit**
  - CRPS 13,92, față de 14,04 pentru un model cu distribuția Johnson S_U și 20,46 pentru cel naiv
  - MAE 17,28, față de 18,21 și 25,98; RMSE 25,81, față de 29,19 și 41,47
  - Prețurile simulate au distribuții neparametrice, de ex. o grupare lîngă zero la amiază

În practică: un model fundamental estimat statistic dă prognoze pe care le puteți explica centrală cu centrală.

(prezentarea lui P. Ghelasi la AIDA 2026, București, 3 iunie 2026: diapozitive; lucrare: Ghelasi & Ziel, 2026, ENEECO)

Test 1: modelul naiv pentru o zi de luni

- Este duminică, ora 11:30 CET
  - Trebuie să prognozați cu modelul naiv prețul de luni pentru ora 19:00
  - Ce preț folosiți?

Răspuns

- Prețul de luni trecută, ora 19:00 ($d - 7$)
  - În anul de test, pentru zilele de luni, sîmbătă și duminică, această regulă este mai precisă decît prețul din ziua precedentă (MAE 29,87 față de 33,48 EUR/MWh).

Test 2: o testare retrospectivă suspectă

- Un furnizor de prognoze raportează rMAE 0,55 pentru România, dar folosește ca regresor consumul realizat în ziua $d-1$
  - Cumpărați prognoza?

Răspuns

- Nu: la ora 12:00 din ziua $d-1$, consumul acelei zile nu este încă măsurat, deci testarea folosește informație din viitor
  - Cereți o nouă testare cu date pînă în ziua $d-2$ (sau cu prognozele publicate de TSO)
  - Cel mai bun rezultat corect al nostru este rMAE 0,795.

Test 3: interpretarea testului DM

- AW-LEAR sau AW-ARX? Testul DM dă $p = 0{,}797$
  - Ce model intră în producție?

Răspuns

- Niciunul nu este semnificativ mai precis
  - Alegeți modelul mai simplu sau, mai bine, media lor, care face parte din cel mai bun ansamblu (rMAE 0,795).

Test 4: o măsură a erorii pentru consiliul de administrație

- Raportul dumneavoastră indică MAPE 5 778% pentru prognoza prețului din România, iar consiliul este alarmat
  - Ce răspundeți?

Răspuns

- MAPE împarte eroarea la prețuri apropiate de zero (387 de ore sub 5 EUR/MWh produc 99,5% din valoarea ei)
  - Raportați în schimb MAE 22,53 EUR/MWh și rMAE 0,810.

Test 5: cointegrarea în practică

- Prețurile din România și Ungaria sînt cointegrate, iar un șoc asupra diferenței se înjumătățește în 0,8 zile
  - Astăzi prețul din România este cu 40 EUR/MWh mai mare decît cel din Ungaria
  - La ce vă așteptați?

Răspuns

- Diferența ar trebui să se reducă la circa jumătate în aproximativ o zi, dacă interconexiunea nu rămîne congestionată
  - Este un semnal pentru tranzacțiile transfrontaliere, nu o garanție.

Recapitulare

- Problema de prognoză și modelele de referință
  - Piața pentru ziua următoare
  - Informațiile disponibile și orizontul
  - Modele naive de referință și măsuri ale erorii
  - Testarea acurateței prognozelor
- Modele expert: ARX și LEAR
  - Modelul expert ARX
  - Transformări de stabilizare a variației
  - Autoregresia estimată cu LASSO
- Ferestre, combinații și învățare automată
  - Ferestre de calibrare
  - Combinarea prognozelor
  - Învățarea automată: introducere la cursul 7
- Prognoze probabilistice și cointegrare
  - Medierea prin regresie cuantilică
  - Cointegrarea: prețuri care evoluează împreună
- Studii de caz pe date recente din România
  - (a) Un an de prognoze
  - (b) O săptămînă de criză
  - (c) Intervalul de tranzacționare de 15 minute
  - (d) Valoarea economică a prognozei
  - Cercetare și practică: conferința AIDA 2026

- Mai întîi, un cadru corect: numai informația disponibilă la ora 12:00 CET în ziua $d-1$, ferestre glisante, modelul naiv ca reper și teste DM.
- În anul de test, cel mai bun model, ansamblul de 4 modele, reduce eroarea modelului naiv cu 20,5%
  - Cursul următor: volatilitatea (cursul 3).

Cercetările grupului nostru despre prognoza consumului și a prețurilor în România

- **Compararea modelelor de prognoză a consumului** (Proșcanu, Proșcanu, Pele & Costea, 2025, RJEF)
  - Ce a făcut lucrarea: a comparat modele sezoniere clasice și rețele neuronale pe consumul național orar al României
  - Rezultat: o rețea neuronală are o eroare net mai mică decît modelul autoregresiv sezonier (studiul de caz C2)
- **Patru generații de modele pentru prețul energiei** (Andrei, Velev, Toma, Pele & Lessmann, 2024, arXiv 2411.03372)
  - Ce a făcut lucrarea: a evaluat comparativ patru generații de metode de prognoză a prețurilor energiei
  - Utilitate: un reper pentru alegerea familiei de modele
- **Explicarea prognozelor de preț pe mai multe orizonturi** (Andrei, Pele & Cramer, 2026, PICBE)
  - Ce a făcut lucrarea: a explicat prognozele prețurilor orare din România
  - Rezultat: arată ce factori contează la fiecare orizont de prognoză și în fiecare regim de preț
- **Avertizarea timpurie a salturilor de preț** (Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE)
  - Ce a făcut lucrarea: a construit un sistem explicabil de inteligență artificială (AI) pentru piața din România
  - Rezultat: prețul anterior și consumul rezidual sînt principalii factori ai salturilor (tema cursului 7)
- Rezultatele de pe acest diapozitiv sînt cele raportate în lucrări; celelalte cifre din curs provin din calculele noastre.

(Academia de Studii Economice din București; Academia Română, Institutul de Prognoză Economică)

Lecturi și resurse suplimentare

- **R. Weron, IIF Distinguished Lectures despre prognoza prețurilor energiei electrice** (2025): prezentări partea I, partea a II-a, notebook-uri Jupyter.
- **epftoolbox**, LEAR și DNN, cu setul de date pentru evaluare publicat de Lago et al. (2021): github.com/jeslago/epftoolbox.
- **Forecasting – Principles and Practice**, ed. a 3-a, otexts.com/fpp3.
- **Acest curs**: cod, date, notebook-uri Jupyter — github.com/danpele/EMQA.
- **Tema 1** aplică ARX, LEAR, DM și intervalele HS/CP pe propria fereastră de test.
- **Exerciții practic**: notebook-ul Jupyter reproduce toate graficele și cifrele din acest curs — notebooks/.

Bibliografie (1/4)

- Andrei, A.-V., Pele, D.-T. & Cramer, A.-A. (2026). Multi-horizon explainability in energy price forecasting: Disentangling market dynamics and renewable intermittency in Romania's liberalized electricity market. *Proceedings of the International Conference on Business Excellence*, 20(1), 104–117. doi:10.2478/picbe-2026-0014
- Andrei, A.-V., Pele, D.-T., Cramer, A.-A., Amza, A. & Diaconu, D. (2026). Explainable AI-based early warning system for electricity price spikes: Evidence from the Romanian market. *Proceedings of the International Conference on Business Excellence*, 20(1), 4820–4836. doi:10.2478/picbe-2026-0352
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2024). Energy price modelling: A comparative evaluation of four generations of forecasting methods. arXiv:2411.03372. arxiv.org/abs/2411.03372
- Agakishiev, I., Härdle, W. K., Kopa, M., Kozmík, K. & Petukhina, A. (2025). Multivariate probabilistic forecasting of electricity prices with trading applications. *Energy Economics*, 141, 108008. doi:10.1016/j.eneco.2024.108008
- Bates, J. M. & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468. doi:10.1057/jors.1969.103
- Diebold, F. X. & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Engle, R. F. & Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica*, 55(2), 251–276. doi:10.2307/1913236
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- Ghelasi, P., Browell, J. & Ziel, F. (2026). A probabilistic merit order for electricity price forecasting. AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026

Bibliografie (2/4)

- Ghelasi, P. & Ziel, F. (2026). A data-driven merit order: Learning a fundamental electricity price model. *Energy Economics*, 154, 109114. doi:10.1016/j.eneco.2025.109114
- Gneiting, T. & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437
- Hubicka, K., Marcjasz, G. & Weron, R. (2019). A note on averaging day-ahead electricity price forecasts across calibration windows. *IEEE Transactions on Sustainable Energy*, 10(1), 321–323. doi:10.1109/TSTE.2018.2869557
- Hyndman, R. J. & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- Johansen, S. (1991). Estimation and hypothesis testing of cointegration vectors in Gaussian vector autoregressive models. *Econometrica*, 59(6), 1551–1580. doi:10.2307/2938278
- Koenker, R. & Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50. doi:10.2307/1913643
- Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- Lago, J., Marcjasz, G., De Schutter, B. & Weron, R. (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293, 116983. doi:10.1016/j.apenergy.2021.116983
- NEMO Committee (2025). 15-Minute MTU in SDAC was implemented. SDAC press release, 1 October 2025. nemo-committee.eu

Bibliografie (3/4)

- NEMO Committee (2026). Single Day-Ahead Coupling (SDAC) and the EUPHEMIA algorithm. nemo-committee.eu/sdac
- MacKinnon, J. G. (1996). Numerical distribution functions for unit root and cointegration tests. *Journal of Applied Econometrics*, 11(6), 601–618. doi:10.1002/(SICI)1099-1255(199611)11:6<601::AID-JAE417>3.0.CO;2-T
- Marcjasz, G., Serafin, T. & Weron, R. (2018). Selection of calibration windows for day-ahead electricity price forecasting. *Energies*, 11(9), 2364. doi:10.3390/en11092364
- Mazzon, G., Petukhina, A. & Marazzina, D. (2026). Multivariate probabilistic day-ahead electricity price forecasting and cross-auction trading in the UK market. AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026
- Nogales, F. J., Contreras, J., Conejo, A. J. & Espínola, R. (2002). Forecasting next-day electricity prices by time series models. *IEEE Transactions on Power Systems*, 17(2), 342–348. doi:10.1109/TPWRS.2002.1007902
- Nowotarski, J. & Weron, R. (2015). Computing electricity spot price prediction intervals using quantile regression and forecast averaging. *Computational Statistics*, 30(3), 791–803. doi:10.1007/s00180-014-0523-0
- Nowotarski, J. & Weron, R. (2018). Recent advances in electricity price forecasting: A review of probabilistic forecasting. *Renewable and Sustainable Energy Reviews*, 81, 1548–1568. doi:10.1016/j.rser.2017.05.234
- Proșcanu, C. A., Proșcanu, M. E., Pele, D. T. & Costea, A. (2025). Watt's next? Benchmarking time series models on Romania's national electricity consumption. *Romanian Journal of Economic Forecasting*, 28(3), 146–163. RePEc.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288. doi:10.1111/j.2517-6161.1996.tb02080.x

Bibliografie (4/4)

- Uniejewski, B., Nowotarski, J. & Weron, R. (2016). Automated variable selection and shrinkage for day-ahead electricity price forecasting. *Energies*, 9(8), 621. doi:10.3390/en9080621
- Uniejewski, B., Weron, R. & Ziel, F. (2018). Variance stabilizing transformations for electricity spot price forecasting. *IEEE Transactions on Power Systems*, 33(2), 2219–2229. doi:10.1109/TPWRS.2017.2734563
- Uniejewski, B. & Weron, R. (2021). Regularized quantile regression averaging for probabilistic electricity price forecasting. *Energy Economics*, 95, 105121. doi:10.1016/j.eneco.2021.105121
- Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030–1081. doi:10.1016/j.ijforecast.2014.08.008
- Weron, R. (2026). Machine learning for electricity price forecasting. Keynote, AIDA Conference, Bucharest University of Economic Studies, 4 June 2026. github.com/danpele/EMQA/resources/aida2026
- Ziel, F. & Weron, R. (2018). Day-ahead electricity price forecasting with high-dimensional structures: Univariate vs. multivariate modeling frameworks. *Energy Economics*, 70, 396–420. doi:10.1016/j.eneco.2017.12.016

Anexa A: modelul LEAR în detaliu

$$\mathrm{AIC}(\lambda) = n \ln \frac{\mathrm{RSS}(\lambda)}{n} + 2\,\mathrm{df}(\lambda)$$

- Suma pătratelor reziduurilor (RSS)
  - $\mathrm{Df}(\lambda)$ = gradele de libertate = numărul coeficienților nenuli
  - Traiectoria de regularizare se calculează cu algoritmul least angle regression (LARS), în scikit-learn.
- Blocul prețurilor: m și s = mediana și 1,4826·MAD ale prețurilor din zilele $d-T-7, \ldots, d-1$, calculate pe toate cele 24 de ore împreună.
- Consumul și producția eoliană și solară: transformare asinh proprie, cu date pînă în ziua $d-2$
  - Apoi fiecare coloană este standardizată pe zilele de calibrare.

(Uniejewski, Nowotarski & Weron, 2016, Energies; Lago et al., 2021, APEN)

Bloc	Coloane
prețuri $d-1$, toate cele 24 de ore	24
prețuri $d-2$, $d-3$, $d-7$	72
consum $d-2$, $d-3$, $d-7$	72
eolian + solar $d-2$, $d-3$, $d-7$	72
ziua săptămînii	7
total	**247**

Anexa B: MAE pe trimestre în anul de test

Model	2025 T4	2026 T1	2026 T2	2026 T3	2026 T4
naiv	19,80	30,19	27,55	28,32	36,05
AW-ARX	15,24	23,62	22,97	22,09	31,05
AW-LEAR	14,86	22,99	22,64	22,91	34,88
GBM	16,25	24,71	22,98	24,97	37,88
MLP	17,27	25,49	24,89	26,30	41,58
ansamblul de 4 modele	14,82	23,02	22,09	22,50	32,91

- Zile pe trimestru: 61, 90, 91, 92, 31 (anul de test începe la 1 noiembrie 2025).
- Verde = cel mai bun în trimestrul respectiv, roșu = cel mai slab.

(Weron, 2014, IJF; Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

Anexa C: scoruri probabilistice și testul Kupiec

$$\mathrm{LR}_{\mathrm{UC}} = -2\ln\frac{(1-p_0)^{n-x}p_0^{\,x}}{(1-\hat{p})^{n-x}\hat{p}^{\,x}} \sim \chi^2_1, \quad \hat{p} = \frac{x}{n}$$

- Raportul de verosimilitate (LR) pentru acoperirea necondiționată (UC)
  - x = orele din afara intervalului de 90%, din n = 8 760
  - $p_0 = 0{,}10$.
- Orele aceleiași zile nu sînt independente, deci testul este orientativ
  - Testul pe proporția zilnică a depășirilor, cu variantă Newey–West, dă $p = <0{,}001$ pentru QRA.
- Scorul pinball mediat pe 99 de cuantile
  - Scorul de probabilitate ordonat continuu $\approx 2\times$ acest scor.

(Kupiec, 1995; Gneiting & Raftery, 2007, JASA)

Metoda	Pinball	Acop. 50%	Acop. 90%	Kupiec
QRA	8,33	47,3	85,7	162,9
CP	8,47	46,5	87,0	83,3
HS	8,41	45,8	85,8	154,1

Anexa D: testele de rădăcină unitară și de cointegrare, în detaliu

Serie / pereche	Test	Statistica	p / crit. 5%
RO, HU, DE-LU, niveluri zilnice	ADF p	–	0,064, 0,052, 0,015
RO–HU	Engle–Granger	$-10{,}58$	$-3{,}34$
RO–HU	Johansen $r = 0$ / $r \leq 1$	139,7 / 6,21	15,49 / 3,84
RO–DE-LU	Engle–Granger	$-5{,}79$	$-3{,}34$
preț RO, TTF, niveluri lunare	ADF p	–	0,295, 0,249
hidro minus media lunii	ADF p	–	0,002
preț–TTF	Engle–Granger	$-5{,}64$	$-3{,}38$
preț–TTF–hidro	Engle–Granger	$-5{,}95$	$-3{,}80$
preț–TTF	Johansen $r = 0$ / $r \leq 1$	21,32 / 3,74	15,49 / 3,84

- ADF cu numărul de decalaje ales prin AIC; Johansen cu constantă și 6 diferențe decalate (date zilnice) sau 2 (date lunare).
- ECM cu erori standard robuste la heteroscedasticitate și autocorelație (6 decalaje), 141 de luni, $R^2 = 0{,}778$.

(Engle & Granger, 1987; Johansen, 1991; MacKinnon, 1996)