

Analiza cantitativă a piețelor de energie

Cursul 7: Învățarea automată pe piețele de energie

Prof. dr. Daniel Traian PELE

Academia de Studii Economice din București, Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

Obiectivele cursului

- Organizarea corectă a unui experiment de învățare automată (ML)
  - Eșantioanele de antrenare, de validare și de test se succed în timp
  - Prognoza folosește numai informația cunoscută la ora 12:00 a Europei Centrale (CET) în ziua dinaintea livrării
- Construirea și calibrarea a două modele pentru cele 24 de prețuri orare ale zilei următoare
  - O rețea neuronală profundă (DNN)
  - Un ansamblu de arbori de decizie construiți secvențial (gradient boosting)
  - În plus, un model fundațional preantrenat
- Compararea cu modelele de referință din cursul 2, pe același an de test
  - Eroarea absolută medie (MAE), rădăcina erorii pătratice medii (RMSE), MAE relativă (rMAE) și testul Diebold–Mariano (DM)
  - Combinarea modelelor de învățare automată cu modelele statistice
- Explicarea prognozelor, anticiparea vîrfurilor de preț și a prețurilor negative
  - Capcanele care fac un model să pară mai bun decît este

Abrevieri (1/2)

AI	inteligență artificială
ARX	model autoregresiv cu variabile exogene
AUC	aria de sub curba ROC
AW	medierea prognozelor obținute pe mai multe ferestre de calibrare
AW-ARX	ARX mediat pe ferestre de calibrare
AW-LEAR	LEAR mediat pe ferestre de calibrare
CET	ora Europei Centrale
CPU	unitatea centrală de procesare (nucleu de procesor)
DM	testul Diebold–Mariano
DNN	rețea neuronală profundă
DST	ora de vară
ENTSO-E	Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică
ETC	titlu tranzacționat la bursă, garantat cu mărfuri (exchange-traded commodity)
EUA	certificat de emisii al UE (1 t CO_2)
EUR	euro
GBM	gradient boosting (ansamblu de arbori de decizie construiți secvențial)
GW	gigawatt
ISE	Institutul Fraunhofer pentru Sisteme de Energie Solară
LASSO	operatorul de contracție și selecție în normă absolută

Abrevieri (2/2)

LEAR	autoregresie estimată cu LASSO
MAD	abaterea absolută mediană
MAE	eroarea absolută medie
ML	învățare automată
MLP	perceptron multistrat (rețea neuronală directă)
MW	megawatt
MWh	megawatt-oră
OPCOM	operatorul pieței de energie electrică și de gaze naturale din România
PZU	piața pentru ziua următoare
ReLU	unitate liniară rectificată (rectified linear unit)
RES	surse regenerabile de energie (aici: eolian + solar)
rMAE	MAE relativă (MAE a modelului / MAE a modelului naiv)
RMSE	rădăcina erorii pătratice medii
RO	România (zonă de ofertare)
ROC	caracteristica de operare a receptorului (receiver operating characteristic)
SHAP	explicații aditive bazate pe valorile Shapley (SHapley Additive exPlanations)
TSO	operator de transport și de sistem
UE	Uniunea Europeană
XGBoost	eXtreme Gradient Boosting (bibliotecă de programe)

Aceleași date și același an de test ca în cursul 2, plus un an de validare

Element	Alegerea din acest curs
Variabila prognozată	prețul orar de pe piața pentru ziua următoare (PZU) din România (RO), administrată de operatorul pieței de energie electrică și de gaze naturale (OPCOM)
Variabile explicative (ca în cursul 2)	prețurile pînă în ziua $d-1$; consumul, producția eoliană și solară, hidro, nucleară și importul net pînă în ziua $d-2$, de la Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică (ENTSO-E); prețul certificatelor de emisii (EUA) ale Uniunii Europene (UE), printr-un titlu tranzacționat la bursă (ETC)
Antrenare	de la 8 ianuarie 2022; crește cu o lună la fiecare reestimare
Anul de validare	1 noiembrie 2024 – 31 octombrie 2025: folosit numai pentru alegerea setărilor modelelor
Anul de test	1 noiembrie 2025 – 31 octombrie 2026, 8 760 de ore, modele reestimate lunar

- **Date pînă la 31 octombrie 2026**
  - Descărcate la 4 noiembrie 2026 de pe energy-charts.info (Fraunhofer ISE) și Yahoo Finance
- **Modelele de referință**: prognozele din cursul 2, preluate din fișierele acestuia
  - Modelul naiv; modelul autoregresiv cu variabile exogene (ARX); operatorul de contracție și selecție în normă absolută (LASSO)
  - Autoregresia estimată cu LASSO (LEAR); ARX mediat pe mai multe ferestre de calibrare (AW-ARX), LEAR la fel (AW-LEAR); ansamblul de 4 modele

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Învățarea automată cîștigă flexibilitate, dar plătește prin varianță

- **Pe scurt:** Un model flexibil poate învăța praguri și interacțiuni pe care LEAR nu le vede, dar poate învăța și zgomotul din anii de antrenare.

$$\hat{\theta} = \arg\min_{\theta} \underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell\big(Y_i, f_\theta(\mathbf{x}_i)\big)}_{\text{potrivirea pe zilele de antrenare}} + \underbrace{\lambda\,\Omega(\theta)}_{\text{penalizare}}$$

- **unde**
  - f_θ = modelul, cu parametrii θ
  - $\mathbf{x}_i$ = variabilele cunoscute la închiderea licitației
  - Y_i = prețul
  - ℓ = funcția de pierdere, aici eroarea absolută
  - Ω = complexitatea modelului, iar λ = ponderea ei.

- **Cît de flexibile sînt modelele noastre?**
  - LEAR: cel mult 247 de coeficienți pentru fiecare oră
  - Rețeaua DNN: 141 336 de parametri, pentru 1 727 de zile de antrenare la ultima reestimare

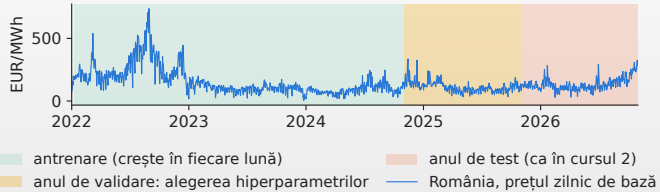
- **Consecința**
  - Eroarea pe datele de antrenare nu spune nimic despre viitor; modelul poate fi judecat numai pe date pe care nu le-a văzut

- **În practică:** întrebați furnizorul de prognoze cîți parametri are modelul pentru fiecare zi de istoric și pe ce zile a fost măsurată eroarea.

(Hastie, Tibshirani & Friedman, 2009; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Trei eșantioane în ordine cronologică: antrenare, validare, test



Sursa: energy-charts.info (Fraunhofer ISE): prețurile PZU ale OPCOM pentru România. Date: preț zilnic de bază, 2022-01-01 - 2026-10-31, zile de livrare CET.

- **Anul de validare**: se compară 25 de setări pentru fiecare model, reestimate la fiecare 3 luni
  - Setarea cu cea mai mică MAE este fixată înainte de începutul anului de test
- **Anul de test**: modelele sînt reestimate la începutul fiecărei luni, pe toate zilele anterioare
  - Nu se folosește pentru nicio alegere; este același an ca în cursul 2, deci erorile se pot compara direct

- **În practică:** tratați anul de test ca pe un plic sigilat: se deschide o singură dată, după ce toate alegerile au fost făcute.

(Bergmeir & Benítez, 2012, Inf. Sci.; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Hiperparametrii se aleg prin căutare aleatoare pe anul de validare

- **Pe scurt:** Setări precum numărul de neuroni sau de arbori nu sînt estimate de model; încercăm mai multe și o păstrăm pe cea care prognozează cel mai bine zilele nevăzute.

$$\gamma^* = \arg \min_{\gamma \in \{\gamma_0, \ldots, \gamma_{24}\}} \frac{1}{24\,|\mathcal{V}|} \sum_{d \in \mathcal{V}} \sum_{h=0}^{23} \left| P_{d,h} - \hat{P}_{d,h}(\gamma) \right|$$

- **unde**
  - γ = o setare (vectorul hiperparametrilor)
  - γ_0 = setarea din cursul 2, celelalte extrase aleator
  - $\mathcal{V}$ = zilele anului de validare
  - $\hat{P}_{d,h}(\gamma)$ = prognoza cu setarea γ.

- **De ce aleator și nu pe o grilă completă**
  - Doar cîteva setări contează cu adevărat; extragerile aleatoare le acoperă mai bine, cu același număr de încercări
- **Bugetul nostru**
  - 24 de setări aleatoare și setarea din cursul 2, pentru fiecare dintre cele două modele
  - 7,3 minute pe un nucleu al unității centrale de procesare (CPU)

- **În practică:** o căutare modestă, dar documentată, este suficientă
  - O căutare fără un eșantion de validare separat nu este o căutare, ci o scurgere de informație.

(Bergstra & Bengio, 2012, JMLR)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

O rețea neuronală înlănțuie regresii, fiecare urmată de o funcție neliniară

- **Pe scurt:** Fiecare neuron transformă neliniar o combinație liniară a intrărilor; stratul de ieșire dă deodată cele 24 de prețuri ale zilei d.

$$\mathbf{z} = \phi\big(W_1 \mathbf{x}_d + \mathbf{b}_1\big), \qquad \hat{\mathbf{Y}}_d = W_2\,\mathbf{z} + \mathbf{b}_2 \in \mathbb{R}^{24}$$
$$\phi(u) = \max(0, u) \quad \text{sau} \quad \phi(u) = \ln(1 + e^u)$$

- **unde**
  - $\mathbf{x}_d$ = intrările zilei d (prețuri, consum, eolian și solar, variabile fundamentale, ziua săptămînii)
  - W_1, W_2 = ponderi, $\mathbf{b}_1, \mathbf{b}_2$ = termeni liberi
  - ϕ = unitatea liniară rectificată (ReLU) sau varianta netedă (softplus)
  - $\hat{\mathbf{Y}}_d$ = prețurile transformate cu asinh (cursul 2).

- **Rețeaua noastră** (aleasă pe anul de validare)
  - 251 de intrări, un strat ascuns de 512 de neuroni, funcția softplus, 24 de ieșiri
  - 141 336 de parametri; rețelele cu două straturi au fost mai slabe la validare
- **Mai bună decît în cursul 2**
  - Perceptronul multistrat (MLP): MAE 25,54; rețeaua de acum: 22,95 EUR/MWh

- **În practică:** o rețea neuronală este o regresie cu mult mai mulți coeficienți: are nevoie de aceeași disciplină a datelor, nu de mai puțină.

(Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Antrenarea: pași mici împotriva erorii, opriți la timp

- **Pe scurt:** Ponderile se modifică puțin, în direcția care reduce eroarea pe un grup aleator de zile; ne oprim cînd eroarea pe zilele mai recente nu mai scade.

$$\mathcal{L}(\theta) = \frac{1}{24\,|B|} \sum_{d \in B} \sum_{h=0}^{23} \left| Y_{d,h} - \hat{Y}_{d,h}(\theta) \right|$$

$$\theta \leftarrow \theta - \eta\, \widehat{\nabla \mathcal{L}}$$

- **unde**
  - B = un grup de 64 de zile (mini-batch)
  - η = rata de învățare ($3 \cdot 10^{-4}$)
  - $\widehat{\nabla \mathcal{L}}$ = gradientul, rescalat prin metoda Adam
  - O epocă = o parcurgere a tuturor zilelor de antrenare.

- **Oprirea timpurie (early stopping)**
  - Antrenare pe primele 85% din zile, urmărirea erorii pe ultimele 15%
  - Se păstrează epoca cea mai bună, apoi rețeaua se reestimează pe toate zilele, cu același număr de epoci

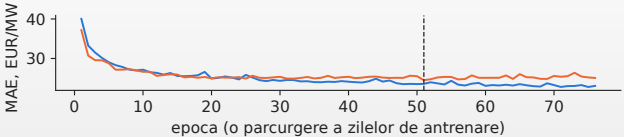
- **Pe datele noastre**
  - Epocile păstrate: mediana 56, între 23 și 92 (12 reestimări × 4 inițializări)
  - Dropout: în timpul antrenării, fiecare neuron este dezactivat aleator, cu probabilitatea 0,1

- **În practică:** regula de oprire folosește numai zile din trecut: face parte din model și se verifică la fel ca restul.

(Kingma & Ba, 2015, ICLR; Srivastava et al., 2014, JMLR)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Oprirea timpurie: ne oprim cînd eroarea pe zilele recente nu mai scade



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: rețeaua DNN aleasă, reestimarea pentru 2026-10, inițializarea 1.

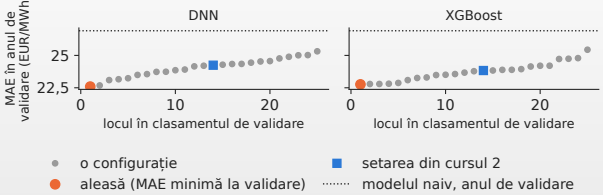
- Reestimarea pentru octombrie 2026: eroarea pe ultimele 15% din zile este minimă la epoca 51 (24,50 EUR/MWh)
  - Antrenarea se oprește la epoca 76
- După acest punct, rețeaua reproduce tot mai bine trecutul și tot mai slab zilele recente
  - Începe să memoreze

- **În practică:** dacă un furnizor nu vă poate arăta această curbă, rețeaua a fost probabil antrenată pînă a reprodus trecutul.

(calcule proprii; rețeaua DNN aleasă, inițializarea 1)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Căutarea aleatoare reduce eroarea de validare a ambelor modele



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de validare 2024-11-01 - 2025-10-31; 25 de configurații pe model, reestimare trimestrială.

- **DNN**: cea mai bună setare are MAE 22,59 EUR/MWh; setarea din cursul 2, 24,24, locul 14 din 25
  - **eXtreme Gradient Boosting (XGBoost)**: 22,76 față de 23,83 (locul 14)
- Toate cele 25 de setări ale ambelor modele sînt mai precise decît modelul naiv în anul de validare (26,90 EUR/MWh)

- **În practică:** prevedeți un an de validare pentru calibrare înainte de a avea încredere într-o prognoză de învățare automată.

(calcule proprii; anul de validare 1 noiembrie 2024 – 31 octombrie 2025)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Un arbore de regresie împarte intrările în căsuțe, cu cîte un preț fiecare

- **Pe scurt:** Un arbore pune întrebări cu răspuns da/nu; fiecare frunză finală conține o valoare, deci pragurile și interacțiunile apar de la sine.

$$f(\mathbf{x}) = \sum_{j=1}^{J} w_j \mathbb{1}\{\mathbf{x} \in R_j\}$$

$$\text{Gain} = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma$$

- **unde**
  - R_j = frunza j, w_j = valoarea ei
  - G, H = sumele derivatelor de ordinul 1 și 2 ale pierderii, la stînga (L) și la dreapta (R)
  - λ, γ = penalizări
  - Se alege împărțirea cu cel mai mare cîștig.

- **Pe datele noastre** (reestimarea pentru octombrie 2026)
  - Primul arbore întreabă: prețul din $d-1$, aceeași oră, este sub 119,5 EUR/MWh?
  - 233 de frunze; modelul adună 1 500 de arbori

- **În practică:** un arbore gîndește ca un trader: dacă ieri prețul a trecut de un prag, diseară urmează o primă.

(Chen & Guestrin, 2016, KDD; Hastie et al., 2009)

Exercițiu practic: notebook-ul Jupyter, secțiunea 3

Gradient boosting: fiecare arbore nou corectează erorile rămase

- **Pe scurt:** Potrivim un arbore mic pe ceea ce este încă greșit, îl adăugăm cu o pondere mică și repetăm de o mie de ori.

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, f_m(\mathbf{x}), \qquad w_j^* = -\frac{G_j}{H_j + \lambda}$$

$$\min \sum_i \ell\big(Y_i, F_M(\mathbf{x}_i)\big) + \sum_m \Big(\gamma J_m + \tfrac{\lambda}{2} \sum_j w_{mj}^2\Big)$$

- **unde**
  - F_m = prognoza după m arbori
  - f_m = arborele m, cu J_m frunze
  - η = rata de învățare
  - w_j^* = valoarea optimă a frunzei j (anexa B)
  - ℓ = eroarea absolută.

- **Setarea aleasă pe anul de validare**
  - 1 500 de arbori de adîncime 8, $\eta = 0{,}02$, fiecare pe o fracțiune 0,8 din rînduri
- **Anul de test**
  - MAE 23,26 EUR/MWh; modelul gradient boosting (GBM) necalibrat din cursul 2: 24,05 (DM: $p < 0{,}001$)
  - AW-LEAR (22,53) rămîne mai precis (DM: $p = 0{,}016$)

- **În practică:** calibrarea contează mai mult decît programul: același tip de arbori a cîștigat aproape un euro pe MWh prin setări bune.

(Friedman, 2001, Ann. Stat.; Chen & Guestrin, 2016, KDD)

Exercițiu practic: notebook-ul Jupyter, secțiunea 3

Modelele fundaționale prognozează prețurile fără nicio antrenare

- **Pe scurt:** Modelele Chronos au fost antrenate de Amazon pe colecții mari de serii de timp; noi le dăm doar prețurile recente și le cerem următoarele 24 de ore (fără reantrenare, zero-shot).

$$\left(\hat{q}^{\tau}_{d,h}\right)^{\tau=0{,}1;\,0{,}5;\,0{,}9}_{h=0,\ldots,23} = g\left(P_{t-2047},\ldots,P_t\right)$$

- **unde**
  - $P_{t-2047},\ldots,P_t$ = ultimele 2048 de prețuri orare, pînă la sfîrșitul zilei $d-1$ (85 de zile)
  - g = rețeaua preantrenată, folosită ca atare
  - $\hat{q}^{\tau}$ = cuantilele prognozate
  - Prognoza punctuală este mediana $\hat{q}^{0,5}$.

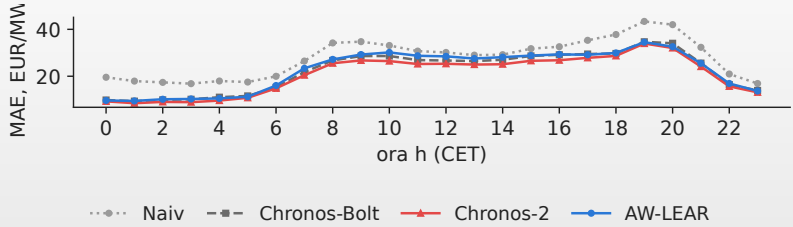
- **Anul de test**, numai cu prețuri, fără variabile fundamentale
  - Chronos-2: MAE 20,82; Chronos-Bolt: 22,15; AW-LEAR: 22,53 EUR/MWh
  - Chronos-2 este mai precis decît AW-LEAR: DM, $p < 0{,}001$; în toate cele 24 de ore
- **Robustețe**
  - În anul de validare: Chronos-2 21,05, cea mai bună rețea DNN calibrată 22,59
  - Publicat în octombrie 2025, înaintea anului de test

- **În practică:** testați un model fundațional înainte de a construi propria rețea: costă puțin, iar aici a fost cel mai precis model individual.

(Ansari et al., 2024, TMLR; Ansari et al., 2025, arXiv)

Exercițiu practic: notebook-ul Jupyter, secțiunea 4

Chronos-2 este mai precis decît AW-LEAR în fiecare oră a zilei



Sursa: energy-charts.info (Fraunhofer ISE): prețurile PZU ale OPCOM pentru România. Date: anul de test 2025-11-01 - 2026-10-31; fără reantrenare, context = ultimele 2048 de prețuri orare.

- Chronos-Bolt, mai mic și mai vechi, este la egalitate cu AW-LEAR (DM: $p = 0{,}220$)
- Intervalul 10%–90% al modelului Chronos-2 conține 76,5% din prețuri, nu 80%: este prea îngust

- **În practică:** folosiți mediana
  - Recalibrați intervalele (cursul 2) înainte de a dimensiona riscul cu ele.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 4

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Clasamentul: Chronos-2 este cel mai bun model individual

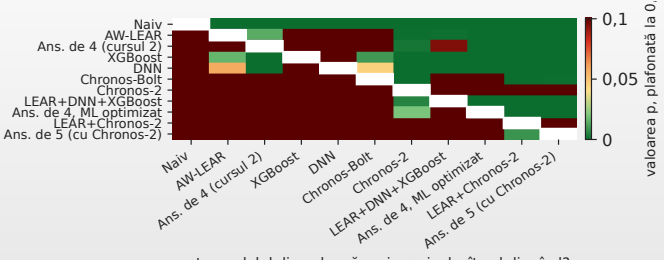
Model	MAE	RMSE	rMAE	față de AW-LEAR, %	DM, p
Naiv	27,82	44,54	1,000	−23,5	–
AW-ARX	22,30	36,34	0,802	+1,0	0,203
AW-LEAR	22,53	36,35	0,810	+0,0	–
Ansamblul de 4 (cursul 2)	22,13	35,76	0,795	+1,8	0,014
GBM (cursul 2)	24,05	37,73	0,864	−6,7	1,000
MLP (cursul 2)	25,54	40,05	0,918	−13,3	1,000
XGBoost, calibrat	23,26	36,94	0,836	−3,2	0,984
DNN, calibrată	22,95	36,42	0,825	−1,8	0,944
Chronos-Bolt, fără antrenare	22,15	35,65	0,796	+1,7	0,220
Chronos-2, fără antrenare	20,82	34,32	0,748	+7,6	<0,001
AW-LEAR + DNN + XGBoost	21,97	35,42	0,790	+2,5	0,001
AW-ARX + AW-LEAR + DNN + XGBoost	21,69	35,25	0,779	+3,8	<0,001
AW-LEAR + Chronos-2	20,81	34,11	0,748	+7,6	–
Ansamblul de 5 (cu Chronos-2)	21,12	34,50	0,759	+6,3	<0,001

- Rădăcina erorii pătratice medii (RMSE); MAE relativă (rMAE) = MAE / MAE a modelului naiv; verde = mai precis, pe fiecare coloană.
- DM, p: test unilateral că modelul este mai precis decît AW-LEAR (eroarea absolută medie zilnică, variantă Newey–West, ca în cursul 2).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Testele DM: combinațiile cu ML depășesc semnificativ AW-LEAR



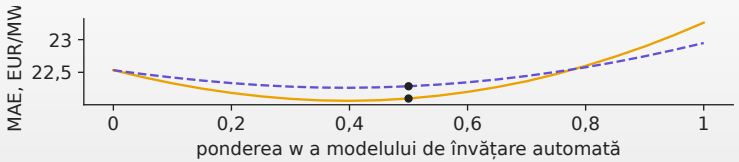
Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31, 365 de zile; valori p unilaterale.

- AW-LEAR + DNN + XGBoost este mai precis decît AW-LEAR ($p = 0{,}001$)
  - Cu AW-ARX adăugat, MAE scade la 21,69, sub ansamblul din cursul 2 ($p < 0{,}001$)
- Adăugarea AW-LEAR la Chronos-2 nu schimbă nimic ($p = 0{,}491$): în zilele dificile, cele două modele greșesc asemănător

(calcule proprii; teste DM unilaterale)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Media funcționează pentru că erorile nu sînt identice



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31; ilustrare, ponderea nu se alege pe anul de test.

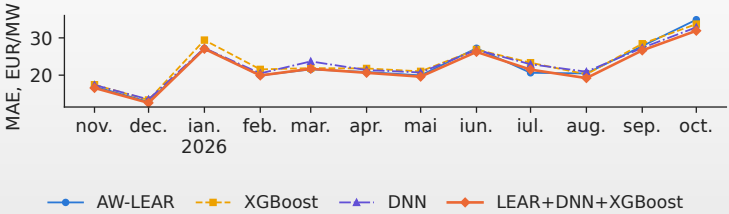
- Var $\left(\frac{e_1+e_2}{2}\right) = \frac{1}{4}(\sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$: dacă $\rho < 1$, media greșește mai puțin (e = eroarea, σ = abaterea ei standard, ρ = corelația)
- Corelația erorilor cu AW-LEAR: 0,94 (DNN), 0,89 (XGBoost)
  - Ponderile egale sînt aproape la fel de bune ca ponderea optimă văzută ulterior (0,40)

- **În practică:** faceți media cu ponderi egale înainte de a estima ponderi „inteligente”.

(Bates & Granger, 1969; calcule proprii)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Lunar, combinația este mai precisă decît AW-LEAR în 10 din 12 luni



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31.

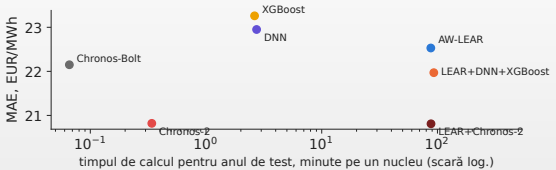
- Luate separat, XGBoost și DNN depășesc AW-LEAR fiecare doar în 3 luni
  - În medie cu acesta, în 10 luni
- Toate modelele greșesc mai mult în aceleași luni (ianuarie, iunie, octombrie): zilele dificile sînt dificile pentru toate

- **În practică:** raportați comitetului de risc acuratețea lună de lună, nu doar media anuală.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Costul de calcul: LEAR zilnic este cel mai scump, ML costă minute



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31; timp măsurat pe un nucleu al calculatorului autorului.

- Anul de test, pe un nucleu: AW-LEAR 87,6 min (365 de zile $\times$ 3 ferestre $\times$ 24 de ore)
  - XGBoost 2,6
  - DNN 2,7
  - Chronos-2 0,3
- Costuri ascunse: căutarea setărilor (7,3 min), preantrenarea Chronos (făcută de alții), oamenii care întrețin fluxul de date

- **În practică:** comparați modelele după eroare raportată la costul total de utilizare, nu doar după eroare.

(calcule proprii; timpi măsurați pe un nucleu al unui laptop cu 18 nuclee)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Valorile Shapley descompun fiecare prognoză în contribuțiile variabilelor

- **Pe scurt:** Contribuția unei variabile este efectul ei mediu atunci cînd este adăugată în model, calculat pe toate ordinile posibile de adăugare a variabilelor.

$$\phi_j = \sum_{S \not\ni j} \frac{|S|!\,(p-|S|-1)!}{p!} \Big[v(S \cup \{j\}) - v(S) \Big]$$

$$\hat{f}(\mathbf{x}) = \phi_0 + \sum_j \phi_j$$

- **unde**
  - ϕ_j = valoarea variabilei j după metoda explicațiilor aditive bazate pe valorile Shapley (SHAP)
  - S = o submulțime a celorlalte variabile
  - $v(S)$ = prognoza așteptată cînd se cunoaște doar S
  - ϕ_0 = prognoza medie
  - $p = 20$ de variabile.

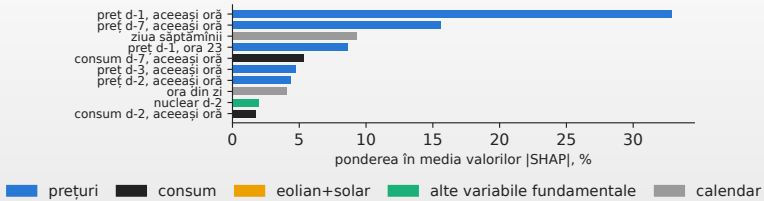
- **De ce valorile Shapley**
  - Singura împărțire echitabilă în sensul teoriei jocurilor; se adună exact la prognoză
- **Pe datele noastre**
  - XGBoost, 8 760 de ore de test; cea mai mare diferență dintre $\hat{f}$ și $\phi_0 + \sum \phi_j$: 0,000009
  - Prețurile din zilele anterioare au 69,3% din contribuția totală

- **În practică:** cereți explicația fiecărei alerte, nu doar un clasament global.

(Shapley, 1953; Lundberg et al., 2020, Nat. Mach. Intell.)

Exercițiu practic: notebook-ul Jupyter, secțiunea 6

Ce determină prognoza arborilor: prețul de ieri, la aceeași oră



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore; XGBoost reestimat lunar.

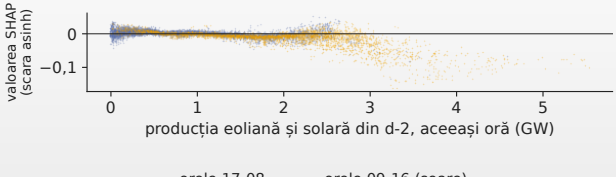
- Primele variabile: prețul din $d-1$, aceeași oră (32,9%), prețul din $d-7$, aceeași oră (15,6%), ziua săptămînii (9,3%) din media $|\phi|$
- Consumul are 8,5%, iar producția eoliană și solară 2,5%: fiind cunoscute doar pînă în $d-2$, sînt informații vechi la închiderea licitației

- **În practică:** cumpărați întîi intrări mai bune: prognozele operatorului de transport și de sistem (TSO).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exerciții practic: notebook-ul Jupyter, secțiunea 6

Producția eoliană și solară scade prețul doar în orele în care este mare



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

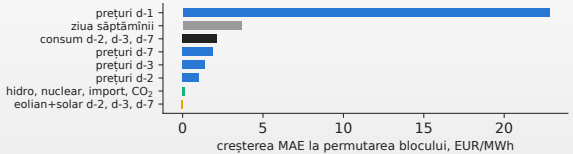
- Fiecare punct este o oră din anul de test: cu cît producția eoliană și solară din $d-2$ la acea oră este mai mare, cu atît contribuția ei este mai negativă (corelație $-0{,}64$)
- Efectul apare peste aproximativ 2 gigawați (GW), mai ales la prînz: un prag pe care un model liniar nu îl poate exprima

- **În practică:** un dezvoltator de parcuri solare poate citi aici reducerea de preț la care contribuie chiar producția sa.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 6

Rețeaua neuronală se bazează și mai mult pe prețurile de ieri



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31; 5 permutări aleatoare ale zilelor de test.

- Importanța prin permutare: I_b = MAE cu blocul b amestecat între zilele de test minus MAE fără amestecare (5 permutări)
  - Se aplică oricărui model
- Prețurile din $d-1$: +22,82 EUR/MWh
  - Ziua săptămînii +3,66
  - Consumul +2,12
  - Producția eoliană și solară −0,08

- **În practică:** monitorizați întîi fluxul prețurilor din $d-1$: fără el, rețeaua cedează.

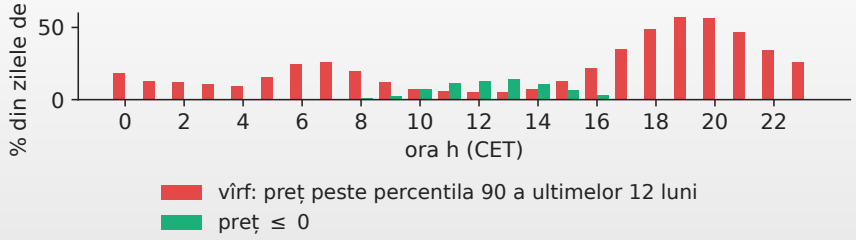
(Breiman, 2001, Mach. Learn.; calcule proprii)

Exerciții practic: notebook-ul Jupyter, secțiunea 6

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Vîrfurile de preț apar seara, prețurile negative la prînz



Sursa: energy-charts.info (Fraunhofer ISE): prețurile PZU ale OPCOM pentru România. Date: anul de test 2025-11-01 - 2026-10-31.

- **Vîrf de preț**: preț peste θ, percentila 90 a prețurilor orare din cele 12 luni dinaintea lunii de livrare
  - θ între 166,8 și 202,4 EUR/MWh; 22,1% din orele de test sînt vîrfuri, cele mai multe la ora 19 (57,0% din zile)
- **Preț $\leq$ 0**: 255 de ore, în 53 de zile din anul de test, mai ales în jurul orei 13

- **În practică:** o baterie se încarcă la prînz și se descarcă la orele 19–20: cele două evenimente sînt chiar modelul ei de afaceri.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Clasificarea vîrfurilor: o prognoză bună de preț le detectează deja

- **Pe scurt:** Un clasificator dă probabilitatea ca o oră să fie un vîrf; judecăm cît de bine ordonează orele și cît de corecte sînt probabilitățile lui.

$$\hat{\pi}_{d,h} = \Pr\left(P_{d,h} > \theta_d \mid \mathbf{x}_{d,h}\right)$$

$$\text{Brier} = \frac{1}{n}\sum_{d,h}\left(\hat{\pi}_{d,h} - S_{d,h}\right)^2$$

- **unde**
  - $S_{d,h} = 1$ dacă ora este un vîrf, 0 altfel
  - Precizia = ponderea alertelor urmate de vîrfuri
  - Sensibilitatea = ponderea vîrfurilor semnalate
  - F1 = media lor armonică
  - Aria de sub curbă (AUC) = probabilitatea ca o oră cu vîrf să primească un scor mai mare decît o oră obișnuită.

- **Pe datele noastre**: clasificatori XGBoost și logistic, reestimați lunar
  - Vîrfuri în 22,1% din orele de test și în 14,3% din ultimul eșantion de antrenare
  - Scorul Brier: XGBoost 0,072; ponderea constantă a vîrfurilor 0,172
- **Repere**
  - Persistența: ponderea vîrfurilor la aceeași oră în ultimele 7 zile
  - Chiar prognoza de preț AW-LEAR, comparată cu θ

- **În practică:** judecați o alertă după probabilitățile ei, nu doar după cîte vîrfuri semnalează.

(Brier, 1950; Fawcett, 2006)

Exerciții practice: notebook-ul Jupyter, secțiunea 7

Alertele din anul de test: AW-LEAR egalează un clasificator dedicat

Model	AUC	Precizie	Sensibilitate	F1	Brier	AUC	F1
XGBoost	0,953	0,826	0,685	0,749	0,072	0,980	0,571
Regresie logistică	0,953	0,847	0,641	0,730	0,072	0,980	0,581
Persistență, 7 zile	0,918	0,761	0,681	0,719	0,083	0,847	0,205
Prognoza AW-LEAR $> \theta$	0,959	0,851	0,733	0,788	–	0,983	0,558

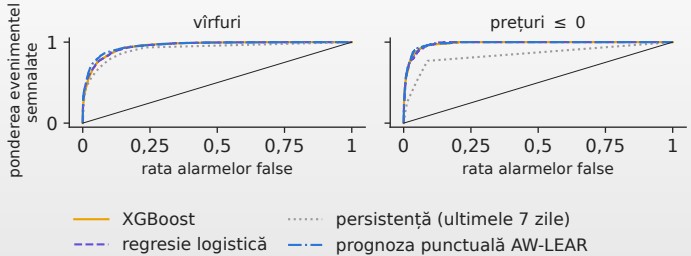
- Coloanele 2–6: vîrfuri (1 938 de ore); coloanele 7–8: prețuri ≤ 0 (255 de ore). Alertă cînd probabilitatea $> 0{,}5$; AW-LEAR: alertă cînd prognoza prețului depășește θ (sau este ≤ 0).
- La prețurile negative, XGBoost semnalează doar o fracțiune 0,467 din evenimente la pragul 0,5: aceste ore sînt rare și depind de vremea de mîine.

- **În practică:** cumpărați un serviciu de alertă pentru vîrfuri doar dacă depășește semnalul ascuns deja în prognoza dumneavoastră de preț.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Persistența detectează vîrfurile, dar nu și prețurile negative



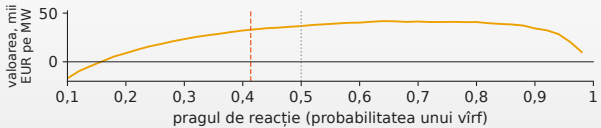
Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

- Curbele caracteristice de operare (ROC)
  - Vîrfuri: AUC între 0,918 (persistență) și 0,959 (AW-LEAR), deoarece vîrful de seară se repetă de la o zi la alta
- Prețuri negative: persistența are AUC 0,847, față de 0,980 pentru XGBoost
  - Ele depind de soarele și vîntul de mîine, nu de ziua de ieri

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Regula cost–pierdere: reacționați cînd probabilitatea depășește C/L



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31; 1 MW de consum flexibil, C = 30 EUR/MWh (ipoteză).

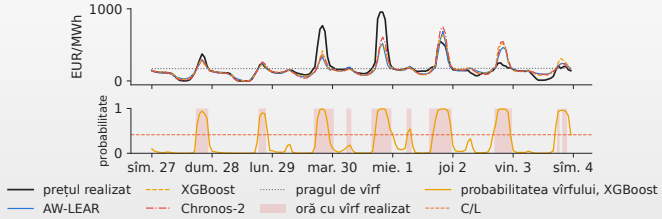
- **Regula**: reacție dacă $\hat{\pi}_{d,h} > C/\bar{L} = 30/72{,}5 = 0{,}414$; C = costul reacției, $\bar{L}$ = costul unui vîrf ratat
  - Mutarea a 1 MWh dintr-o oră cu alertă aduce $P_{d,h} - \theta_d - C$; C = 30 EUR/MWh (ipoteză); $\bar{L}$ = depășirea medie a pragului în anul de validare
- Valoarea pe MW și an: 33,0 mii EUR la pragul C/L, 11,8 cu persistența, 62,4 cu informație perfectă

- **În practică:** stabiliți pragul din propriile costuri
  - Cel mai bun prag văzut ulterior (0,64) este înțelepciune retrospectivă.

(Murphy, 1977, MWR; calcule proprii)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Studiu de caz, 30 iunie 2026: vîrful a fost anticipat, amploarea lui nu



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: 2026-06-27 - 2026-07-03, date orare.

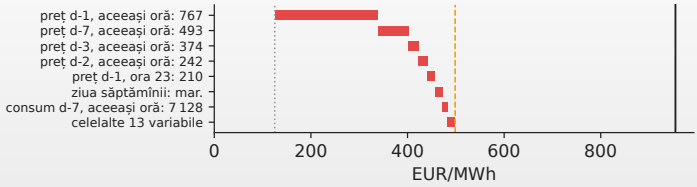
- **Ora 20:00 CET**: 954,59 EUR/MWh, cel mai mare preț din anul de test
  - Prognoze: AW-LEAR 520, XGBoost 499, DNN 614, Chronos-2 607; probabilitatea vîrfului 0,992
- Săptămîna 27 iunie 2026 – 3 iulie 2026: 47 de ore cu vîrfuri, 45 de alerte la pragul C/L, iar 39 de alerte au fost corecte

În practică: probabilitatea arată dacă reacționați, prognoza punctuală arată cît.

(calcule proprii; prețurile PZU din România)

Exerciții practic: notebook-ul Jupyter, secțiunea 8

Studiu de caz: arborii au urmat seara extremă din ziua precedentă



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: 2026-06-30, ora 20:00 CET; contribuții exprimate în EUR/MWh (anexa C).

- De la 125 (prognoza medie) la 499 EUR/MWh: prețul din $d-1$, aceeași oră, $+213$
  - Prețul din $d-7$ $+64$
- Arborii nu pot depăși prețurile memorate în frunze: valorile extreme sînt plafonate

- **În practică:** prezentați consiliului de administrație această descompunere pentru fiecare alertă importantă.

(calcule proprii; valori SHAP în EUR/MWh, anexa C)

Exerciții practic: notebook-ul Jupyter, secțiunea 8

Avertizarea timpurie a vîrfurilor: lucrarea grupului și replicarea ei

- **Ce a făcut lucrarea** (Andrei, Pele, Cramer, Amza & Diaconu, 2026)
  - Date: 5.000 de ore de pe PZU din România, în 2024, cu date despre consum, surse regenerabile și combustibili; vîrf = preț peste percentila 90
  - Metodă: păduri aleatoare și XGBoost, explicate cu SHAP; un scor de avertizare construit din pragurile mai multor indicatori
  - Rezultat: prețul anterior și prognoza consumului rezidual sînt principalii factori ai vîrfurilor
- **Replicarea noastră** (studiul de caz C7, numai cu informația de la închiderea licitației)
  - Perioada de test: iulie 2025 – octombrie 2026; vîrfuri în 22,1% din ore (în antrenare: 10,0%)
  - XGBoost: AUC 0,946; principalii factori: prețul de ieri și cel de acum o săptămînă, la aceeași oră, ca pe diapozitivele anterioare

- Rezultatele lucrării sînt cele raportate de autori; cifrele replicării sînt calculate cu notebook-ul Jupyter al studiului de caz C7, pe datele noastre.

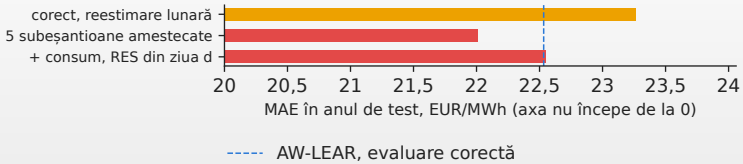
- **În practică:** prognoza consumului rezidual este variabila de care un model de vîrfuri are cea mai mare nevoie și care lipsește din datele noastre publice.

(Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE; studiul de caz C7)

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Informația din viitor: două evaluări invalide avantajează XGBoost



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC).
Date: anul de test 2025-11-01 - 2026-10-31; XGBoost, configurația aleasă.

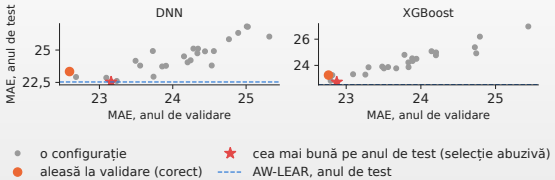
- **Validare încrucișată cu 5 subeșantioane amestecate**: zile din viitor ajung în eșantionul de antrenare
  - MAE 22,01 în loc de 23,26: cu 5,4% mai bine, doar pe hîrtie
- **Consumul și producția eoliană și solară din ziua d ca intrări**: nu sînt cunoscute la ora 12:00 în ziua $d-1$; în grafic, surse regenerabile de energie (RES)
  - MAE 22,55; un cîștig aparent de 3,1%, cel mult cît ar putea aduce prognoze perfecte ale acestor variabile

- **În practică:** cereți oricărui furnizor o testare cronologică, cu fiecare intrare datată la momentul închiderii licitației.

(Bergmeir & Benítez, 2012, Inf. Sci.; calcule proprii)

Exercițiu practic: notebook-ul Jupyter, secțiunea 9

Alegerea pe anul de test simulează o victorie asupra LEAR



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC). Date: anul de validare și anul de test 2025-11-01 - 2026-10-31; o inițializare pe configurație.

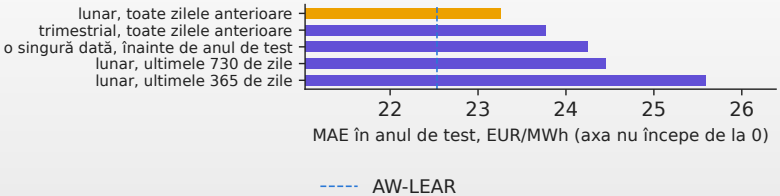
- Rețeaua DNN aleasă corect (la validare, o inițializare): MAE 23,34
  - Cea mai bună dintre cele 25 de setări pe anul de test: 22,52, chiar sub AW-LEAR (22,53)
- Clasamentele de validare și de test sînt apropiate (corelația Spearman 0,86 pentru DNN, 0,94 pentru XGBoost): validarea funcționează, dar nu este perfectă

- **În practică:** întrebați cîte modele au fost încercate înaintea celui prezentat
  - Cu cît sînt mai multe încercări, cu atît cel mai bun pare mai bun decît este.

(White, 2000, Econometrica; calcule proprii)

Exercițiu practic: notebook-ul Jupyter, secțiunea 9

Reestimarea: un model neactualizat un an pierde 4,3%



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM; consum, producție și fluxuri ENTSO-E; Yahoo Finance (EUA ETC). Date: anul de test 2025-11-01 - 2026-10-31; XGBoost, configurația aleasă.

- Estimat o singură dată, înaintea anului de test: MAE 24,25
  - Pierderea crește în timp (+0,15 EUR/MWh în primele 3 luni, +3,70 în ultimele 3)
- O fereastră glisantă scurtă (365 de zile, MAE 25,59) este mai slabă decît întregul istoric: arborii au nevoie de multe vîrfuri din trecut pentru a învăța

În practică: includeți reestimarea lunară în calendarul operațional, cu un responsabil, ca pe orice alt control.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 9

Testul de scurgere a informației: ștergerea viitorului nu schimbă nimic

- **Testul**
  - Pentru prima zi din fiecare dintre cele 12 luni de test, toate datele de după ora 12:00 din ziua $d-1$ sînt șterse, apoi înlocuite cu 10 000 EUR/MWh
  - XGBoost, rețeaua DNN și clasificatorul de vîrfuri sînt reestimate și trebuie să dea aceleași prognoze
- **Rezultatul**
  - Arborii și clasificatorul: prognoze identice; DNN: diferențe sub 0,001 EUR/MWh (rotunjiri ale calculelor paralele)
  - Chronos: contextul este construit numai din zilele dinaintea zilei d, verificat în cod
- **Lista de verificare înainte de a avea încredere într-un model**
  - Fiecare intrare datată la momentul închiderii licitației
  - Setări alese pe un an de validare
  - Un singur an de test, deschis o singură dată, cu teste DM față de LEAR
  - Reestimări lunare și un test de perturbare ca acesta

În practică: includeți această verificare în evaluarea oricărui model, statistic sau de învățare automată.

(cursul 2; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 10

Test 1: o testare retrospectivă perfectă

- Un start-up prezintă o rețea neuronală cu rMAE 0,70 pentru România, testată prin validare încrucișată cu 5 subeșantioane amestecate
  - Ce cereți?

Răspuns

- O testare cronologică pe un an neatins, cu intrări cunoscute la ora 12:00 în ziua $d - 1$: pe datele noastre, doar amestecarea a făcut XGBoost să pară cu 5,4% mai bun.

Test 2: ce model puneți în producție

- Chronos-2 are cea mai mică MAE dintre modelele individuale
  - Combinația AW-LEAR + Chronos-2 are aceeași MAE
  - Pe care o puneți în producție?

Răspuns

- Combinația: aceeași acuratețe (DM, $p = 0{,}491$), dar dacă modelul preantrenat se degradează sau devine indisponibil, LEAR asigură în continuare jumătate din prognoză.

Test 3: interpretarea valorilor SHAP

- Consumul are o pondere SHAP mică (8,5%)
  - Putem concluziona că acesta nu influențează prețul?

Răspuns

- Nu: SHAP explică modelul, nu piața
  - Consumul intră doar cu valoarea din ziua $d - 2$, deja reflectată în prețul de ieri.

Test 4: pragul de alertă

- Mutarea a 1 MWh vă costă 60 EUR în loc de 30
  - Cum se schimbă pragul de alertă?

Răspuns

- Se dublează: C/L crește de la 0,414 la aproximativ dublul acestei valori, deci reacționați numai la vîrfurile mai sigure.

Test 5: reestimarea

- Echipa de date propune ca modelul să fie antrenat o dată pe an, pentru a economisi efort
  - Ce arată anul de test?

Răspuns

- Un model neactualizat un an a fost cu 4,3% mai puțin precis, iar diferența a crescut în ultimele luni
  - O reestimare lunară a XGBoost durează circa 13 de secunde.

Recapitulare

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

- Calibrate, rețeaua DNN și XGBoost sînt mai precise decît în cursul 2, dar nu depășesc singure AW-LEAR
  - În medie cu acesta, îl depășesc
- Chronos-2, fără antrenare, este cel mai precis model individual (MAE 20,82, cu 7,6% sub AW-LEAR)
  - Orice model trebuie explicat, validat și reestimat

Cercetările grupului nostru: învățarea automată pe piața din România

- **Avertizarea timpurie a vîrfurilor de preț** (Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE)
  - Ce a făcut lucrarea: a construit un sistem explicabil de inteligență artificială (AI) pentru PZU din România
  - Rezultat: prețul anterior și consumul rezidual sînt principalii factori ai vîrfurilor (studiul de caz C7)
- **Explicarea prognozelor de preț pe mai multe orizonturi** (Andrei, Pele & Cramer, 2026, PICBE)
  - Ce a făcut lucrarea: a explicat prognozele de învățare automată pentru prețurile orare din România
  - Rezultat: arată ce factori contează la fiecare orizont și în fiecare regim de preț
- **Patru generații de modele pentru prețul energiei** (Andrei, Velev, Toma, Pele & Lessmann, 2024, arXiv 2411.03372)
  - Ce a făcut lucrarea: a comparat patru generații de metode de prognoză a prețurilor energiei, de la modelele statistice la învățarea profundă
  - Utilitate: un reper pentru alegerea familiei de modele
- **Modele fundaționale pentru riscul extrem** (Jheng, Tak, Găman, Mazurencu-Marinescu-Pele & Pele, 2026, ECECSR)
  - Ce a făcut lucrarea: a folosit modele fundaționale preantrenate, fără reantrenare și cu calibrare conformală, pentru prognoza pierderilor extreme pe piețele din Europa Centrală și de Est
- Rezultatele de pe acest diapozitiv sînt cele raportate în lucrări; celelalte cifre din curs provin din calculele noastre.

(Academia de Studii Economice din București; Academia Română, Institutul de Prognoză Economică)

Lecturi și resurse suplimentare

- **epftoolbox**: rețeaua DNN și modelul LEAR din Lago et al. (2021), cu date deschise pentru evaluare — github.com/jeslago/epftoolbox.
- **XGBoost** și **shap**, documentație: xgboost.readthedocs.io, shap.readthedocs.io.
- **Chronos**, modele fundaționale: github.com/amazon-science/chronos-forecasting.
- **Interpretable Machine Learning** (C. Molnar), gratuit online: christophm.github.io.
- **Acest curs**: cod, date, notebook-uri Jupyter — github.com/danpele/EMQA.
- **Studiul de caz C7** replică pe datele cursului lucrarea despre avertizarea timpurie a vîrfurilor.
- **Exerciții practic**: notebook-ul Jupyter reproduce toate graficele și cifrele din acest curs — notebooks/.

Bibliografie (1/3)

- Andrei, A.-V., Pele, D.-T. & Cramer, A.-A. (2026). Multi-horizon explainability in energy price forecasting: Disentangling market dynamics and renewable intermittency in Romania's liberalized electricity market. *Proceedings of the International Conference on Business Excellence*, 20(1), 104–117. doi:10.2478/picbe-2026-0014
- Andrei, A.-V., Pele, D.-T., Cramer, A.-A., Amza, A. & Diaconu, D. (2026). Explainable AI-based early warning system for electricity price spikes: Evidence from the Romanian market. *Proceedings of the International Conference on Business Excellence*, 20(1), 4820–4836. doi:10.2478/picbe-2026-0352
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2024). Energy price modelling: A comparative evaluation of four generations of forecasting methods. arXiv:2411.03372.
- Ansari, A. F., Stella, L., Turkmen, C. et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. arXiv:2403.07815.
- Ansari, A. F., Shchur, O., Küken, J. et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821.
- Bates, J. M. & Granger, C. W. J. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. doi:10.1057/jors.1969.103
- Bergmeir, C. & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213. doi:10.1016/j.ins.2011.12.028
- Bergstra, J. & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi:10.1023/A:1010933404324

Bibliografie (2/3)

- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
- Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794. doi:10.1145/2939672.2939785
- Diebold, F. X. & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. doi:10.1016/j.patrec.2005.10.010
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. Springer. doi:10.1007/978-0-387-84858-7
- Jheng, S., Tak, R., Găman, Ș., Mazurencu-Marinescu-Pele, M. & Pele, D. T. (2026). Can foundation models manage risk? Zero-shot VaR and ES forecasting with conformal calibration in CEE markets. *Economic Computation and Economic Cybernetics Studies and Research*, 60(2), 267–290. doi:10.24818/18423264/60.2.26.14
- Kingma, D. P. & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*. arXiv:1412.6980.
- Lago, J., De Ridder, F. & De Schutter, B. (2018). Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221, 386–405. doi:10.1016/j.apenergy.2018.02.069

Bibliografie (3/3)

- Lago, J., Marcjasz, G., De Schutter, B. & Weron, R. (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293, 116983. doi:10.1016/j.apenergy.2021.116983
- Lundberg, S. M., Erion, G., Chen, H. et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. doi:10.1038/s42256-019-0138-9
- Marcjasz, G., Narajewski, M., Weron, R. & Ziel, F. (2023). Distributional neural networks for electricity price forecasting. *Energy Economics*, 125, 106843. doi:10.1016/j.eneco.2023.106843
- Murphy, A. H. (1977). The value of climatological, categorical and probabilistic forecasts in the cost-loss ratio situation. *Monthly Weather Review*, 105(7), 803–816. doi:10.1175/1520-0493(1977)105<0803:TVOCCA>2.0.CO;2
- Shapley, L. S. (1953). A value for n-person games. In *Contributions to the Theory of Games II*, 307–317. Princeton University Press. doi:10.1515/9781400881970-018
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15, 1929–1958.
- Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030–1081. doi:10.1016/j.ijforecast.2014.08.008
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152

Anexa A: propagarea înapoi a erorii și pasul Adam

$$\frac{\partial \mathcal{L}}{\partial W_2} = \boldsymbol{\delta}\, \mathbf{z}^\top, \quad \boldsymbol{\delta} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{Y}}}$$

$$\frac{\partial \mathcal{L}}{\partial W_1} = \left[(W_2^\top \boldsymbol{\delta}) \odot \phi'(\mathbf{u}) \right] \mathbf{x}^\top$$

- Regula de derivare a funcțiilor compuse, de la ieșire spre intrări
  - Pentru eroarea absolută, $\partial |y - \hat{y}| / \partial \hat{y} = -\operatorname{sign}(y - \hat{y})$.
- $\mathbf{u} = W_1 \mathbf{x} + \mathbf{b}_1$
  - $\odot$ = produs element cu element
  - Pentru softplus, $\phi'(u) = 1/(1 + e^{-u})$.

(Kingma & Ba, 2015, ICLR; Hastie et al., 2009)

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2$$

$$\theta_k = \theta_{k-1} - \eta \, \frac{m_k / (1 - \beta_1^k)}{\sqrt{v_k / (1 - \beta_2^k)} + \varepsilon}$$

- g_k = gradientul pe grupul de zile k
  - $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$ (valori implicite)
  - Fiecare pondere are propriul pas.
- Penalizarea ponderilor adaugă $\lambda\theta$ la g_k (o penalizare pătratică, aici $\lambda = 10^{-5}$).

Anexa B: de ce valoarea optimă a unei frunze este $-G/(H+\lambda)$

$$\ell\big(Y_i, F_{m-1} + f\big) \approx \ell_i + g_i f(\mathbf{x}_i) + \tfrac{1}{2} h_i f(\mathbf{x}_i)^2$$

$$\sum_j \left[G_j w_j + \tfrac{1}{2}(H_j + \lambda) w_j^2 \right] + \gamma J, \quad G_j = \textstyle\sum_{i \in R_j} g_i$$

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \qquad \text{scor} = -\tfrac{1}{2} \sum_j \frac{G_j^2}{H_j + \lambda} + \gamma J$$

- Dezvoltare Taylor de ordinul doi a funcției de pierdere în jurul prognozei curente
  - g_i, h_i = derivatele de ordinul întîi și al doilea
  - H_j = suma h_i din frunza j.
- În fiecare frunză, obiectivul este o parabolă în w_j: anulînd derivata, se obține w_j^*.
- Cîștigul unei împărțiri, de pe diapozitivul despre arborele de regresie, este scorul dinainte minus scorul de după împărțire.
- Pentru eroarea absolută, $h_i = 0$
  - XGBoost calculează atunci valorile frunzelor printr-o căutare unidimensională.

(Chen & Guestrin, 2016, KDD)

Anexa C: valori SHAP exprimate în EUR/MWh

$$\hat{P} = m + s \sinh\left(\phi_0 + \sum_j \phi_j\right), \qquad P_0 = m + s \sinh \phi_0$$

$$\phi_j^{\text{EUR}} = \phi_j \frac{\hat{P} - P_0}{\sum_k \phi_k} \Rightarrow \sum_j \phi_j^{\text{EUR}} = \hat{P} - P_0$$

- Arborii prognozează prețul transformat cu asinh
  - m, s = mediana și abaterea absolută mediană (MAD), scalată, a prețurilor de antrenare.
- Valorile SHAP se adună pe această scară
  - Pentru a raporta în euro, diferența $\hat{P} - P_0$ se împarte proporțional cu ϕ_j.
- Semnele și ordinea nu se schimbă
  - Contribuțiile se adună exact la prognoza în EUR/MWh.

(Lundberg et al., 2020, Nat. Mach. Intell.)

Anexa D: spațiile de căutare și setările alese

Setare DNN	Valori încercate	Aleasă
neuroni, stratul 1	64, 128, 256, 512	512
neuroni, stratul 2	0, 32, 64, 128, 256	niciunul
funcția de activare	ReLU, softplus	softplus
dropout	0,0; 0,1; 0,2; 0,3	0,1
rata de învățare	$3 \cdot 10^{-4}$; 10^{-3}; $3 \cdot 10^{-3}$	$3 \cdot 10^{-4}$
penalizare L1, intrări	0; 10^{-3}; 10^{-2}; 10^{-1}	0
grup (zile)	32, 64, 128	64
consum/RES/fund.	da sau nu	da/da/da

Setare XGBoost	Valori încercate	Aleasă
arbori	300, 600, 1000, 1500	1500
rata de învățare η	0,02; 0,05; 0,10	0,02
adîncimea	3, 4, 5, 6, 8	8
ponderea min. în frunză	1, 5, 20, 50	5
rînduri pe arbore	0,6; 0,8; 1,0	0,8
λ	0,1; 1,0; 10,0	0,1
funcția de pierdere	pătrat, abs., Huber	absolută

⊡ 24 de extrageri aleatoare pe model (cu valoare inițială fixată) și setarea din cursul 2; aleasă = MAE minimă în anul de validare.

(Bergstra & Bengio, 2012, JMLR)