

# Analiza cantitativă a piețelor de energie

## Cursul 7: Învățarea automată pe piețele de energie

**Prof. dr. Daniel Traian PELE**

Academia de Studii Economice din București, Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

# Obiectivele cursului

- Organizarea corectă a unui experiment de învățare automată (ML)
  - Eșantioanele de antrenare, de validare și de test se succed în timp
  - Prognoza folosește numai informația cunoscută la ora 12:00 a Europei Centrale (CET) în ziua dinaintea livrării
- Construirea și calibrarea a două modele pentru cele 24 de prețuri orare ale zilei următoare
  - O rețea neuronală profundă (DNN)
  - Un ansamblu de arbori de decizie construiți secvențial (gradient boosting)
  - În plus, un model fundațional preantrenat
- Compararea cu modelele de referință din cursul 2, pe același an de test
  - Eroarea absolută medie (MAE), rădăcina erorii pătratice medii (RMSE), MAE relativă (rMAE) și testul Diebold–Mariano (DM)
  - Combinarea modelelor de învățare automată cu modelele statistice
- Explicarea prognozelor, anticiparea vîrfurilor de preț și a prețurilor negative
  - Capcanele care fac un model să pară mai bun decît este

# Abrevieri (1/2)

| | |
|---|---|
| **AI** | inteligență artificială |
| **ARIMA** | model autoregresiv integrat cu medie mobilă |
| **ARX** | model autoregresiv cu variabile exogene |
| **AUC** | aria de sub curba ROC |
| **AW** | medierea prognozelor obținute pe mai multe ferestre de calibrare |
| **AW-ARX** | ARX mediat pe ferestre de calibrare |
| **AW-LEAR** | LEAR mediat pe ferestre de calibrare |
| **CET** | ora Europei Centrale |
| **CPU** | unitatea centrală de procesare (nucleu de procesor) |
| **DM** | testul Diebold–Mariano |
| **DNN** | rețea neuronală profundă |
| **DST** | ora de vară |
| **ENTSO-E** | Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică |
| **ETC** | titlu tranzacționat la bursă, garantat cu mărfuri (exchange-traded commodity) |
| **EUA** | certificat de emisii al UE (1 t $CO_2$) |
| **EUR** | euro |
| **FWER** | rata erorii la nivelul familiei de ipoteze |
| **GBM** | gradient boosting (ansamblu de arbori de decizie construiți secvențial) |
| **GW** | gigawatt |
| **ISE** | Institutul Fraunhofer pentru Sisteme de Energie Solară |
| **LASSO** | operatorul de contracție și selecție în normă absolută |
| **LEAR** | autoregresie estimată cu LASSO |

# Abrevieri (2/2)

| | |
|---|---|
| **LLM** | model mare de limbaj |
| **MAD** | abaterea absolută mediană |
| **MAE** | eroarea absolută medie |
| **ML** | învățare automată |
| **MLP** | perceptron multistrat (rețea neuronală directă) |
| **MW** | megawatt |
| **MWh** | megawatt-oră |
| **OPCOM** | operatorul pieței de energie electrică și de gaze naturale din România |
| **PZU** | piața pentru ziua următoare |
| **RC** | testul Reality Check (testul de selecție abuzivă al lui White, 2000) |
| **ReLU** | unitate liniară rectificată (rectified linear unit) |
| **RES** | surse regenerabile de energie (aici: eolian + solar) |
| **rMAE** | MAE relativă (MAE a modelului / MAE a modelului naiv) |
| **RMSE** | rădăcina erorii pătratice medii |
| **RO** | România (zonă de ofertare) |
| **ROC** | caracteristica de operare a receptorului (receiver operating characteristic) |
| **SHAP** | explicații aditive bazate pe valorile Shapley (SHapley Additive exPlanations) |
| **SMAPE** | eroarea procentuală absolută medie simetrică |
| **SPA** | abilitate predictivă superioară (testul lui Hansen, 2005) |
| **TSO** | operator de transport și de sistem |
| **UE** | Uniunea Europeană |
| **XGBoost** | eXtreme Gradient Boosting (bibliotecă de programe) |

# Datele: eșantionul și anul de test din cursul 2, cu un an suplimentar de validare

| Element | Alegerea din acest curs |
|---|---|
| Variabila prognozată | prețul orar de pe piața pentru ziua următoare (PZU) din România (RO), administrată de operatorul pieței de energie electrică și de gaze naturale (OPCOM) |
| Variabile explicative (ca în cursul 2) | prețurile pînă în ziua $d-1$; consumul, producția eoliană și solară, hidro, nucleară și importul net pînă în ziua $d-2$, de la Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică (ENTSO-E); prețul certificatelor de emisii (EUA) ale Uniunii Europene (UE), printr-un titlu tranzacționat la bursă (ETC) |
| Antrenare | de la 8 ianuarie 2022; crește cu o lună la fiecare reestimare |
| Anul de validare | 1 noiembrie 2024 – 31 octombrie 2025: folosit numai pentru alegerea setărilor modelelor |
| Anul de test | 1 noiembrie 2025 – 31 octombrie 2026, 8 760 de ore, modele reestimate lunar |

- **Date pînă la 31 octombrie 2026**
  - Descărcate la 4 noiembrie 2026 de pe energy-charts.info (Fraunhofer ISE) și Yahoo Finance
- **Modelele de referință**: prognozele din cursul 2, preluate din fișierele acestuia
  - Modelul naiv; modelul autoregresiv cu variabile exogene (ARX); operatorul de contracție și selecție în normă absolută (LASSO)
  - Autoregresia estimată cu LASSO (LEAR); ARX mediat pe mai multe ferestre de calibrare (AW-ARX), LEAR la fel (AW-LEAR); ansamblul de 4 modele

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 1

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Flexibilitatea și varianța modelelor de învățare automată

- **Pe scurt:** Un model flexibil poate învăța praguri și interacțiuni pe care LEAR nu le vede, dar poate învăța și zgomotul din anii de antrenare.

$$\hat{\theta} = \arg\min_{\theta} \underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell\big(Y_i, f_\theta(\mathbf{x}_i)\big)}_{\text{potrivirea pe zilele de antrenare}} + \underbrace{\lambda\,\Omega(\theta)}_{\text{penalizare}}$$

- **unde**
  - $f_\theta$ = modelul, cu parametrii $\theta$
  - $\mathbf{x}_i$ = variabilele cunoscute la închiderea licitației
  - $Y_i$ = prețul
  - $\ell$ = funcția de pierdere, aici eroarea absolută
  - $\Omega$ = complexitatea modelului, iar $\lambda$ = ponderea ei.

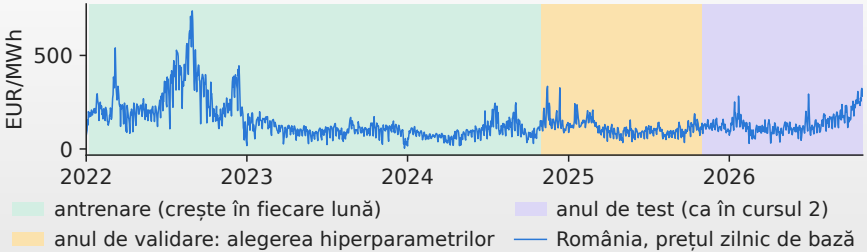
- **Cît de flexibile sînt modelele noastre?**
  - LEAR: cel mult 247 de coeficienți pentru fiecare oră
  - Rețeaua DNN: 141 336 de parametri, pentru 1 727 de zile de antrenare la ultima reestimare
- **Consecința**
  - Eroarea pe datele de antrenare nu spune nimic despre viitor; modelul poate fi judecat numai pe date pe care nu le-a văzut

- **În practică:** întrebați furnizorul de prognoze cîți parametri are modelul pentru fiecare zi de istoric și pe ce zile a fost măsurată eroarea.

(Hastie, Tibshirani & Friedman, 2009; Lago et al., 2021, APEN)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 1

# Trei eșantioane în ordine cronologică: antrenare, validare, test




Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: preț zilnic de bază, 2022-01-01 - 2026-10-31.

- **Anul de validare**: se compară 25 de setări pentru fiecare model, reestimate la fiecare 3 luni
  - Setarea cu cea mai mică MAE este fixată înainte de începutul anului de test
- **Anul de test**: modelele sînt reestimate la începutul fiecărei luni, pe toate zilele anterioare
  - Nu se folosește pentru nicio alegere; este același an ca în cursul 2, deci erorile se pot compara direct

**În practică:** tratați anul de test ca pe un plic sigilat, deschis o singură dată, după toate alegerile.

(Bergmeir & Benítez, 2012, Inf. Sci.; Lago et al., 2021, APEN)

EMQA_L7_split_ml

# Hiperparametrii se aleg prin căutare aleatoare pe anul de validare

- **Pe scurt:** Setări precum numărul de neuroni sau de arbori nu sînt estimate de model; încercăm mai multe și o păstrăm pe cea care prognozează cel mai bine zilele nevăzute.

$$\gamma^* = \arg \min_{\gamma \in \{\gamma_0, \ldots, \gamma_{24}\}} \frac{1}{24\,|\mathcal{V}|} \sum_{d \in \mathcal{V}} \sum_{h=0}^{23} \left| P_{d,h} - \hat{P}_{d,h}(\gamma) \right|$$

- **unde**
  - $\gamma$ = o setare (vectorul hiperparametrilor)
  - $\gamma_0$ = setarea din cursul 2, celelalte extrase aleator
  - $\mathcal{V}$ = zilele anului de validare
  - $\hat{P}_{d,h}(\gamma)$ = prognoza cu setarea $\gamma$.

- **De ce aleator și nu pe o grilă completă**
  - Doar cîteva setări contează cu adevărat; extragerile aleatoare le acoperă mai bine, cu același număr de încercări
- **Bugetul nostru**
  - 24 de setări aleatoare și setarea din cursul 2, pentru fiecare dintre cele două modele
  - 7,3 minute pe un nucleu al unității centrale de procesare (CPU)

- **În practică:** o căutare modestă, dar documentată, este suficientă
  - O căutare fără un eșantion de validare separat nu este o căutare, ci o scurgere de informație.

(Bergstra & Bengio, 2012, JMLR)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 2

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Structura unei rețele neuronale cu propagare înainte

- **Pe scurt:** Fiecare neuron transformă neliniar o combinație liniară a intrărilor; stratul de ieșire dă deodată cele 24 de prețuri ale zilei $d$.

$$\mathbf{z} = \phi\big(W_1 \mathbf{x}_d + \mathbf{b}_1\big), \qquad \hat{\mathbf{Y}}_d = W_2\,\mathbf{z} + \mathbf{b}_2 \in \mathbb{R}^{24}$$
$$\phi(u) = \max(0, u) \quad \text{sau} \quad \phi(u) = \ln(1 + e^u)$$

- **unde**
  - $\mathbf{x}_d$ = intrările zilei $d$ (prețuri, consum, eolian și solar, variabile fundamentale, ziua săptămînii)
  - $W_1, W_2$ = ponderi, $\mathbf{b}_1, \mathbf{b}_2$ = termeni liberi
  - $\phi$ = unitatea liniară rectificată (ReLU) sau varianta netedă (softplus)
  - $\hat{\mathbf{Y}}_d$ = prețurile transformate cu asinh (cursul 2).

- **Rețeaua noastră** (aleasă pe anul de validare)
  - 251 de intrări, un strat ascuns de 512 de neuroni, funcția softplus, 24 de ieșiri
  - 141 336 de parametri; rețelele cu două straturi au fost mai slabe la validare
- **Mai bună decît în cursul 2**
  - Perceptronul multistrat (MLP): MAE 25,54; rețeaua de acum: 22,95 EUR/MWh

- **În practică:** o rețea neuronală este o regresie cu mult mai mulți coeficienți: are nevoie de aceeași disciplină a datelor, nu de mai puțină.

(Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 2

# Antrenarea: metoda gradientului descendent stocastic, cu oprire timpurie

- **Pe scurt:** Ponderile se modifică puțin, în direcția care reduce eroarea pe un grup aleator de zile; ne oprim cînd eroarea pe zilele mai recente nu mai scade.

$$\mathcal{L}(\theta) = \frac{1}{24\,|B|} \sum_{d \in B} \sum_{h=0}^{23} \left| Y_{d,h} - \hat{Y}_{d,h}(\theta) \right|$$

$$\theta \leftarrow \theta - \eta\, \widehat{\nabla \mathcal{L}}$$

- **unde**
  - $B$ = un grup de 64 de zile (mini-batch)
  - $\eta$ = rata de învățare ($3 \cdot 10^{-4}$)
  - $\widehat{\nabla \mathcal{L}}$ = gradientul, rescalat prin metoda Adam
  - O epocă = o parcurgere a tuturor zilelor de antrenare.

- **Oprirea timpurie (early stopping)**
  - Antrenare pe primele 85% din zile, urmărirea erorii pe ultimele 15%
  - Se păstrează epoca cea mai bună, apoi rețeaua se reestimează pe toate zilele, cu același număr de epoci

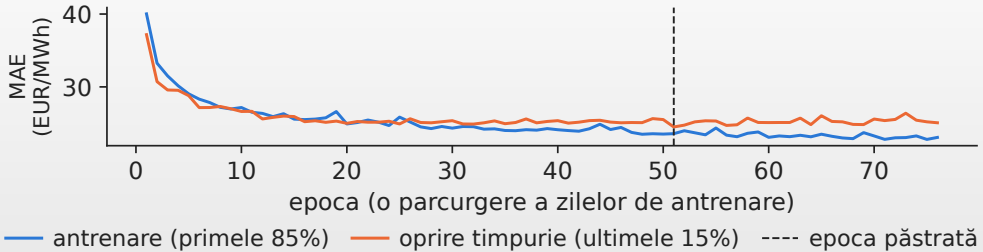
- **Pe datele noastre**
  - Epocile păstrate: mediana 56, între 23 și 92 (12 reestimări × 4 inițializări)
  - Dropout: în timpul antrenării, fiecare neuron este dezactivat aleator, cu probabilitatea 0,1

- **În practică:** regula de oprire folosește numai zile din trecut: face parte din model și se verifică la fel ca restul.

(Kingma & Ba, 2015, ICLR; Srivastava et al., 2014, JMLR)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 2

# Oprirea timpurie: ne oprim cînd eroarea pe zilele recente nu mai scade



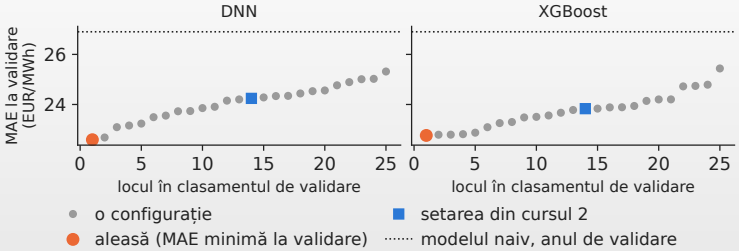

Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: rețeaua DNN aleasă, reestimarea pentru 2026-10, inițializarea 1.

- Reestimarea pentru octombrie 2026: eroarea pe ultimele 15% din zile este minimă la epoca 51
  - 24,50 EUR/MWh; antrenarea se oprește la epoca 76
- După acest punct, rețeaua reproduce mai bine trecutul, dar mai slab zilele recente: începe să memoreze

- **În practică:** cereți furnizorului această curbă: fără ea, rețeaua poate să fi memorat trecutul.

(calcule proprii; rețeaua DNN aleasă, inițializarea 1) EMQA_L7_learning_curve

# Căutarea aleatoare reduce eroarea de validare a ambelor modele




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de validare 2024-11-01 - 2025-10-31, reestimare trimestrială.

- **DNN**: cea mai bună setare are MAE 22,59 EUR/MWh; setarea din cursul 2, 24,24, locul 14 din 25
  - **eXtreme Gradient Boosting (XGBoost)**: 22,76 față de 23,83 (locul 14)
- Toate cele 25 de setări, la ambele modele, sînt mai precise decît modelul naiv (26,90 EUR/MWh)

- **În practică:** prevedeți un an de validare pentru calibrarea oricărui model de învățare automată.

(calcule proprii; anul de validare 1 noiembrie 2024 – 31 octombrie 2025)

EMQA_L7_search

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Un arbore de regresie împarte intrările în căsuțe, cu cîte un preț fiecare

- **Pe scurt:** Un arbore pune întrebări cu răspuns da/nu; fiecare frunză finală conține o valoare, deci pragurile și interacțiunile apar de la sine.

$$f(\mathbf{x}) = \sum_{j=1}^{J} w_j \mathbb{1}\{\mathbf{x} \in R_j\}$$

$$\text{Gain} = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma$$

- **unde**
  - $R_j$ = frunza $j$, $w_j$ = valoarea ei
  - $G$, $H$ = sumele derivatelor de ordinul 1 și 2 ale pierderii, la stînga ($L$) și la dreapta ($R$)
  - $\lambda$, $\gamma$ = penalizări
  - Se alege împărțirea cu cel mai mare cîștig.

- **Pe datele noastre** (reestimarea pentru octombrie 2026)
  - Primul arbore întreabă: prețul din $d-1$, aceeași oră, este sub 119,5 EUR/MWh?
  - 233 de frunze; modelul adună 1 500 de arbori

- **În practică:** un arbore gîndește ca un trader: dacă ieri prețul a trecut de un prag, diseară urmează o primă.

(Chen & Guestrin, 2016, KDD; Hastie et al., 2009)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 3

# Gradient boosting: fiecare arbore nou corectează erorile rămase

- **Pe scurt:** Potrivim un arbore mic pe ceea ce este încă greșit, îl adăugăm cu o pondere mică și repetăm de o mie de ori.

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, f_m(\mathbf{x}), \qquad w_j^* = -\frac{G_j}{H_j + \lambda}$$

$$\min \sum_i \ell\big(Y_i, F_M(\mathbf{x}_i)\big) + \sum_m \Big(\gamma J_m + \tfrac{\lambda}{2} \sum_j w_{mj}^2\Big)$$

- **unde**
  - $F_m$ = prognoza după $m$ arbori
  - $f_m$ = arborele $m$, cu $J_m$ frunze
  - $\eta$ = rata de învățare
  - $w_j^*$ = valoarea optimă a frunzei $j$ (anexa B)
  - $\ell$ = eroarea absolută.

- **Setarea aleasă pe anul de validare**
  - 1 500 de arbori de adîncime 8, $\eta = 0{,}02$, fiecare pe o fracțiune 0,8 din rînduri
- **Anul de test**
  - MAE 23,26 EUR/MWh; modelul gradient boosting (GBM) necalibrat din cursul 2: 24,05 (DM: $p < 0{,}001$)
  - AW-LEAR (22,53) rămîne mai precis (DM: $p = 0{,}016$)

- **În practică:** calibrarea contează mai mult decît programul: același tip de arbori a cîștigat aproape un euro pe MWh prin setări bune.

(Friedman, 2001, Ann. Stat.; Chen & Guestrin, 2016, KDD)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 3

# Modelele fundaționale prognozează prețurile fără nicio antrenare

- **Pe scurt:** Modelele Chronos au fost antrenate de Amazon pe colecții mari de serii de timp; noi le dăm doar prețurile recente și le cerem următoarele 24 de ore (fără reantrenare, zero-shot).

$$\left(\hat{q}^{\tau}_{d,h}\right)^{\tau=0{,}1;\,0{,}5;\,0{,}9}_{h=0,\ldots,23} = g\left(P_{t-2047},\ldots,P_t\right)$$

- **unde**
  - $P_{t-2047},\ldots,P_t$ = ultimele 2048 de prețuri orare, pînă la sfîrșitul zilei $d-1$ (85 de zile)
  - $g$ = rețeaua preantrenată, folosită ca atare
  - $\hat{q}^{\tau}$ = cuantilele prognozate
  - Prognoza punctuală este mediana $\hat{q}^{0,5}$.

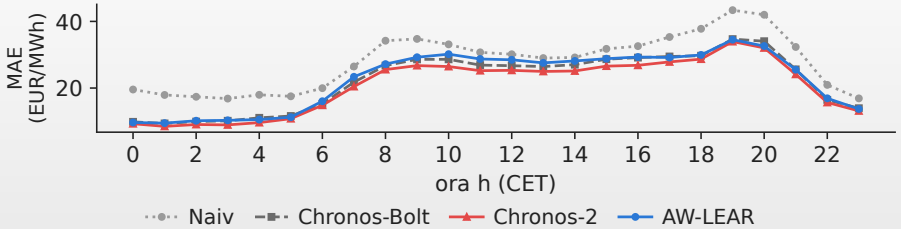
- **Anul de test**, numai cu prețuri, fără variabile fundamentale
  - Chronos-2: MAE 20,82; Chronos-Bolt: 22,15; AW-LEAR: 22,53 EUR/MWh
  - Chronos-2 este mai precis decît AW-LEAR: DM, $p < 0{,}001$; în toate cele 24 de ore
- **Robustețe**
  - În anul de validare: Chronos-2 21,05, cea mai bună rețea DNN calibrată 22,59
  - Publicat în octombrie 2025, înaintea anului de test

- **În practică:** testați un model fundațional înainte de a construi propria rețea: costă puțin, iar aici a fost cel mai precis model individual.

(Ansari et al., 2024, TMLR; Ansari et al., 2025, arXiv)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 4

# Chronos-2 este mai precis decît AW-LEAR în fiecare oră a zilei




Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: anul de test 2025-11-01 - 2026-10-31; fără reantrenare, context = ultimele 2048 de prețuri orare.

- Chronos-Bolt, mai mic și mai vechi, este la egalitate cu AW-LEAR (DM: $p = 0{,}220$)
- Intervalul 10%–90% al modelului Chronos-2 conține 76,5% din prețuri, nu 80%: este prea îngust

- **În practică:** folosiți mediana
  - Recalibrați intervalele (cursul 2) înainte de a dimensiona riscul cu ele.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026) EMQA_L7_foundation_hour

# AIDA 2026: DNN întrece LEAR, modelele preantrenate concurează

- **R. Weron, conferință invitată** (4 iunie 2026, diapozitive)
  - Evoluția modelelor: ARX, medierea pe ferestre, LEAR, rețele profunde și interpretabile
  - Modele preantrenate, fără reantrenare (zero-shot), față de LEAR și de rețele DNN distribuționale, test 2021–2025
- **Rețele profunde și interpretabile**
  - Evaluarea deschisă epftoolbox: rețeaua DNN are rMAE mai mică decît LEAR pe toate cele cinci piețe (Lago et al., 2021)
  - NBEATSx: blocurile de trend, sezonalitate și variabile exogene fac rețeaua interpretabilă (Olivares et al., 2023)
- **Rezultate zero-shot** (RMSE, conform diapozitivelor)
  - 2022: LEAR + predicție conformală 45,71, Chronos 2 41,07, TabPFN 3.0 ts 34,39
  - 2025: 20,38, 20,58 și 17,66; o versiune TabPFN a fost cea mai bună în fiecare an
- **Legătura cu anul nostru de test**
  - Chronos-2, fără reantrenare, este cel mai precis model individual (MAE 20,82, față de 22,53 la AW-LEAR)
  - Clasamentele se schimbă: TabPFN 2.0 a avut RMSE 68,85 în 2022 și 17,52 în 2025

- **În practică:** păstrați LEAR ca reper și testați modelele zero-shot alături de el, pe mai mulți ani.

(diapozitivele AIDA 2026, București; lucrări: Lago et al., 2021, APEN; Olivares et al., 2023, IJF)

# AIDA 2026: patru generații de modele pe 27 de serii europene de prețuri

- **A.-V. Andrei et al., prezentare** (3 iunie 2026, diapozitive)
  - 11 modele, patru generații: econometrie, de ex. modelul autoregresiv integrat cu medie mobilă (ARIMA); învățare profundă; transformere; modele mari de limbaj (LLM) preantrenate: Chronos, TimesFM
- **Date și validare walk-forward**
  - Prețuri angro din 27 de țări ale Uniunii Europene (UE), Ember (ENTSO-E)
  - 96 de pași la intrare și 96 la ieșire; antrenare 2000 de ore (83 de zile), test 500 de ore (20 de zile)
  - Eroarea procentuală absolută medie simetrică (SMAPE); scor $(100 \times \text{SMAPE} + \text{RMSE})/2$
- **Rezultate** (locul între cele 11 modele)
  - PatchTST (un transformer) este pe primul sau al doilea loc în toate cele 27 de țări
  - România: PatchTST 1, TimesFM 2, Chronos 8, ARIMA 9
  - Germania: PatchTST 1, TimesFM 5, Chronos 10
  - Cîștigurile depind de model, nu sînt uniforme în generația a patra
- **Legătura cu acest curs**
  - Pe prețurile din România, Chronos-2 (2025) este cel mai bun model individual (MAE 20,82)

**În practică:** comparați generațiile de modele prin validare walk-forward, pe mai multe piețe, înainte de a alege.

(diapozitivele AIDA 2026, București; lucrare: Andrei et al., 2024, arXiv)

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Clasamentul: Chronos-2 este cel mai bun model individual

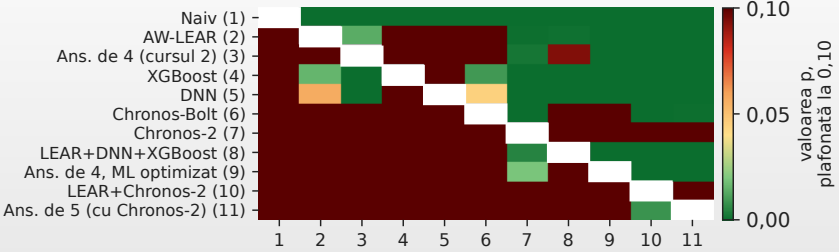
| Model | MAE | RMSE | rMAE | față de AW-LEAR, % | DM, $p$ |
|---|---|---|---|---|---|
| Naiv | 27,82 | 44,54 | 1,000 | −23,5 | – |
| AW-ARX | 22,30 | 36,34 | 0,802 | +1,0 | 0,203 |
| AW-LEAR | 22,53 | 36,35 | 0,810 | +0,0 | – |
| Ansamblul de 4 (cursul 2) | 22,13 | 35,76 | 0,795 | +1,8 | 0,014 |
| GBM (cursul 2) | 24,05 | 37,73 | 0,864 | −6,7 | 1,000 |
| MLP (cursul 2) | 25,54 | 40,05 | 0,918 | −13,3 | 1,000 |
| XGBoost, calibrat | 23,26 | 36,94 | 0,836 | −3,2 | 0,984 |
| DNN, calibrată | 22,95 | 36,42 | 0,825 | −1,8 | 0,944 |
| Chronos-Bolt, fără antrenare | 22,15 | 35,65 | 0,796 | +1,7 | 0,220 |
| Chronos-2, fără antrenare | 20,82 | 34,32 | 0,748 | +7,6 | <0,001 |
| AW-LEAR + DNN + XGBoost | 21,97 | 35,42 | 0,790 | +2,5 | 0,001 |
| AW-ARX + AW-LEAR + DNN + XGBoost | 21,69 | 35,25 | 0,779 | +3,8 | <0,001 |
| AW-LEAR + Chronos-2 | 20,81 | 34,11 | 0,748 | +7,6 | – |
| Ansamblul de 5 (cu Chronos-2) | 21,12 | 34,50 | 0,759 | +6,3 | <0,001 |

- Rădăcina erorii pătratice medii (RMSE); MAE relativă (rMAE) = MAE / MAE a modelului naiv; verde = mai precis, pe fiecare coloană.
- DM, $p$: test unilateral că modelul este mai precis decît AW-LEAR (eroarea absolută medie zilnică, variantă Newey–West, ca în cursul 2).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 5

# Testele DM: combinațiile cu ML depășesc semnificativ AW-LEAR




modelul din coloană (numerotat ca rîndurile): este mai precis decît cel din rînd?

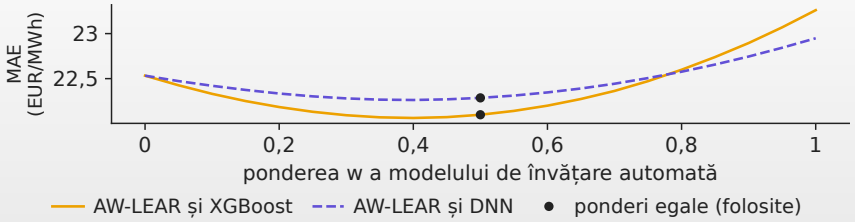
Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 365 de zile; valori p unilaterale.

- AW-LEAR + DNN + XGBoost este mai precis decît AW-LEAR ($p = 0{,}001$)
  - Cu AW-ARX adăugat, MAE scade la 21,69, sub ansamblul din cursul 2 ($p < 0{,}001$)
- Adăugarea AW-LEAR la Chronos-2 nu schimbă nimic ($p = 0{,}491$): în zilele dificile, cele două modele greșesc asemănător

(calcule proprii; teste DM unilaterale)

EMQA_L7_dm_matrix

# Media funcționează pentru că erorile nu sînt identice




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; ilustrare, ponderea nu se alege pe anul de test.

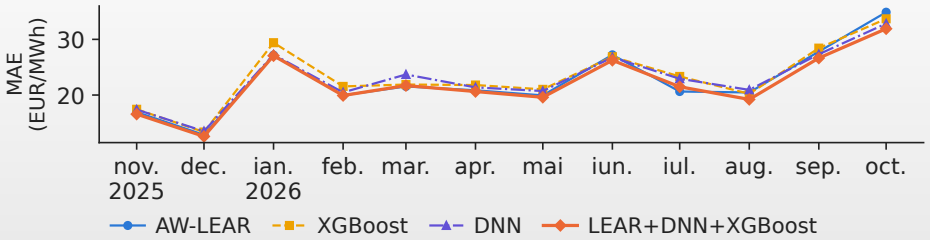
- Var $\left(\frac{e_1+e_2}{2}\right) = \frac{1}{4}(\sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$: dacă $\rho < 1$, media greșește mai puțin ($e$ = eroarea, $\sigma$ = abaterea ei standard, $\rho$ = corelația)
- Corelația erorilor cu AW-LEAR: 0,94 (DNN), 0,89 (XGBoost)
  - Ponderile egale sînt aproape la fel de bune ca ponderea optimă văzută ulterior (0,40)

- **În practică:** faceți media cu ponderi egale înainte de a estima ponderi „inteligente”.

(Bates & Granger, 1969; calcule proprii)

EMQA_L7_combo_weight

# Lunar, combinația este mai precisă decît AW-LEAR în 10 din 12 luni




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

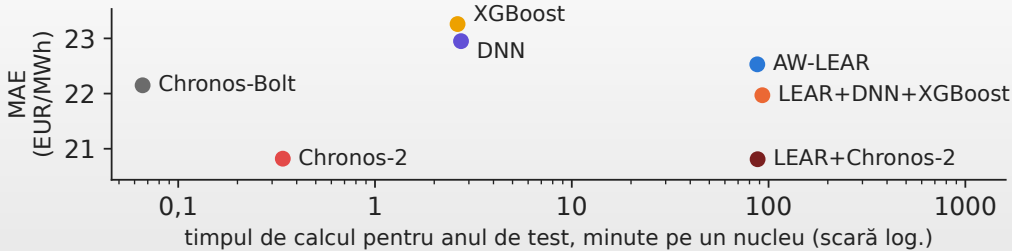
- Luate separat, XGBoost și DNN depășesc AW-LEAR fiecare doar în 3 luni
  - În medie cu acesta, în 10 luni
- Toate modelele greșesc mai mult în aceleași luni (ianuarie, iunie, octombrie): zilele dificile sînt dificile pentru toate

- **În practică:** raportați comitetului de risc acuratețea lună de lună, nu doar media anuală.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_monthly_ml

# Costul de calcul: LEAR zilnic este cel mai scump, ML costă minute




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; un nucleu de procesor.

- Anul de test, pe un nucleu: AW-LEAR 87,6 min (365 de zile × 3 ferestre × 24 de ore)
  - XGBoost 2,6 min, DNN 2,7 min, Chronos-2 0,3 min
- Costuri ascunse: căutarea setărilor (7,3 min), preantrenarea Chronos, oamenii care operează fluxul

- **În practică:** comparați modelele după eroare raportată la costul total de utilizare, nu doar după eroare.

(calcule proprii; timpi măsurați pe un nucleu al unui laptop cu 18 nuclee)

EMQA_L7_cost_gain

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Valorile Shapley descompun fiecare prognoză în contribuțiile variabilelor

- **Pe scurt:** Contribuția unei variabile este efectul ei mediu atunci cînd este adăugată în model, calculat pe toate ordinile posibile de adăugare a variabilelor.

$$\phi_j = \sum_{S \not\ni j} \frac{|S|!\,(p-|S|-1)!}{p!} \Big[ v(S \cup \{j\}) - v(S) \Big]$$

$$\hat{f}(\mathbf{x}) = \phi_0 + \sum_j \phi_j$$

- **unde**
  - $\phi_j$ = valoarea variabilei $j$ după metoda explicațiilor aditive bazate pe valorile Shapley (SHAP)
  - $S$ = o submulțime a celorlalte variabile
  - $v(S)$ = prognoza așteptată cînd se cunoaște doar $S$
  - $\phi_0$ = prognoza medie
  - $p = 20$ de variabile.

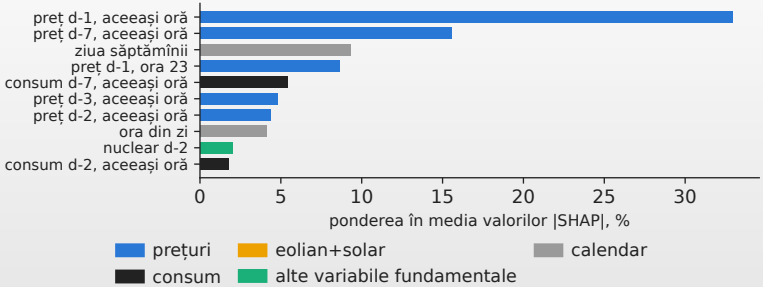
- **De ce valorile Shapley**
  - Singura împărțire echitabilă în sensul teoriei jocurilor; se adună exact la prognoză
- **Pe datele noastre**
  - XGBoost, 8 760 de ore de test; cea mai mare diferență dintre $\hat{f}$ și $\phi_0 + \sum \phi_j$: 0,000009
  - Prețurile din zilele anterioare au 69,3% din contribuția totală

- **În practică:** cereți explicația fiecărei alerte, nu doar un clasament global.

(Shapley, 1953; Lundberg et al., 2020, Nat. Mach. Intell.)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 6

# Ce determină prognoza arborilor: prețul de ieri, la aceeași oră




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

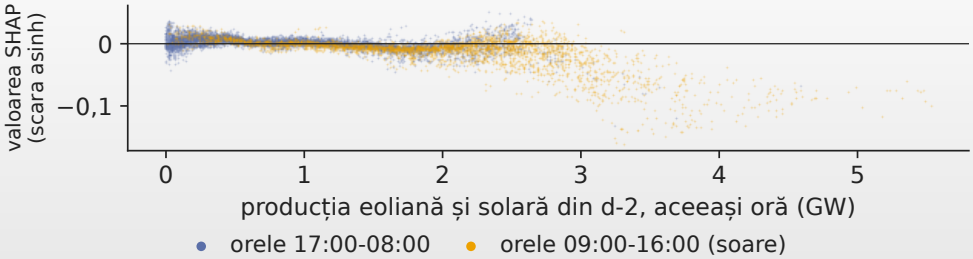
- Ponderi în media $|\phi|$: prețul din $d-1$, aceeași oră (32,9%), din $d-7$ (15,6%), ziua săptămînii (9,3%)
- Consum 8,5%, eolian și solar 2,5%: cunoscute doar pînă în $d-2$, deci informații vechi

- **În practică:** cumpărați întîi intrări mai bune: prognozele operatorului de transport și de sistem (TSO).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_shap_global

# Producția eoliană și solară scade prețul doar în orele în care este mare




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

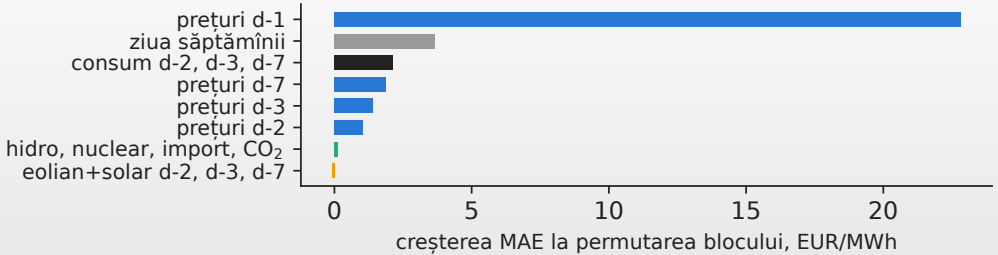
- Fiecare punct este o oră din anul de test
  - Mai multă producție eoliană și solară în $d-2$ înseamnă o contribuție mai negativă (corelație $-0{,}64$)
- Efectul apare peste circa 2 gigawați (GW): un prag pe care un model liniar nu îl poate exprima

- **În practică:** un dezvoltator solar vede aici reducerea de preț la care contribuie propria producție.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_shap_res

# Rețeaua neuronală se bazează și mai mult pe prețurile de ieri




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

- Importanța prin permutare $I_b$ = creșterea MAE cînd blocul $b$ este amestecat între zilele de test
  - 5 permutări, metodă valabilă pentru orice model
- Prețurile din $d-1$: $+22{,}82$ EUR/MWh
  - Ziua săptămînii $+3{,}66$, consumul $+2{,}12$, producția eoliană și solară $-0{,}08$

- **În practică:** monitorizați întîi fluxul prețurilor din $d-1$: fără el, rețeaua cedează.

(Breiman, 2001, Mach. Learn.; calcule proprii)

EMQA_L7_perm_dnn

# Finanțele energiei folosesc învățarea automată, dar rar o explică

- **R. Clodnitchi, prezentare** (3 iunie 2026, diapozitive)
  - Analiză sistematică a literaturii despre inteligența artificială (AI) în finanțele energiei (Anagnoste et al., 2025, *Energy Strategy Reviews*)
  - Circa 700 de articole din Web of Science, 232 reținute (evaluate colegial, 2020–2025), pe șase piloni ai finanțelor energiei
- **Unde se folosește AI** (ponderea lucrărilor cu AI/ML)
  - Mecanisme de preț 100%, derivate pe energie 100%, piețe energetice și financiare 97,5%, gestiunea riscului 93,0%
  - Finanțe verzi 60,4%; finanțele corporative ale firmelor de energie 0% (numai econometrie pe date panel)
- **Ce lipsește**
  - AI explicabilă: 19,6% din lucrările despre derivate, 0–5% în ceilalți piloni
  - Domină rețelele neuronale: 88,2% din lucrările despre derivate, 72,1% în gestiunea riscului
  - Direcția propusă: AI explicabilă și învățare automată cauzală, pentru autoritățile de reglementare și evaluarea politicilor
- **Legătura cu acest curs**
  - Graficele SHAP și de permutare din această secțiune sînt tipul de explicație pe care analiza îl găsește rar

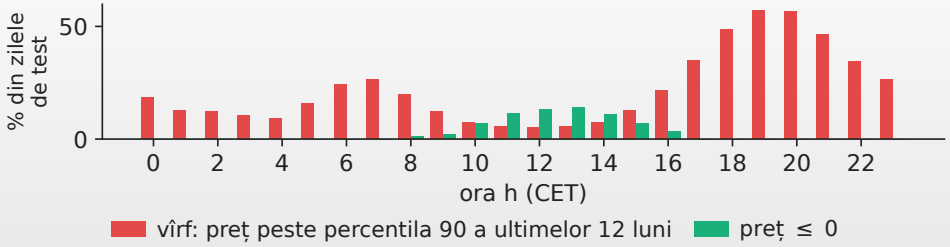
**În practică:** cereți explicația odată cu prognoza: autoritățile și consiliile de administrație o vor cere.

(diapozitivele AIDA 2026, București; lucrare: Anagnoste et al., 2025, ESR)

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Vîrfurile de preț apar seara, prețurile negative la prînz




Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: anul de test 2025-11-01 - 2026-10-31.

- **Vîrf de preț**: preț peste $\theta$, percentila 90 a prețurilor orare din cele 12 luni dinaintea lunii de livrare
  - $\theta$ între 166,8 și 202,4 EUR/MWh; 22,1% din orele de test sînt vîrfuri, cele mai multe la ora 19 (57,0% din zile)
- **Preț $\leq$ 0**: 255 de ore, în 53 de zile din anul de test, mai ales în jurul orei 13

- **În practică:** o baterie se încarcă la prînz și se descarcă la orele 19–20: cele două evenimente sînt chiar modelul ei de afaceri.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026) EMQA_L7_events_hour

# Clasificarea vîrfurilor: o prognoză bună de preț le detectează deja

- **Pe scurt:** Un clasificator dă probabilitatea ca o oră să fie un vîrf; judecăm cît de bine ordonează orele și cît de corecte sînt probabilitățile lui.

$$\hat{\pi}_{d,h} = \Pr\left(P_{d,h} > \theta_d \mid \mathbf{x}_{d,h}\right)$$

$$\text{Brier} = \frac{1}{n}\sum_{d,h}\left(\hat{\pi}_{d,h} - S_{d,h}\right)^2$$

- **unde**
  - $S_{d,h} = 1$ dacă ora este un vîrf, 0 altfel
  - Precizia = ponderea alertelor urmate de vîrfuri
  - Sensibilitatea = ponderea vîrfurilor semnalate
  - F1 = media lor armonică
  - Aria de sub curbă (AUC) = probabilitatea ca o oră cu vîrf să primească un scor mai mare decît o oră obișnuită.

- **Pe datele noastre**: clasificatori XGBoost și logistic, reestimați lunar
  - Vîrfuri în 22,1% din orele de test și în 14,3% din ultimul eșantion de antrenare
  - Scorul Brier: XGBoost 0,072; ponderea constantă a vîrfurilor 0,172
- **Repere**
  - Persistența: ponderea vîrfurilor la aceeași oră în ultimele 7 zile
  - Chiar prognoza de preț AW-LEAR, comparată cu $\theta$

- **În practică:** judecați o alertă după probabilitățile ei, nu doar după cîte vîrfuri semnalează.

(Brier, 1950; Fawcett, 2006)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 7

# Alertele din anul de test: AW-LEAR egalează un clasificator dedicat

| Model | AUC | Precizie | Sensibilitate | F1 | Brier | AUC | F1 |
|---|---|---|---|---|---|---|---|
| XGBoost | 0,953 | 0,826 | 0,685 | 0,749 | 0,072 | 0,980 | 0,571 |
| Regresie logistică | 0,953 | 0,847 | 0,641 | 0,730 | 0,072 | 0,980 | 0,581 |
| Persistență, 7 zile | 0,918 | 0,761 | 0,681 | 0,719 | 0,083 | 0,847 | 0,205 |
| Prognoza AW-LEAR $> \theta$ | 0,959 | 0,851 | 0,733 | 0,788 | – | 0,983 | 0,558 |

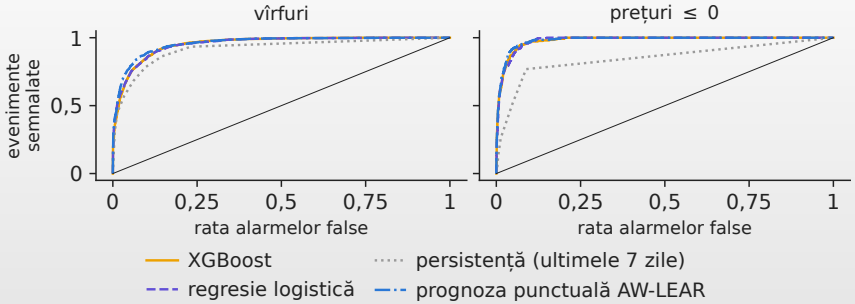
- Coloanele 2–6: vîrfuri (1 938 de ore); coloanele 7–8: prețuri $\leq 0$ (255 de ore). Alertă cînd probabilitatea $> 0{,}5$; AW-LEAR: alertă cînd prognoza prețului depășește $\theta$ (sau este $\leq 0$).
- La prețurile negative, XGBoost semnalează doar o fracțiune 0,467 din evenimente la pragul 0,5: aceste ore sînt rare și depind de vremea de mîine.

- **În practică:** cumpărați un serviciu de alertă pentru vîrfuri doar dacă depășește semnalul ascuns deja în prognoza dumneavoastră de preț.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 7

# Persistența detectează vîrfurile, dar nu și prețurile negative



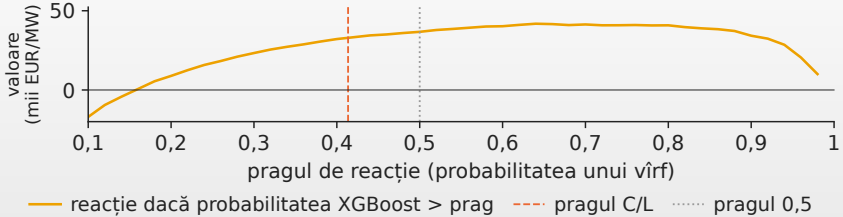

Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

- Curbele caracteristice de operare (ROC)
  - Vîrfuri: AUC între 0,918 (persistență) și 0,959 (AW-LEAR), deoarece vîrful de seară se repetă de la o zi la alta
- Prețuri negative: persistența are AUC 0,847, față de 0,980 pentru XGBoost
  - Ele depind de soarele și vîntul de mîine, nu de ziua de ieri

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_roc

# Regula cost–pierdere: reacționați cînd probabilitatea depășește C/L




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; 1 MW de consum flexibil.

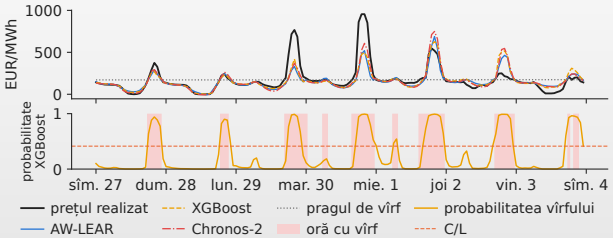
- **Regula**: reacție dacă $\hat{\pi}_{d,h} > C/\bar{L} = 30/72{,}5 = 0{,}414$
  - C = costul reacției = 30 EUR/MWh (ipoteză): mutarea a 1 MWh dintr-o oră cu alertă aduce $P_{d,h} - \theta_d - C$
  - $\bar{L}$ = costul unui vîrf ratat = depășirea medie a pragului în anul de validare
- Valoarea pe MW și an: 33,0 mii EUR la pragul C/L, 11,8 cu persistența, 62,4 cu informație perfectă

- **În practică:** stabiliți pragul din propriile costuri, nu retrospectiv (cel mai bun prag ulterior: 0,64).

(Murphy, 1977, MWR; calcule proprii)

EMQA_L7_decision

# Studiu de caz, 30 iunie 2026: modelele au anticipat vîrful, dar i-au subestimat amplitudinea




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: 2026-06-27 - 2026-07-03, date orare.

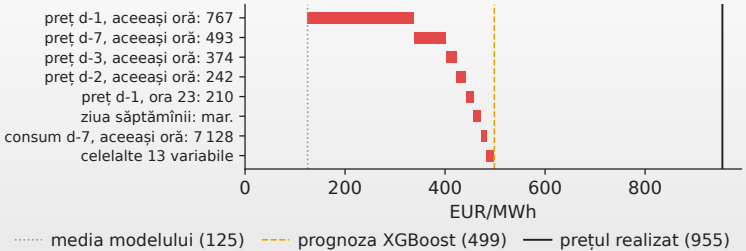
- **Ora 20:00 CET**: 954,59 EUR/MWh, cel mai mare preț din anul de test
  - Prognoze: AW-LEAR 520, XGBoost 499, DNN 614, Chronos-2 607; probabilitatea vîrfului 0,992
- În acea săptămînă: 47 de ore cu vîrf, 45 de alerte la pragul C/L, dintre care 39 corecte

- **În practică:** probabilitatea arată dacă reacționați, prognoza punctuală arată cît.

(calcule proprii; prețurile PZU din România)

EMQA_L7_case_week

# Studiu de caz: arborii au urmat seara extremă din ziua precedentă




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: 2026-06-30, ora 20:00 CET; contribuții exprimate în EUR/MWh (anexa C).

- De la 125 (prognoza medie) la 499 EUR/MWh: prețul din $d-1$, aceeași oră, +213
  - Prețul din $d-7$ +64
- Arborii nu pot depăși prețurile memorate în frunze: valorile extreme sînt plafonate

- **În practică:** prezentați consiliului de administrație această descompunere pentru fiecare alertă importantă.

(calcule proprii; valori SHAP în EUR/MWh, anexa C)

EMQA_L7_shap_local

# Avertizarea timpurie a vîrfurilor: lucrarea grupului și replicarea ei

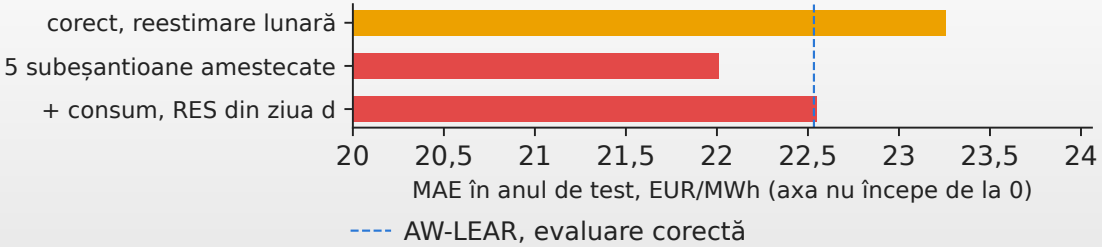
- **Ce a făcut lucrarea** (Andrei, Pele, Cramer, Amza & Diaconu, 2026)
  - Date: 5.000 de ore de pe PZU din România, în 2024, cu date despre consum, surse regenerabile și combustibili; vîrf = preț peste percentila 90
  - Metodă: păduri aleatoare și XGBoost, explicate cu SHAP; un scor de avertizare construit din pragurile mai multor indicatori
  - Rezultat: prețul anterior și prognoza consumului rezidual sînt principalii factori ai vîrfurilor
- **Replicarea noastră** (studiul de caz C7, numai cu informația de la închiderea licitației)
  - Perioada de test: iulie 2025 – octombrie 2026; vîrfuri în 22,1% din ore (în antrenare: 10,0%)
  - XGBoost: AUC 0,946; principalii factori: prețul de ieri și cel de acum o săptămînă, la aceeași oră, ca pe diapozitivele anterioare
- Rezultatele lucrării sînt cele raportate de autori; cifrele replicării sînt calculate cu notebook-ul Jupyter al studiului de caz C7, pe datele noastre.
- **În practică:** prognoza consumului rezidual este variabila de care un model de vîrfuri are cea mai mare nevoie și care lipsește din datele noastre publice.

(Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE; studiul de caz C7)

## Cuprins


- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

# Informația din viitor: două evaluări invalide avantajează XGBoost




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

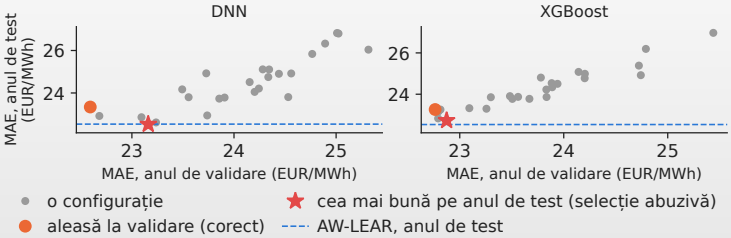
- **Validare încrucișată cu 5 subeșantioane amestecate**: zile din viitor intră în antrenare
  - MAE 22,01 în loc de 23,26: cu 5,4% mai bine, doar pe hîrtie
- **Consum și surse regenerabile de energie (RES) din ziua** $d$: necunoscute la 12:00 în $d-1$
  - MAE 22,55, un cîștig aparent de 3,1%: cel mult cît ar aduce prognoze perfecte ale acestor variabile

**În practică:** cereți oricărui furnizor o testare cronologică, cu intrările datate la închiderea licitației.

(Bergmeir & Benítez, 2012, Inf. Sci.; calcule proprii)

EMQA_L7_pit_leak

# Data snooping: selecția pe anul de test produce un avantaj aparent față de LEAR




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de validare și anul de test 2025-11-01 - 2026-10-31.

- Rețeaua DNN aleasă corect (la validare, o inițializare): MAE 23,34
  - Cea mai bună dintre cele 25 de setări pe anul de test: 22,52, chiar sub AW-LEAR (22,53)
- Validarea funcționează, dar imperfect: corelația Spearman a rangurilor, 0,86 (DNN), 0,94 (XGBoost)

- **În practică:** întrebați cîte modele au fost încercate: cu cît mai multe, cu atît cel mai bun pare mai bun.

(White, 2000, Econometrica; calcule proprii)

EMQA_L7_snooping

# Cel mai bun dintre multe modele trebuie testat față de reper

$$\mathrm{RC}_n = \max_{k=1,\ldots,m} \sqrt{n}\,\bar{d}_k, \qquad \bar{d}_k = \frac{1}{n}\sum_{t=1}^{n} d_{k,t}$$

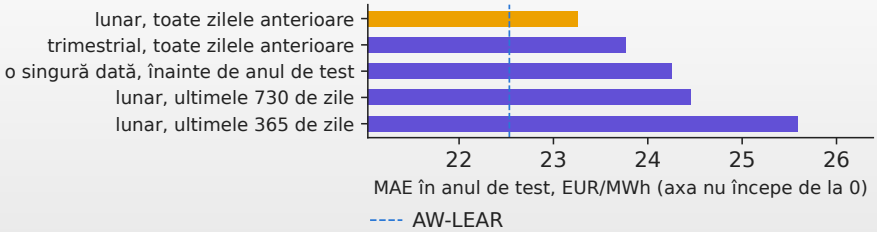
- **unde**
  - $d_{k,t}$ = pierderea reperului minus cea a modelului $k$ în ziua $t$
  - $H_0$: $E(d_{k,t}) \leq 0$ pentru orice $k$
  - Valoarea critică: bootstrap comun pe $(d_{1,t}, \ldots, d_{m,t})$, cu corelația dintre modele păstrată.
- **De ce**: pentru $m$ teste independente la 5%, P(cel puțin o victorie falsă) $= 1 - 0{,}95^m$: 0,401 ($m = 10$), 0,994 ($m = 100$)

- **C.-M. Kuan, 4 iunie 2026** (diapozitive)
  - Testul Reality Check (RC), White (2000): conservator, modelele slabe adăugate îi reduc puterea (Hansen, 2005)
  - Testul abilității predictive superioare (SPA), Hansen (2005): recentrează modelele slabe, mai puternic
  - Step-RC (Romano & Wolf, 2005), Step-SPA (Hsu, Hsu & Kuan, 2010): identifică modelele mai bune, controlînd rata erorii la nivelul familiei de ipoteze (FWER)
- **Pe datele noastre**
  - Cea mai bună dintre cele 25 de setări DNN pe anul de test trece sub AW-LEAR: cazul corectat de RC și SPA

- **În practică:** cînd vi se arată cel mai bun dintre multe modele, cereți valoarea p a testului RC sau SPA.

(diapozitivele AIDA 2026; lucrări: White, 2000; Hansen, 2005; Romano & Wolf, 2005; Hsu et al., 2010)

# Reestimarea: un model neactualizat un an pierde 4,2%




Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

- Estimat o singură dată, înaintea anului de test: MAE 24,25
  - Pierderea crește în timp (+0,15 EUR/MWh în primele 3 luni, +3,70 în ultimele 3)
- O fereastră glisantă scurtă (365 de zile, MAE 25,59) este mai slabă decît întregul istoric: arborii au nevoie de multe vîrfuri din trecut pentru a învăța

- **În practică:** includeți reestimarea lunară în calendarul operațional, cu un responsabil, ca pe orice alt control.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_pit_retrain

# Testul de scurgere a informației: prognozele recalculate fără datele viitoare rămîn neschimbate

- **Testul**
  - Pentru prima zi din fiecare dintre cele 12 luni de test, toate datele de după ora 12:00 din ziua $d-1$ sînt șterse, apoi înlocuite cu 10 000 EUR/MWh
  - XGBoost, rețeaua DNN și clasificatorul de vîrfuri sînt reestimate și trebuie să dea aceleași prognoze
- **Rezultatul**
  - Arborii și clasificatorul: prognoze identice; DNN: diferențe sub 0,001 EUR/MWh (rotunjiri ale calculelor paralele)
  - Chronos: contextul este construit numai din zilele dinaintea zilei $d$, verificat în cod
- **Lista de verificare înainte de a avea încredere într-un model**
  - Fiecare intrare datată la momentul închiderii licitației
  - Setări alese pe un an de validare
  - Un singur an de test, deschis o singură dată, cu teste DM față de LEAR
  - Reestimări lunare și un test de perturbare ca acesta

- **În practică:** includeți această verificare în evaluarea oricărui model, statistic sau de învățare automată.

(cursul 2; Lago et al., 2021, APEN)

**Exercițiu practic:** notebook-ul Jupyter, secțiunea 10

## Test 1: o testare retrospectivă perfectă

- Un start-up prezintă o rețea neuronală cu rMAE 0,70 pentru România, testată prin validare încrucișată cu 5 subeșantioane amestecate
  - Ce cereți?

**Răspuns**

- O testare cronologică pe un an neatins, cu intrări cunoscute la ora 12:00 în ziua $d - 1$: pe datele noastre, doar amestecarea a făcut XGBoost să pară cu 5,4% mai bun.

## Test 2: ce model puneți în producție

- Chronos-2 are cea mai mică MAE dintre modelele individuale
  - Combinația AW-LEAR + Chronos-2 are aceeași MAE
  - Pe care o puneți în producție?

**Răspuns**

- Combinația: aceeași acuratețe (DM, $p = 0{,}491$), dar dacă modelul preantrenat se degradează sau devine indisponibil, LEAR asigură în continuare jumătate din prognoză.

## Test 3: interpretarea valorilor SHAP

- Consumul are o pondere SHAP mică (8,5%)
  - Putem concluziona că acesta nu influențează prețul?

**Răspuns**

- Nu: SHAP explică modelul, nu piața
  - Consumul intră doar cu valoarea din ziua $d - 2$, deja reflectată în prețul de ieri.

# Test 4: pragul de alertă

- Mutarea a 1 MWh vă costă 60 EUR în loc de 30
  - Cum se schimbă pragul de alertă?

**Răspuns**

- Se dublează: C/L crește de la 0,414 la aproximativ dublul acestei valori, deci reacționați numai la vîrfurile mai sigure.

## Test 5: reestimarea

- Echipa de date propune ca modelul să fie antrenat o dată pe an, pentru a economisi efort
  - Ce arată anul de test?

**Răspuns**

- Un model neactualizat un an a fost cu 4,2% mai puțin precis, iar diferența a crescut în ultimele luni
  - O reestimare lunară a XGBoost durează circa 13 de secunde.

# Recapitulare

- Modelele de învățare automată și evaluarea lor
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Compararea modelelor, combinarea lor și costul de calcul
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Erori de evaluare care supraestimează precizia

- Calibrate, rețeaua DNN și XGBoost sînt mai precise decît în cursul 2, dar nu depășesc singure AW-LEAR
  - În medie cu acesta, îl depășesc
- Chronos-2, fără antrenare, este cel mai precis model individual (MAE 20,82, cu 7,6% sub AW-LEAR)
  - Orice model trebuie explicat, validat și reestimat

# Cercetările grupului nostru: învățarea automată pe piața din România

- **Avertizarea timpurie a vîrfurilor de preț** (Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE)
  - Ce a făcut lucrarea: a construit un sistem explicabil de inteligență artificială (AI) pentru PZU din România
  - Rezultat: prețul anterior și consumul rezidual sînt principalii factori ai vîrfurilor (studiul de caz C7)
- **Explicarea prognozelor de preț pe mai multe orizonturi** (Andrei, Pele & Cramer, 2026, PICBE)
  - Ce a făcut lucrarea: a explicat prognozele de învățare automată pentru prețurile orare din România
  - Rezultat: arată ce factori contează la fiecare orizont și în fiecare regim de preț
- **Patru generații de modele pentru prețul energiei** (Andrei, Velev, Toma, Pele & Lessmann, 2024, arXiv 2411.03372)
  - Ce a făcut lucrarea: a comparat patru generații de metode de prognoză a prețurilor energiei, de la modelele statistice la învățarea profundă
  - Utilitate: un reper pentru alegerea familiei de modele
- **Modele fundaționale pentru riscul extrem** (Jheng, Tak, Găman, Mazurencu-Marinescu-Pele & Pele, 2026, ECECSR)
  - Ce a făcut lucrarea: a folosit modele fundaționale preantrenate, fără reantrenare și cu calibrare conformală, pentru prognoza pierderilor extreme pe piețele din Europa Centrală și de Est
- Rezultatele de pe acest diapozitiv sînt cele raportate în lucrări; celelalte cifre din curs provin din calculele noastre.

(Academia de Studii Economice din București; Academia Română, Institutul de Prognoză Economică)

## Lecturi și resurse suplimentare

- **epftoolbox**: rețeaua DNN și modelul LEAR din Lago et al. (2021), cu date deschise pentru evaluare — github.com/jeslago/epftoolbox.
- **XGBoost** și **shap**, documentație: xgboost.readthedocs.io, shap.readthedocs.io.
- **Chronos**, modele fundaționale: github.com/amazon-science/chronos-forecasting.
- **Interpretable Machine Learning** (C. Molnar), gratuit online: christophm.github.io.
- **Acest curs**: cod, date, notebook-uri Jupyter — github.com/danpele/EMQA.
- **Studiul de caz C7** replică pe datele cursului lucrarea despre avertizarea timpurie a vîrfurilor.
- **Exerciții practic**: notebook-ul Jupyter reproduce toate graficele și cifrele din acest curs — notebooks/.

# Bibliografie (1/4)


- Anagnoste, S., Andrei, A.-V., Bolovăneanu, V., Cepoi, C.-O., Clodnitchi, R., Cramer, A.-A., Grecu, R.-A., Lessmann, S., Pele, D. T., Petukhina, A. & Strat, V. A. (2025). The role of AI in (re)shaping energy finance: A systematic literature review. *Energy Strategy Reviews*, 61, 101833. doi:10.1016/j.esr.2025.101833
- Andrei, A.-V., Pele, D.-T. & Cramer, A.-A. (2026). Multi-horizon explainability in energy price forecasting: Disentangling market dynamics and renewable intermittency in Romania's liberalized electricity market. *Proceedings of the International Conference on Business Excellence*, 20(1), 104–117. doi:10.2478/picbe-2026-0014
- Andrei, A.-V., Pele, D.-T., Cramer, A.-A., Amza, A. & Diaconu, D. (2026). Explainable AI-based early warning system for electricity price spikes: Evidence from the Romanian market. *Proceedings of the International Conference on Business Excellence*, 20(1), 4820–4836. doi:10.2478/picbe-2026-0352
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2024). Energy price modelling: A comparative evaluation of four generations of forecasting methods. arXiv:2411.03372
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2026). Energy price modelling: A comparative evaluation of four generations of forecasting methods. Talk, AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026
- Ansari, A. F., Stella, L., Turkmen, C. et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. arXiv:2403.07815
- Ansari, A. F., Shchur, O., Küken, J. et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821
- Bates, J. M. & Granger, C. W. J. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. doi:10.1057/jors.1969.103
- Bergmeir, C. & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213. doi:10.1016/j.ins.2011.12.028

# Bibliografie (2/4)


- Bergstra, J. & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305. jmlr.org/papers/v13/bergstra12a.html
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi:10.1023/A:1010933404324
- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
- Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794. doi:10.1145/2939672.2939785
- Clodnitchi, R. (2026). The role of AI in (re)shaping energy finance: A systematic literature review. Talk, AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026
- Diebold, F. X. & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. doi:10.1016/j.patrec.2005.10.010
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063

# Bibliografie (3/4)


- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. Springer. doi:10.1007/978-0-387-84858-7
- Hsu, P.-H., Hsu, Y.-C. & Kuan, C.-M. (2010). Testing the predictive ability of technical analysis using a new stepwise test without data snooping bias. *Journal of Empirical Finance*, 17(3), 471–484. doi:10.1016/j.jempfin.2010.01.001
- Jheng, S., Tak, R., Găman, Ș., Mazurencu-Marinescu-Pele, M. & Pele, D. T. (2026). Can foundation models manage risk? Zero-shot VaR and ES forecasting with conformal calibration in CEE markets. *Economic Computation and Economic Cybernetics Studies and Research*, 60(2), 267–290. doi:10.24818/18423264/60.2.26.14
- Kingma, D. P. & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*. arXiv:1412.6980
- Kuan, C.-M. (2026). Large-scale multiple inequality testing without data snooping bias. Keynote, AIDA Conference, Bucharest University of Economic Studies, 4 June 2026. github.com/danpele/EMQA/resources/aida2026
- Lago, J., De Ridder, F. & De Schutter, B. (2018). Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221, 386–405. doi:10.1016/j.apenergy.2018.02.069
- Lago, J., Marcjasz, G., De Schutter, B. & Weron, R. (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293, 116983. doi:10.1016/j.apenergy.2021.116983
- Lundberg, S. M., Erion, G., Chen, H. et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. doi:10.1038/s42256-019-0138-9
- Marcjasz, G., Narajewski, M., Weron, R. & Ziel, F. (2023). Distributional neural networks for electricity price forecasting. *Energy Economics*, 125, 106843. doi:10.1016/j.eneco.2023.106843

# Bibliografie (4/4)


- Murphy, A. H. (1977). The value of climatological, categorical and probabilistic forecasts in the cost-loss ratio situation. *Monthly Weather Review*, 105(7), 803–816. doi:10.1175/1520-0493(1977)105<0803:TVOCCA>2.0.CO;2
- Olivares, K. G., Challu, C., Marcjasz, G., Weron, R. & Dubrawski, A. (2023). Neural basis expansion analysis with exogenous variables: Forecasting electricity prices with NBEATSx. *International Journal of Forecasting*, 39(2), 884–900. doi:10.1016/j.ijforecast.2022.03.001
- Romano, J. P. & Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282. doi:10.1111/j.1468-0262.2005.00615.x
- Shapley, L. S. (1953). A value for n-person games. In *Contributions to the Theory of Games II*, 307–317. Princeton University Press. doi:10.1515/9781400881970-018
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15, 1929–1958. jmlr.org/papers/v15/srivastava14a.html
- Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030–1081. doi:10.1016/j.ijforecast.2014.08.008
- Weron, R. (2026). Machine learning for electricity price forecasting. Keynote, AIDA Conference, Bucharest University of Economic Studies, 4 June 2026. github.com/danpele/EMQA/resources/aida2026
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152

# Anexa A: propagarea înapoi a erorii și pasul Adam

$$\frac{\partial \mathcal{L}}{\partial W_2} = \boldsymbol{\delta}\, \mathbf{z}^\top, \quad \boldsymbol{\delta} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{Y}}}$$

$$\frac{\partial \mathcal{L}}{\partial W_1} = \left[ (W_2^\top \boldsymbol{\delta}) \odot \phi'(\mathbf{u}) \right] \mathbf{x}^\top$$

- Regula de derivare a funcțiilor compuse, de la ieșire spre intrări
  - Pentru eroarea absolută, $\partial |y - \hat{y}| / \partial \hat{y} = -\operatorname{sign}(y - \hat{y})$.
- $\mathbf{u} = W_1 \mathbf{x} + \mathbf{b}_1$
  - $\odot$ = produs element cu element
  - Pentru softplus, $\phi'(u) = 1/(1 + e^{-u})$.

(Kingma & Ba, 2015, ICLR; Hastie et al., 2009)

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2$$

$$\theta_k = \theta_{k-1} - \eta \, \frac{m_k / (1 - \beta_1^k)}{\sqrt{v_k / (1 - \beta_2^k)} + \varepsilon}$$

- $g_k$ = gradientul pe grupul de zile $k$
  - $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$ (valori implicite)
  - Fiecare pondere are propriul pas.
- Penalizarea ponderilor adaugă $\lambda\theta$ la $g_k$ (o penalizare pătratică, aici $\lambda = 10^{-5}$).

# Anexa B: de ce valoarea optimă a unei frunze este $-G/(H+\lambda)$

$$\ell\big(Y_i, F_{m-1} + f\big) \approx \ell_i + g_i f(\mathbf{x}_i) + \tfrac{1}{2} h_i f(\mathbf{x}_i)^2$$

$$\sum_j \left[ G_j w_j + \tfrac{1}{2}(H_j + \lambda) w_j^2 \right] + \gamma J, \quad G_j = \textstyle\sum_{i \in R_j} g_i$$

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \qquad \text{scor} = -\tfrac{1}{2} \sum_j \frac{G_j^2}{H_j + \lambda} + \gamma J$$

- Dezvoltare Taylor de ordinul doi a funcției de pierdere în jurul prognozei curente
  - $g_i$, $h_i$ = derivatele de ordinul întîi și al doilea
  - $H_j$ = suma $h_i$ din frunza $j$.
- În fiecare frunză, obiectivul este o parabolă în $w_j$: anulînd derivata, se obține $w_j^*$.
- Cîștigul unei împărțiri, de pe diapozitivul despre arborele de regresie, este scorul dinainte minus scorul de după împărțire.
- Pentru eroarea absolută, $h_i = 0$
  - XGBoost calculează atunci valorile frunzelor printr-o căutare unidimensională.

(Chen & Guestrin, 2016, KDD)

# Anexa C: valori SHAP exprimate în EUR/MWh

$$\hat{P} = m + s \sinh\left(\phi_0 + \sum_j \phi_j\right), \qquad P_0 = m + s \sinh \phi_0$$

$$\phi_j^{\text{EUR}} = \phi_j \frac{\hat{P} - P_0}{\sum_k \phi_k} \;\Rightarrow\; \sum_j \phi_j^{\text{EUR}} = \hat{P} - P_0$$

- Arborii prognozează prețul transformat cu asinh
  - $m$, $s$ = mediana și abaterea absolută mediană (MAD), scalată, a prețurilor de antrenare.
- Valorile SHAP se adună pe această scară
  - Pentru a raporta în euro, diferența $\hat{P} - P_0$ se împarte proporțional cu $\phi_j$.
- Semnele și ordinea nu se schimbă
  - Contribuțiile se adună exact la prognoza în EUR/MWh.

(Lundberg et al., 2020, Nat. Mach. Intell.)

# Anexa D: spațiile de căutare și setările alese

| Setare DNN | Valori încercate | Aleasă |
|---|---|---|
| neuroni, stratul 1 | 64, 128, 256, 512 | 512 |
| neuroni, stratul 2 | 0, 32, 64, 128, 256 | niciunul |
| funcția de activare | ReLU, softplus | softplus |
| dropout | 0,0; 0,1; 0,2; 0,3 | 0,1 |
| rata de învățare | $3 \cdot 10^{-4}$; $10^{-3}$; $3 \cdot 10^{-3}$ | $3 \cdot 10^{-4}$ |
| penalizare L1, intrări | 0; $10^{-3}$; $10^{-2}$; $10^{-1}$ | 0 |
| grup (zile) | 32, 64, 128 | 64 |
| consum/RES/fund. | da sau nu | da/da/da |

| Setare XGBoost | Valori încercate | Aleasă |
|---|---|---|
| arbori | 300, 600, 1000, 1500 | 1500 |
| rata de învățare $\eta$ | 0,02; 0,05; 0,10 | 0,02 |
| adîncimea | 3, 4, 5, 6, 8 | 8 |
| ponderea min. în frunză | 1, 5, 20, 50 | 5 |
| rînduri pe arbore | 0,6; 0,8; 1,0 | 0,8 |
| $\lambda$ | 0,1; 1,0; 10,0 | 0,1 |
| funcția de pierdere | pătrat, abs., Huber | absolută |

⊡ 24 de extrageri aleatoare pe model (cu valoare inițială fixată) și setarea din cursul 2; aleasă = MAE minimă în anul de validare.

(Bergstra & Bengio, 2012, JMLR)