

Analiza cantitativă a piețelor de energie

Cursul 7: Învățarea automată pe piețele de energie

Prof. dr. Daniel Traian PELE

Academia de Studii Economice din București, Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

Obiectivele cursului

- Organizarea corectă a unui experiment de învățare automată (ML)
  - Eșantioanele de antrenare, de validare și de test se succed în timp
  - Prognoza folosește numai informația cunoscută la ora 12:00 a Europei Centrale (CET) în ziua dinaintea livrării
- Construirea și calibrarea a două modele pentru cele 24 de prețuri orare ale zilei următoare
  - O rețea neuronală profundă (DNN)
  - Un ansamblu de arbori de decizie construiți secvențial (gradient boosting)
  - În plus, un model fundațional preantrenat
- Compararea cu modelele de referință din cursul 2, pe același an de test
  - Eroarea absolută medie (MAE), rădăcina erorii pătratice medii (RMSE), MAE relativă (rMAE) și testul Diebold–Mariano (DM)
  - Combinarea modelelor de învățare automată cu modelele statistice
- Explicarea prognozelor, anticiparea vîrfurilor de preț și a prețurilor negative
  - Capcanele care fac un model să pară mai bun decît este

Abrevieri (1/2)

AI	inteligență artificială
ARIMA	model autoregresiv integrat cu medie mobilă
ARX	model autoregresiv cu variabile exogene
AUC	aria de sub curba ROC
AW	medierea prognozelor obținute pe mai multe ferestre de calibrare
AW-ARX	ARX mediat pe ferestre de calibrare
AW-LEAR	LEAR mediat pe ferestre de calibrare
CET	ora Europei Centrale
CPU	unitatea centrală de procesare (nucleu de procesor)
DM	testul Diebold–Mariano
DNN	rețea neuronală profundă
DST	ora de vară
ENTSO-E	Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică
ETC	titlu tranzacționat la bursă, garantat cu mărfuri (exchange-traded commodity)
EUA	certificat de emisii al UE (1 t CO_2)
EUR	euro
FWER	rata erorii la nivelul familiei de ipoteze
GBM	gradient boosting (ansamblu de arbori de decizie construiți secvențial)
GW	gigawatt
ISE	Institutul Fraunhofer pentru Sisteme de Energie Solară
LASSO	operatorul de contracție și selecție în normă absolută
LEAR	autoregresie estimată cu LASSO

Abrevieri (2/2)

LLM	model mare de limbaj
MAD	abaterea absolută mediană
MAE	eroarea absolută medie
ML	învățare automată
MLP	perceptron multistrat (rețea neuronală directă)
MW	megawatt
MWh	megawatt-oră
OPCOM	operatorul pieței de energie electrică și de gaze naturale din România
PZU	piața pentru ziua următoare
RC	testul Reality Check (testul de selecție abuzivă al lui White, 2000)
ReLU	unitate liniară rectificată (rectified linear unit)
RES	surse regenerabile de energie (aici: eolian + solar)
rMAE	MAE relativă (MAE a modelului / MAE a modelului naiv)
RMSE	rădăcina erorii pătratice medii
RO	România (zonă de ofertare)
ROC	caracteristica de operare a receptorului (receiver operating characteristic)
SHAP	explicații aditive bazate pe valorile Shapley (SHapley Additive exPlanations)
SMAPE	eroarea procentuală absolută medie simetrică
SPA	abilitate predictivă superioară (testul lui Hansen, 2005)
TSO	operator de transport și de sistem
UE	Uniunea Europeană
XGBoost	eXtreme Gradient Boosting (bibliotecă de programe)

Aceleași date și același an de test ca în cursul 2, plus un an de validare

Element	Alegerea din acest curs
Variabila prognozată	prețul orar de pe piața pentru ziua următoare (PZU) din România (RO), administrată de operatorul pieței de energie electrică și de gaze naturale (OPCOM)
Variabile explicative (ca în cursul 2)	prețurile pînă în ziua $d-1$; consumul, producția eoliană și solară, hidro, nucleară și importul net pînă în ziua $d-2$, de la Rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică (ENTSO-E); prețul certificatelor de emisii (EUA) ale Uniunii Europene (UE), printr-un titlu tranzacționat la bursă (ETC)
Antrenare	de la 8 ianuarie 2022; crește cu o lună la fiecare reestimare
Anul de validare	1 noiembrie 2024 – 31 octombrie 2025: folosit numai pentru alegerea setărilor modelelor
Anul de test	1 noiembrie 2025 – 31 octombrie 2026, 8 760 de ore, modele reestimate lunar

- **Date pînă la 31 octombrie 2026**
  - Descărcate la 4 noiembrie 2026 de pe energy-charts.info (Fraunhofer ISE) și Yahoo Finance
- **Modelele de referință**: prognozele din cursul 2, preluate din fișierele acestuia
  - Modelul naiv; modelul autoregresiv cu variabile exogene (ARX); operatorul de contracție și selecție în normă absolută (LASSO)
  - Autoregresia estimată cu LASSO (LEAR); ARX mediat pe mai multe ferestre de calibrare (AW-ARX), LEAR la fel (AW-LEAR); ansamblul de 4 modele

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Învățarea automată cîștigă flexibilitate, dar plătește prin varianță

- **Pe scurt:** Un model flexibil poate învăța praguri și interacțiuni pe care LEAR nu le vede, dar poate învăța și zgomotul din anii de antrenare.

$$\hat{\theta} = \arg\min_{\theta} \underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell\big(Y_i, f_\theta(\mathbf{x}_i)\big)}_{\text{potrivirea pe zilele de antrenare}} + \underbrace{\lambda\,\Omega(\theta)}_{\text{penalizare}}$$

- **unde**
  - f_θ = modelul, cu parametrii θ
  - $\mathbf{x}_i$ = variabilele cunoscute la închiderea licitației
  - Y_i = prețul
  - ℓ = funcția de pierdere, aici eroarea absolută
  - Ω = complexitatea modelului, iar λ = ponderea ei.

- **Cît de flexibile sînt modelele noastre?**
  - LEAR: cel mult 247 de coeficienți pentru fiecare oră
  - Rețeaua DNN: 141 336 de parametri, pentru 1 727 de zile de antrenare la ultima reestimare

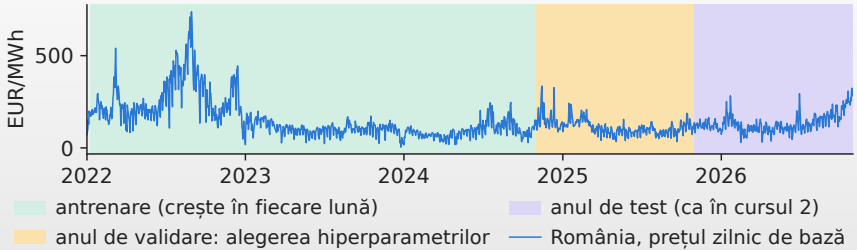
- **Consecința**
  - Eroarea pe datele de antrenare nu spune nimic despre viitor; modelul poate fi judecat numai pe date pe care nu le-a văzut

- **În practică:** întrebați furnizorul de prognoze cîți parametri are modelul pentru fiecare zi de istoric și pe ce zile a fost măsurată eroarea.

(Hastie, Tibshirani & Friedman, 2009; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 1

Trei eșantioane în ordine cronologică: antrenare, validare, test



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: preț zilnic de bază, 2022-01-01 - 2026-10-31.

- **Anul de validare**: se compară 25 de setări pentru fiecare model, reestimate la fiecare 3 luni
  - Setarea cu cea mai mică MAE este fixată înainte de începutul anului de test
- **Anul de test**: modelele sînt reestimate la începutul fiecărei luni, pe toate zilele anterioare
  - Nu se folosește pentru nicio alegere; este același an ca în cursul 2, deci erorile se pot compara direct

- **În practică:** tratați anul de test ca pe un plic sigilat, deschis o singură dată, după toate alegerile.

(Bergmeir & Benítez, 2012, Inf. Sci.; Lago et al., 2021, APEN)

EMQA_L7_split_ml

Hiperparametrii se aleg prin căutare aleatoare pe anul de validare

- **Pe scurt:** Setări precum numărul de neuroni sau de arbori nu sînt estimate de model; încercăm mai multe și o păstrăm pe cea care prognozează cel mai bine zilele nevăzute.

$$\gamma^* = \arg \min_{\gamma \in \{\gamma_0, \ldots, \gamma_{24}\}} \frac{1}{24\,|\mathcal{V}|} \sum_{d \in \mathcal{V}} \sum_{h=0}^{23} \left| P_{d,h} - \hat{P}_{d,h}(\gamma) \right|$$

- **unde**
  - γ = o setare (vectorul hiperparametrilor)
  - γ_0 = setarea din cursul 2, celelalte extrase aleator
  - $\mathcal{V}$ = zilele anului de validare
  - $\hat{P}_{d,h}(\gamma)$ = prognoza cu setarea γ.

- **De ce aleator și nu pe o grilă completă**
  - Doar cîteva setări contează cu adevărat; extragerile aleatoare le acoperă mai bine, cu același număr de încercări
- **Bugetul nostru**
  - 24 de setări aleatoare și setarea din cursul 2, pentru fiecare dintre cele două modele
  - 7,3 minute pe un nucleu al unității centrale de procesare (CPU)

- **În practică:** o căutare modestă, dar documentată, este suficientă
  - O căutare fără un eșantion de validare separat nu este o căutare, ci o scurgere de informație.

(Bergstra & Bengio, 2012, JMLR)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

O rețea neuronală înlănțuie regresii, fiecare urmată de o funcție neliniară

- **Pe scurt:** Fiecare neuron transformă neliniar o combinație liniară a intrărilor; stratul de ieșire dă deodată cele 24 de prețuri ale zilei d.

$$\mathbf{z} = \phi\big(W_1 \mathbf{x}_d + \mathbf{b}_1\big), \qquad \hat{\mathbf{Y}}_d = W_2\,\mathbf{z} + \mathbf{b}_2 \in \mathbb{R}^{24}$$
$$\phi(u) = \max(0, u) \quad \text{sau} \quad \phi(u) = \ln(1 + e^u)$$

- **unde**
  - $\mathbf{x}_d$ = intrările zilei d (prețuri, consum, eolian și solar, variabile fundamentale, ziua săptămînii)
  - W_1, W_2 = ponderi, $\mathbf{b}_1, \mathbf{b}_2$ = termeni liberi
  - ϕ = unitatea liniară rectificată (ReLU) sau varianta netedă (softplus)
  - $\hat{\mathbf{Y}}_d$ = prețurile transformate cu asinh (cursul 2).

- **Rețeaua noastră** (aleasă pe anul de validare)
  - 251 de intrări, un strat ascuns de 512 de neuroni, funcția softplus, 24 de ieșiri
  - 141 336 de parametri; rețelele cu două straturi au fost mai slabe la validare
- **Mai bună decît în cursul 2**
  - Perceptronul multistrat (MLP): MAE 25,54; rețeaua de acum: 22,95 EUR/MWh

- **În practică:** o rețea neuronală este o regresie cu mult mai mulți coeficienți: are nevoie de aceeași disciplină a datelor, nu de mai puțină.

(Lago, Marcjasz, De Schutter & Weron, 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Antrenarea: pași mici împotriva erorii, opriți la timp

- **Pe scurt:** Ponderile se modifică puțin, în direcția care reduce eroarea pe un grup aleator de zile; ne oprim cînd eroarea pe zilele mai recente nu mai scade.

$$\mathcal{L}(\theta) = \frac{1}{24\,|B|} \sum_{d \in B} \sum_{h=0}^{23} \left| Y_{d,h} - \hat{Y}_{d,h}(\theta) \right|$$

$$\theta \leftarrow \theta - \eta\, \widehat{\nabla \mathcal{L}}$$

- **unde**
  - B = un grup de 64 de zile (mini-batch)
  - η = rata de învățare ($3 \cdot 10^{-4}$)
  - $\widehat{\nabla \mathcal{L}}$ = gradientul, rescalat prin metoda Adam
  - O epocă = o parcurgere a tuturor zilelor de antrenare.

- **Oprirea timpurie (early stopping)**
  - Antrenare pe primele 85% din zile, urmărirea erorii pe ultimele 15%
  - Se păstrează epoca cea mai bună, apoi rețeaua se reestimează pe toate zilele, cu același număr de epoci

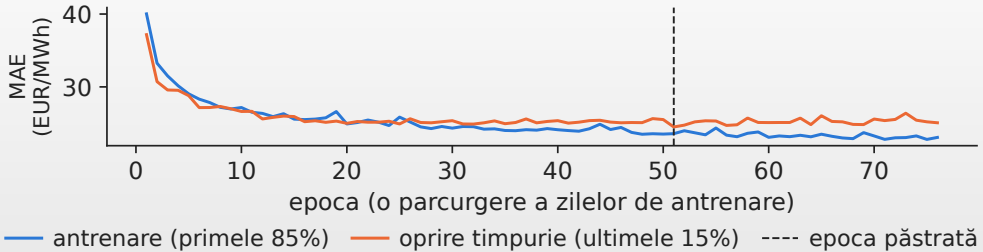
- **Pe datele noastre**
  - Epocile păstrate: mediana 56, între 23 și 92 (12 reestimări × 4 inițializări)
  - Dropout: în timpul antrenării, fiecare neuron este dezactivat aleator, cu probabilitatea 0,1

- **În practică:** regula de oprire folosește numai zile din trecut: face parte din model și se verifică la fel ca restul.

(Kingma & Ba, 2015, ICLR; Srivastava et al., 2014, JMLR)

Exercițiu practic: notebook-ul Jupyter, secțiunea 2

Oprirea timpurie: ne oprim cînd eroarea pe zilele recente nu mai scade



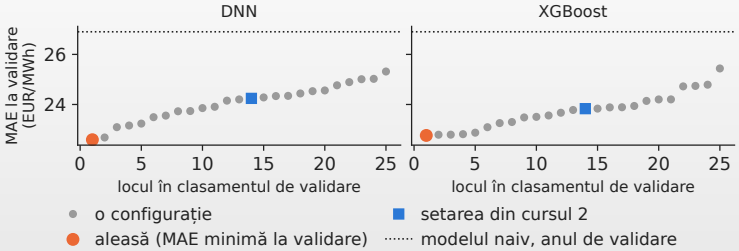
Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: rețeaua DNN aleasă, reestimarea pentru 2026-10, inițializarea 1.

- Reestimarea pentru octombrie 2026: eroarea pe ultimele 15% din zile este minimă la epoca 51
  - 24,50 EUR/MWh; antrenarea se oprește la epoca 76
- După acest punct, rețeaua reproduce mai bine trecutul, dar mai slab zilele recente: începe să memoreze

- **În practică:** cereți furnizorului această curbă: fără ea, rețeaua poate să fi memorat trecutul.

(calcule proprii; rețeaua DNN aleasă, inițializarea 1) EMQA_L7_learning_curve

Căutarea aleatoare reduce eroarea de validare a ambelor modele



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de validare 2024-11-01 - 2025-10-31, reestimare trimestrială.

- **DNN**: cea mai bună setare are MAE 22,59 EUR/MWh; setarea din cursul 2, 24,24, locul 14 din 25
  - **eXtreme Gradient Boosting (XGBoost)**: 22,76 față de 23,83 (locul 14)
- Toate cele 25 de setări, la ambele modele, sînt mai precise decît modelul naiv (26,90 EUR/MWh)

- **În practică:** prevedeți un an de validare pentru calibrarea oricărui model de învățare automată.

(calcule proprii; anul de validare 1 noiembrie 2024 – 31 octombrie 2025)

EMQA_L7_search

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Un arbore de regresie împarte intrările în căsuțe, cu cîte un preț fiecare

- **Pe scurt:** Un arbore pune întrebări cu răspuns da/nu; fiecare frunză finală conține o valoare, deci pragurile și interacțiunile apar de la sine.

$$f(\mathbf{x}) = \sum_{j=1}^{J} w_j \mathbb{1}\{\mathbf{x} \in R_j\}$$

$$\text{Gain} = \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma$$

- **unde**
  - R_j = frunza j, w_j = valoarea ei
  - G, H = sumele derivatelor de ordinul 1 și 2 ale pierderii, la stînga (L) și la dreapta (R)
  - λ, γ = penalizări
  - Se alege împărțirea cu cel mai mare cîștig.

- **Pe datele noastre** (reestimarea pentru octombrie 2026)
  - Primul arbore întreabă: prețul din $d-1$, aceeași oră, este sub 119,5 EUR/MWh?
  - 233 de frunze; modelul adună 1 500 de arbori

- **În practică:** un arbore gîndește ca un trader: dacă ieri prețul a trecut de un prag, diseară urmează o primă.

(Chen & Guestrin, 2016, KDD; Hastie et al., 2009)

Exercițiu practic: notebook-ul Jupyter, secțiunea 3

Gradient boosting: fiecare arbore nou corectează erorile rămase

- **Pe scurt:** Potrivim un arbore mic pe ceea ce este încă greșit, îl adăugăm cu o pondere mică și repetăm de o mie de ori.

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta\, f_m(\mathbf{x}), \qquad w_j^* = -\frac{G_j}{H_j + \lambda}$$

$$\min \sum_i \ell\big(Y_i, F_M(\mathbf{x}_i)\big) + \sum_m \Big(\gamma J_m + \tfrac{\lambda}{2} \sum_j w_{mj}^2\Big)$$

- **unde**
  - F_m = prognoza după m arbori
  - f_m = arborele m, cu J_m frunze
  - η = rata de învățare
  - w_j^* = valoarea optimă a frunzei j (anexa B)
  - ℓ = eroarea absolută.

- **Setarea aleasă pe anul de validare**
  - 1 500 de arbori de adîncime 8, $\eta = 0{,}02$, fiecare pe o fracțiune 0,8 din rînduri
- **Anul de test**
  - MAE 23,26 EUR/MWh; modelul gradient boosting (GBM) necalibrat din cursul 2: 24,05 (DM: $p < 0{,}001$)
  - AW-LEAR (22,53) rămîne mai precis (DM: $p = 0{,}016$)

- **În practică:** calibrarea contează mai mult decît programul: același tip de arbori a cîștigat aproape un euro pe MWh prin setări bune.

(Friedman, 2001, Ann. Stat.; Chen & Guestrin, 2016, KDD)

Exercițiu practic: notebook-ul Jupyter, secțiunea 3

Modelele fundaționale prognozează prețurile fără nicio antrenare

- **Pe scurt:** Modelele Chronos au fost antrenate de Amazon pe colecții mari de serii de timp; noi le dăm doar prețurile recente și le cerem următoarele 24 de ore (fără reantrenare, zero-shot).

$$\left(\hat{q}^{\tau}_{d,h}\right)^{\tau=0{,}1;\,0{,}5;\,0{,}9}_{h=0,\ldots,23} = g\left(P_{t-2047},\ldots,P_t\right)$$

- **unde**
  - $P_{t-2047},\ldots,P_t$ = ultimele 2048 de prețuri orare, pînă la sfîrșitul zilei $d-1$ (85 de zile)
  - g = rețeaua preantrenată, folosită ca atare
  - $\hat{q}^{\tau}$ = cuantilele prognozate
  - Prognoza punctuală este mediana $\hat{q}^{0,5}$.

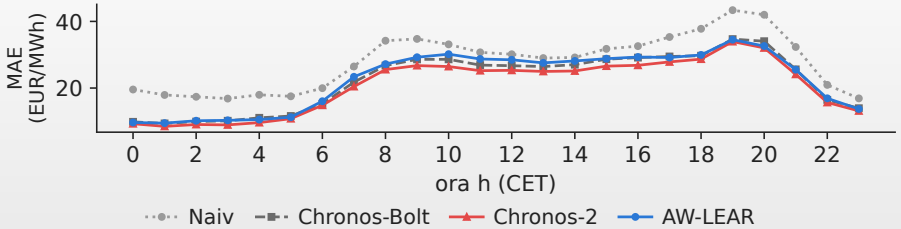
- **Anul de test**, numai cu prețuri, fără variabile fundamentale
  - Chronos-2: MAE 20,82; Chronos-Bolt: 22,15; AW-LEAR: 22,53 EUR/MWh
  - Chronos-2 este mai precis decît AW-LEAR: DM, $p < 0{,}001$; în toate cele 24 de ore
- **Robustețe**
  - În anul de validare: Chronos-2 21,05, cea mai bună rețea DNN calibrată 22,59
  - Publicat în octombrie 2025, înaintea anului de test

- **În practică:** testați un model fundațional înainte de a construi propria rețea: costă puțin, iar aici a fost cel mai precis model individual.

(Ansari et al., 2024, TMLR; Ansari et al., 2025, arXiv)

Exercițiu practic: notebook-ul Jupyter, secțiunea 4

Chronos-2 este mai precis decît AW-LEAR în fiecare oră a zilei



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: anul de test 2025-11-01 - 2026-10-31; fără reantrenare, context = ultimele 2048 de prețuri orare.

- Chronos-Bolt, mai mic și mai vechi, este la egalitate cu AW-LEAR (DM: $p = 0{,}220$)
- Intervalul 10%–90% al modelului Chronos-2 conține 76,5% din prețuri, nu 80%: este prea îngust

- **În practică:** folosiți mediana
  - Recalibrați intervalele (cursul 2) înainte de a dimensiona riscul cu ele.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026) EMQA_L7_foundation_hour

AIDA 2026: DNN întrece LEAR, modelele preantrenate concurează

- **R. Weron, conferință invitată** (4 iunie 2026, diapozitive)
  - Evoluția modelelor: ARX, medierea pe ferestre, LEAR, rețele profunde și interpretabile
  - Modele preantrenate, fără reantrenare (zero-shot), față de LEAR și de rețele DNN distribuționale, test 2021–2025
- **Rețele profunde și interpretabile**
  - Evaluarea deschisă epftoolbox: rețeaua DNN are rMAE mai mică decît LEAR pe toate cele cinci piețe (Lago et al., 2021)
  - NBEATSx: blocurile de trend, sezonalitate și variabile exogene fac rețeaua interpretabilă (Olivares et al., 2023)
- **Rezultate zero-shot** (RMSE, conform diapozitivelor)
  - 2022: LEAR + predicție conformală 45,71, Chronos 2 41,07, TabPFN 3.0 ts 34,39
  - 2025: 20,38, 20,58 și 17,66; o versiune TabPFN a fost cea mai bună în fiecare an
- **Legătura cu anul nostru de test**
  - Chronos-2, fără reantrenare, este cel mai precis model individual (MAE 20,82, față de 22,53 la AW-LEAR)
  - Clasamentele se schimbă: TabPFN 2.0 a avut RMSE 68,85 în 2022 și 17,52 în 2025

- **În practică:** păstrați LEAR ca reper și testați modelele zero-shot alături de el, pe mai mulți ani.

(diapozitivele AIDA 2026, București; lucrări: Lago et al., 2021, APEN; Olivares et al., 2023, IJF)

AIDA 2026: patru generații de modele pe 27 de serii europene de prețuri

- **A.-V. Andrei et al., prezentare** (3 iunie 2026, diapozitive)
  - 11 modele, patru generații: econometrie, de ex. modelul autoregresiv integrat cu medie mobilă (ARIMA); învățare profundă; transformere; modele mari de limbaj (LLM) preantrenate: Chronos, TimesFM
- **Date și validare walk-forward**
  - Prețuri angro din 27 de țări ale Uniunii Europene (UE), Ember (ENTSO-E)
  - 96 de pași la intrare și 96 la ieșire; antrenare 2000 de ore (83 de zile), test 500 de ore (20 de zile)
  - Eroarea procentuală absolută medie simetrică (SMAPE); scor $(100 \times \text{SMAPE} + \text{RMSE})/2$
- **Rezultate** (locul între cele 11 modele)
  - PatchTST (un transformer) este pe primul sau al doilea loc în toate cele 27 de țări
  - România: PatchTST 1, TimesFM 2, Chronos 8, ARIMA 9
  - Germania: PatchTST 1, TimesFM 5, Chronos 10
  - Cîștigurile depind de model, nu sînt uniforme în generația a patra
- **Legătura cu acest curs**
  - Pe prețurile din România, Chronos-2 (2025) este cel mai bun model individual (MAE 20,82)

În practică: comparați generațiile de modele prin validare walk-forward, pe mai multe piețe, înainte de a alege.

(diapozitivele AIDA 2026, București; lucrare: Andrei et al., 2024, arXiv)

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Clasamentul: Chronos-2 este cel mai bun model individual

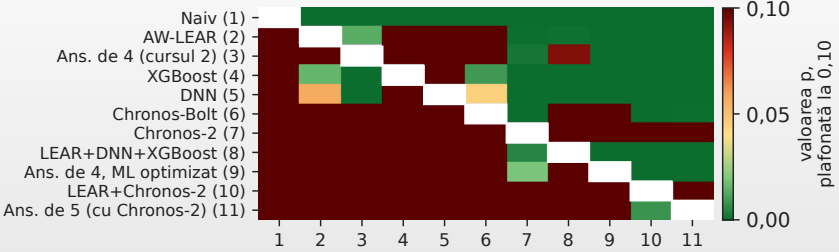
Model	MAE	RMSE	rMAE	față de AW-LEAR, %	DM, p
Naiv	27,82	44,54	1,000	−23,5	–
AW-ARX	22,30	36,34	0,802	+1,0	0,203
AW-LEAR	22,53	36,35	0,810	+0,0	–
Ansamblul de 4 (cursul 2)	22,13	35,76	0,795	+1,8	0,014
GBM (cursul 2)	24,05	37,73	0,864	−6,7	1,000
MLP (cursul 2)	25,54	40,05	0,918	−13,3	1,000
XGBoost, calibrat	23,26	36,94	0,836	−3,2	0,984
DNN, calibrată	22,95	36,42	0,825	−1,8	0,944
Chronos-Bolt, fără antrenare	22,15	35,65	0,796	+1,7	0,220
Chronos-2, fără antrenare	20,82	34,32	0,748	+7,6	<0,001
AW-LEAR + DNN + XGBoost	21,97	35,42	0,790	+2,5	0,001
AW-ARX + AW-LEAR + DNN + XGBoost	21,69	35,25	0,779	+3,8	<0,001
AW-LEAR + Chronos-2	20,81	34,11	0,748	+7,6	–
Ansamblul de 5 (cu Chronos-2)	21,12	34,50	0,759	+6,3	<0,001

- Rădăcina erorii pătratice medii (RMSE); MAE relativă (rMAE) = MAE / MAE a modelului naiv; verde = mai precis, pe fiecare coloană.
- DM, p: test unilateral că modelul este mai precis decît AW-LEAR (eroarea absolută medie zilnică, variantă Newey–West, ca în cursul 2).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 5

Testele DM: combinațiile cu ML depășesc semnificativ AW-LEAR



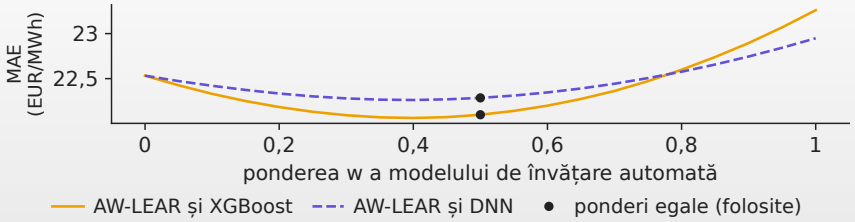
Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 365 de zile; valori p unilaterale.

- AW-LEAR + DNN + XGBoost este mai precis decît AW-LEAR ($p = 0{,}001$)
  - Cu AW-ARX adăugat, MAE scade la 21,69, sub ansamblul din cursul 2 ($p < 0{,}001$)
- Adăugarea AW-LEAR la Chronos-2 nu schimbă nimic ($p = 0{,}491$): în zilele dificile, cele două modele greșesc asemănător

(calcule proprii; teste DM unilaterale)

EMQA_L7_dm_matrix

Media funcționează pentru că erorile nu sînt identice



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; ilustrare, ponderea nu se alege pe anul de test.

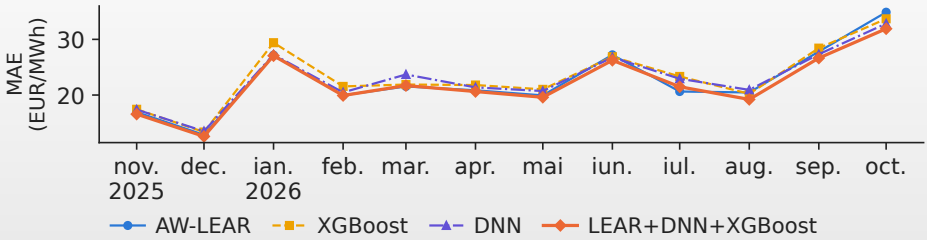
- Var $\left(\frac{e_1+e_2}{2}\right) = \frac{1}{4}(\sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$: dacă $\rho < 1$, media greșește mai puțin (e = eroarea, σ = abaterea ei standard, ρ = corelația)
- Corelația erorilor cu AW-LEAR: 0,94 (DNN), 0,89 (XGBoost)
  - Ponderile egale sînt aproape la fel de bune ca ponderea optimă văzută ulterior (0,40)

- **În practică:** faceți media cu ponderi egale înainte de a estima ponderi „inteligente”.

(Bates & Granger, 1969; calcule proprii)

EMQA_L7_combo_weight

Lunar, combinația este mai precisă decît AW-LEAR în 10 din 12 luni



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

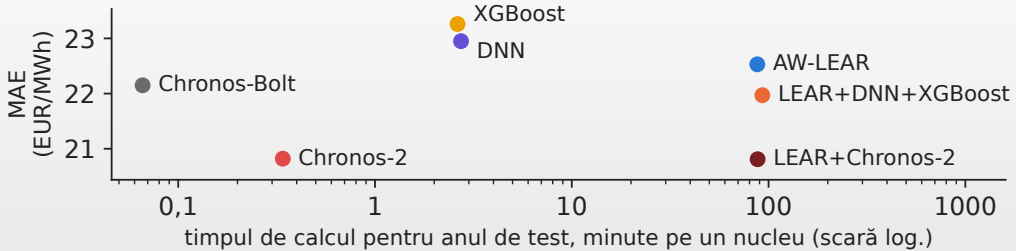
- Luate separat, XGBoost și DNN depășesc AW-LEAR fiecare doar în 3 luni
  - În medie cu acesta, în 10 luni
- Toate modelele greșesc mai mult în aceleași luni (ianuarie, iunie, octombrie): zilele dificile sînt dificile pentru toate

- **În practică:** raportați comitetului de risc acuratețea lună de lună, nu doar media anuală.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_monthly_ml

Costul de calcul: LEAR zilnic este cel mai scump, ML costă minute



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; un nucleu de procesor.

- Anul de test, pe un nucleu: AW-LEAR 87,6 min (365 de zile × 3 ferestre × 24 de ore)
  - XGBoost 2,6 min, DNN 2,7 min, Chronos-2 0,3 min
- Costuri ascunse: căutarea setărilor (7,3 min), preantrenarea Chronos, oamenii care operează fluxul

- **În practică:** comparați modelele după eroare raportată la costul total de utilizare, nu doar după eroare.

(calcule proprii; timpi măsurați pe un nucleu al unui laptop cu 18 nuclee)

EMQA_L7_cost_gain

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Valorile Shapley descompun fiecare prognoză în contribuțiile variabilelor

- **Pe scurt:** Contribuția unei variabile este efectul ei mediu atunci cînd este adăugată în model, calculat pe toate ordinile posibile de adăugare a variabilelor.

$$\phi_j = \sum_{S \not\ni j} \frac{|S|!\,(p-|S|-1)!}{p!} \Big[v(S \cup \{j\}) - v(S) \Big]$$

$$\hat{f}(\mathbf{x}) = \phi_0 + \sum_j \phi_j$$

- **unde**
  - ϕ_j = valoarea variabilei j după metoda explicațiilor aditive bazate pe valorile Shapley (SHAP)
  - S = o submulțime a celorlalte variabile
  - $v(S)$ = prognoza așteptată cînd se cunoaște doar S
  - ϕ_0 = prognoza medie
  - $p = 20$ de variabile.

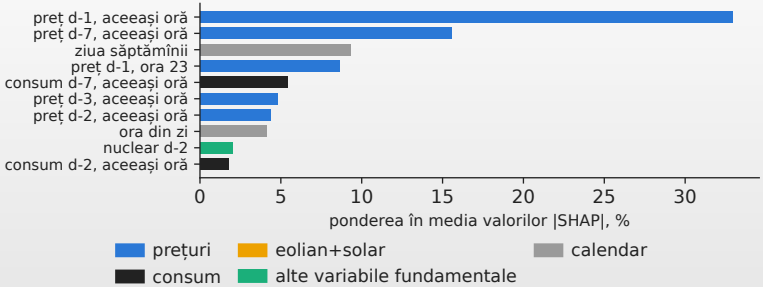
- **De ce valorile Shapley**
  - Singura împărțire echitabilă în sensul teoriei jocurilor; se adună exact la prognoză
- **Pe datele noastre**
  - XGBoost, 8 760 de ore de test; cea mai mare diferență dintre $\hat{f}$ și $\phi_0 + \sum \phi_j$: 0,000009
  - Prețurile din zilele anterioare au 69,3% din contribuția totală

- **În practică:** cereți explicația fiecărei alerte, nu doar un clasament global.

(Shapley, 1953; Lundberg et al., 2020, Nat. Mach. Intell.)

Exercițiu practic: notebook-ul Jupyter, secțiunea 6

Ce determină prognoza arborilor: prețul de ieri, la aceeași oră



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

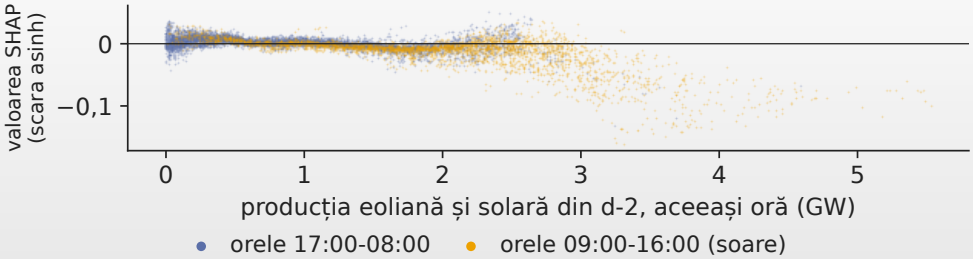
- Ponderi în media $|\phi|$: prețul din $d-1$, aceeași oră (32,9%), din $d-7$ (15,6%), ziua săptămînii (9,3%)
- Consum 8,5%, eolian și solar 2,5%: cunoscute doar pînă în $d-2$, deci informații vechi

- **În practică:** cumpărați întîi intrări mai bune: prognozele operatorului de transport și de sistem (TSO).

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_shap_global

Producția eoliană și solară scade prețul doar în orele în care este mare



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

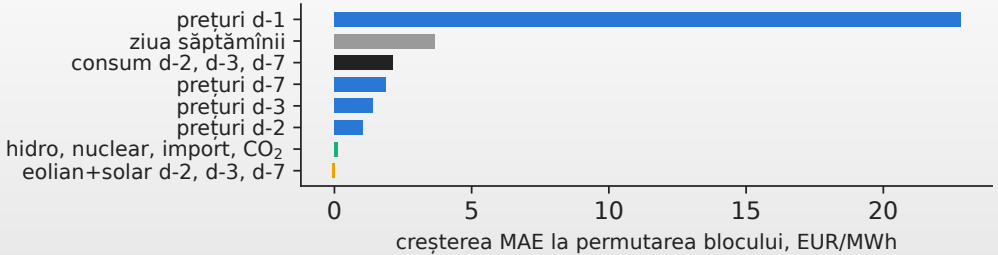
- Fiecare punct este o oră din anul de test
  - Mai multă producție eoliană și solară în $d-2$ înseamnă o contribuție mai negativă (corelație $-0{,}64$)
- Efectul apare peste circa 2 gigawați (GW): un prag pe care un model liniar nu îl poate exprima

- **În practică:** un dezvoltator solar vede aici reducerea de preț la care contribuie propria producție.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_shap_res

Rețeaua neuronală se bazează și mai mult pe prețurile de ieri



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

- Importanța prin permutare I_b = creșterea MAE cînd blocul b este amestecat între zilele de test
  - 5 permutări, metodă valabilă pentru orice model
- Prețurile din $d-1$: $+22{,}82$ EUR/MWh
  - Ziua săptămînii $+3{,}66$, consumul $+2{,}12$, producția eoliană și solară $-0{,}08$

- **În practică:** monitorizați întîi fluxul prețurilor din $d-1$: fără el, rețeaua cedează.

(Breiman, 2001, Mach. Learn.; calcule proprii)

EMQA_L7_perm_dnn

Finanțele energiei folosesc învățarea automată, dar rar o explică

- **R. Clodnitchi, prezentare** (3 iunie 2026, diapozitive)
  - Analiză sistematică a literaturii despre inteligența artificială (AI) în finanțele energiei (Anagnoste et al., 2025, *Energy Strategy Reviews*)
  - Circa 700 de articole din Web of Science, 232 reținute (evaluate colegial, 2020–2025), pe șase piloni ai finanțelor energiei
- **Unde se folosește AI** (ponderea lucrărilor cu AI/ML)
  - Mecanisme de preț 100%, derivate pe energie 100%, piețe energetice și financiare 97,5%, gestiunea riscului 93,0%
  - Finanțe verzi 60,4%; finanțele corporative ale firmelor de energie 0% (numai econometrie pe date panel)
- **Ce lipsește**
  - AI explicabilă: 19,6% din lucrările despre derivate, 0–5% în ceilalți piloni
  - Domină rețelele neuronale: 88,2% din lucrările despre derivate, 72,1% în gestiunea riscului
  - Direcția propusă: AI explicabilă și învățare automată cauzală, pentru autoritățile de reglementare și evaluarea politicilor
- **Legătura cu acest curs**
  - Graficele SHAP și de permutare din această secțiune sînt tipul de explicație pe care analiza îl găsește rar

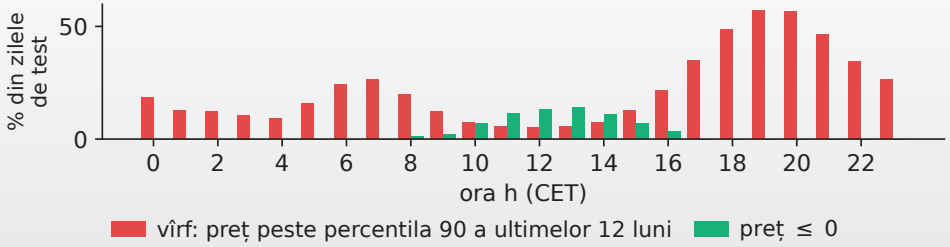
În practică: cereți explicația odată cu prognoza: autoritățile și consiliile de administrație o vor cere.

(diapozitivele AIDA 2026, București; lucrare: Anagnoste et al., 2025, ESR)

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Vîrfurile de preț apar seara, prețurile negative la prînz



Sursa: energy-charts.info (Fraunhofer ISE): prețuri OPCOM. Date: anul de test 2025-11-01 - 2026-10-31.

- **Vîrf de preț**: preț peste θ, percentila 90 a prețurilor orare din cele 12 luni dinaintea lunii de livrare
  - θ între 166,8 și 202,4 EUR/MWh; 22,1% din orele de test sînt vîrfuri, cele mai multe la ora 19 (57,0% din zile)
- **Preț $\leq$ 0**: 255 de ore, în 53 de zile din anul de test, mai ales în jurul orei 13

- **În practică:** o baterie se încarcă la prînz și se descarcă la orele 19–20: cele două evenimente sînt chiar modelul ei de afaceri.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026) EMQA_L7_events_hour

Clasificarea vîrfurilor: o prognoză bună de preț le detectează deja

- **Pe scurt:** Un clasificator dă probabilitatea ca o oră să fie un vîrf; judecăm cît de bine ordonează orele și cît de corecte sînt probabilitățile lui.

$$\hat{\pi}_{d,h} = \Pr\left(P_{d,h} > \theta_d \mid \mathbf{x}_{d,h}\right)$$

$$\text{Brier} = \frac{1}{n}\sum_{d,h}\left(\hat{\pi}_{d,h} - S_{d,h}\right)^2$$

- **unde**
  - $S_{d,h} = 1$ dacă ora este un vîrf, 0 altfel
  - Precizia = ponderea alertelor urmate de vîrfuri
  - Sensibilitatea = ponderea vîrfurilor semnalate
  - F1 = media lor armonică
  - Aria de sub curbă (AUC) = probabilitatea ca o oră cu vîrf să primească un scor mai mare decît o oră obișnuită.

- **Pe datele noastre**: clasificatori XGBoost și logistic, reestimați lunar
  - Vîrfuri în 22,1% din orele de test și în 14,3% din ultimul eșantion de antrenare
  - Scorul Brier: XGBoost 0,072; ponderea constantă a vîrfurilor 0,172
- **Repere**
  - Persistența: ponderea vîrfurilor la aceeași oră în ultimele 7 zile
  - Chiar prognoza de preț AW-LEAR, comparată cu θ

- **În practică:** judecați o alertă după probabilitățile ei, nu doar după cîte vîrfuri semnalează.

(Brier, 1950; Fawcett, 2006)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Alertele din anul de test: AW-LEAR egalează un clasificator dedicat

Model	AUC	Precizie	Sensibilitate	F1	Brier	AUC	F1
XGBoost	0,953	0,826	0,685	0,749	0,072	0,980	0,571
Regresie logistică	0,953	0,847	0,641	0,730	0,072	0,980	0,581
Persistență, 7 zile	0,918	0,761	0,681	0,719	0,083	0,847	0,205
Prognoza AW-LEAR $> \theta$	0,959	0,851	0,733	0,788	–	0,983	0,558

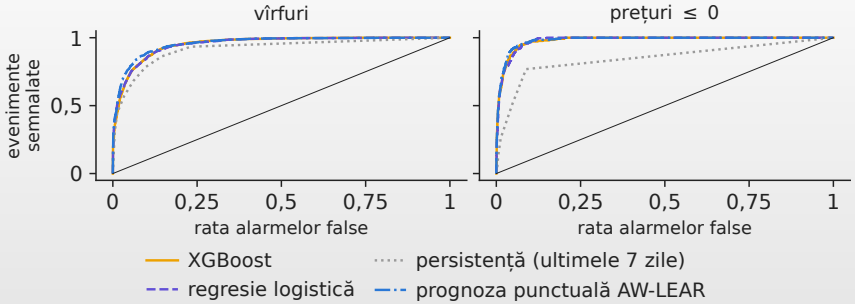
- Coloanele 2–6: vîrfuri (1 938 de ore); coloanele 7–8: prețuri ≤ 0 (255 de ore). Alertă cînd probabilitatea $> 0{,}5$; AW-LEAR: alertă cînd prognoza prețului depășește θ (sau este ≤ 0).
- La prețurile negative, XGBoost semnalează doar o fracțiune 0,467 din evenimente la pragul 0,5: aceste ore sînt rare și depind de vremea de mîine.

- **În practică:** cumpărați un serviciu de alertă pentru vîrfuri doar dacă depășește semnalul ascuns deja în prognoza dumneavoastră de preț.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

Exercițiu practic: notebook-ul Jupyter, secțiunea 7

Persistența detectează vîrfurile, dar nu și prețurile negative



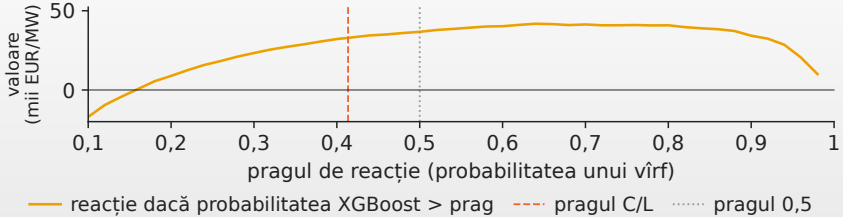
Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31, 8760 de ore.

- Curbele caracteristice de operare (ROC)
  - Vîrfuri: AUC între 0,918 (persistență) și 0,959 (AW-LEAR), deoarece vîrful de seară se repetă de la o zi la alta
- Prețuri negative: persistența are AUC 0,847, față de 0,980 pentru XGBoost
  - Ele depind de soarele și vîntul de mîine, nu de ziua de ieri

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_roc

Regula cost–pierdere: reacționați cînd probabilitatea depășește C/L



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31; 1 MW de consum flexibil.

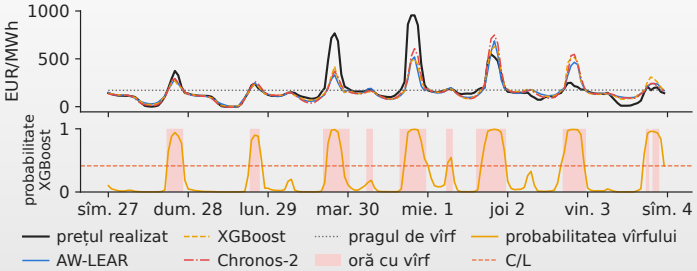
- **Regula**: reacție dacă $\hat{\pi}_{d,h} > C/\bar{L} = 30/72{,}5 = 0{,}414$
  - C = costul reacției = 30 EUR/MWh (ipoteză): mutarea a 1 MWh dintr-o oră cu alertă aduce $P_{d,h} - \theta_d - C$
  - $\bar{L}$ = costul unui vîrf ratat = depășirea medie a pragului în anul de validare
- Valoarea pe MW și an: 33,0 mii EUR la pragul C/L, 11,8 cu persistența, 62,4 cu informație perfectă

- **În practică:** stabiliți pragul din propriile costuri, nu retrospectiv (cel mai bun prag ulterior: 0,64).

(Murphy, 1977, MWR; calcule proprii)

EMQA_L7_decision

Studiu de caz, 30 iunie 2026: vîrf anticipat, amploare subestimată



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: 2026-06-27 - 2026-07-03, date orare.

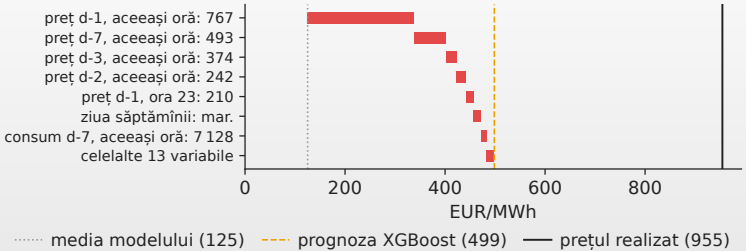
- **Ora 20:00 CET**: 954,59 EUR/MWh, cel mai mare preț din anul de test
  - Prognoze: AW-LEAR 520, XGBoost 499, DNN 614, Chronos-2 607; probabilitatea vîrfului 0,992
- În acea săptămînă: 47 de ore cu vîrf, 45 de alerte la pragul C/L, dintre care 39 corecte

- **În practică:** probabilitatea arată dacă reacționați, prognoza punctuală arată cît.

(calcule proprii; prețurile PZU din România)

EMQA_L7_case_week

Studiu de caz: arborii au urmat seara extremă din ziua precedentă



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: 2026-06-30, ora 20:00 CET; contribuții exprimate în EUR/MWh (anexa C).

- De la 125 (prognoza medie) la 499 EUR/MWh: prețul din $d-1$, aceeași oră, +213
  - Prețul din $d-7$ +64
- Arborii nu pot depăși prețurile memorate în frunze: valorile extreme sînt plafonate

- **În practică:** prezentați consiliului de administrație această descompunere pentru fiecare alertă importantă.

(calcule proprii; valori SHAP în EUR/MWh, anexa C)

EMQA_L7_shap_local

Avertizarea timpurie a vîrfurilor: lucrarea grupului și replicarea ei

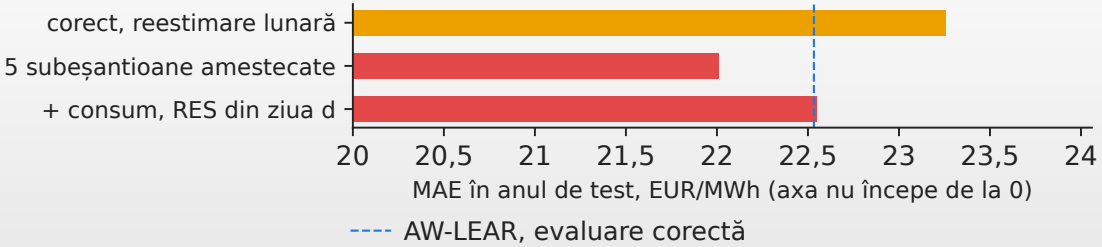
- **Ce a făcut lucrarea** (Andrei, Pele, Cramer, Amza & Diaconu, 2026)
  - Date: 5.000 de ore de pe PZU din România, în 2024, cu date despre consum, surse regenerabile și combustibili; vîrf = preț peste percentila 90
  - Metodă: păduri aleatoare și XGBoost, explicate cu SHAP; un scor de avertizare construit din pragurile mai multor indicatori
  - Rezultat: prețul anterior și prognoza consumului rezidual sînt principalii factori ai vîrfurilor
- **Replicarea noastră** (studiul de caz C7, numai cu informația de la închiderea licitației)
  - Perioada de test: iulie 2025 – octombrie 2026; vîrfuri în 22,1% din ore (în antrenare: 10,0%)
  - XGBoost: AUC 0,946; principalii factori: prețul de ieri și cel de acum o săptămînă, la aceeași oră, ca pe diapozitivele anterioare
- Rezultatele lucrării sînt cele raportate de autori; cifrele replicării sînt calculate cu notebook-ul Jupyter al studiului de caz C7, pe datele noastre.
- **În practică:** prognoza consumului rezidual este variabila de care un model de vîrfuri are cea mai mare nevoie și care lipsește din datele noastre publice.

(Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE; studiul de caz C7)

Cuprins

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

Informația din viitor: două evaluări invalide avantajează XGBoost



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

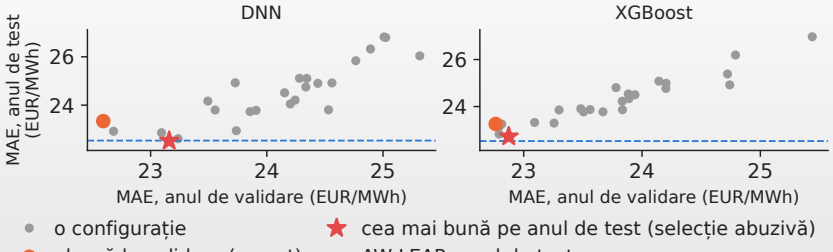
- **Validare încrucișată cu 5 subeșantioane amestecate**: zile din viitor intră în antrenare
  - MAE 22,01 în loc de 23,26: cu 5,4% mai bine, doar pe hîrtie
- **Consum și surse regenerabile de energie (RES) din ziua** d: necunoscute la 12:00 în $d-1$
  - MAE 22,55, un cîștig aparent de 3,1%: cel mult cît ar aduce prognoze perfecte ale acestor variabile

- **În practică:** cereți oricărui furnizor o testare cronologică, cu intrările datate la închiderea licitației.

(Bergmeir & Benítez, 2012, Inf. Sci.; calcule proprii)

EMQA_L7_pit_leak

Alegerea pe anul de test simulează o victorie asupra LEAR



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de validare și anul de test 2025-11-01 - 2026-10-31.

- Rețeaua DNN aleasă corect (la validare, o inițializare): MAE 23,34
  - Cea mai bună dintre cele 25 de setări pe anul de test: 22,52, chiar sub AW-LEAR (22,53)
- Validarea funcționează, dar imperfect: corelația Spearman a rangurilor, 0,86 (DNN), 0,94 (XGBoost)

- **În practică:** întrebați cîte modele au fost încercate: cu cît mai multe, cu atît cel mai bun pare mai bun.

(White, 2000, Econometrica; calcule proprii)

EMQA_L7_snooping

Cel mai bun dintre multe modele trebuie testat față de reper

$$\mathrm{RC}_n = \max_{k=1,\ldots,m} \sqrt{n}\,\bar{d}_k, \qquad \bar{d}_k = \frac{1}{n}\sum_{t=1}^{n} d_{k,t}$$

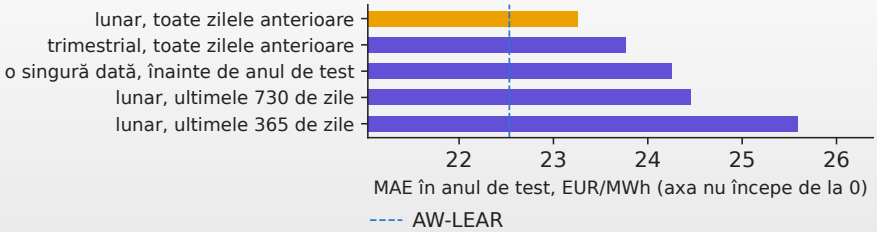
- **unde**
  - $d_{k,t}$ = pierderea reperului minus cea a modelului k în ziua t
  - H_0: $E(d_{k,t}) \leq 0$ pentru orice k
  - Valoarea critică: bootstrap comun pe $(d_{1,t}, \ldots, d_{m,t})$, cu corelația dintre modele păstrată.
- **De ce**: pentru m teste independente la 5%, P(cel puțin o victorie falsă) $= 1 - 0{,}95^m$: 0,401 ($m = 10$), 0,994 ($m = 100$)

- **C.-M. Kuan, 4 iunie 2026** (diapozitive)
  - Testul Reality Check (RC), White (2000): conservator, modelele slabe adăugate îi reduc puterea (Hansen, 2005)
  - Testul abilității predictive superioare (SPA), Hansen (2005): recentrează modelele slabe, mai puternic
  - Step-RC (Romano & Wolf, 2005), Step-SPA (Hsu, Hsu & Kuan, 2010): identifică modelele mai bune, controlînd rata erorii la nivelul familiei de ipoteze (FWER)
- **Pe datele noastre**
  - Cea mai bună dintre cele 25 de setări DNN pe anul de test trece sub AW-LEAR: cazul corectat de RC și SPA

- **În practică:** cînd vi se arată cel mai bun dintre multe modele, cereți valoarea p a testului RC sau SPA.

(diapozitivele AIDA 2026; lucrări: White, 2000; Hansen, 2005; Romano & Wolf, 2005; Hsu et al., 2010)

Reestimarea: un model neactualizat un an pierde 4,2%



Sursa: energy-charts.info (Fraunhofer ISE); Yahoo Finance (EUA). Date: anul de test 2025-11-01 - 2026-10-31.

- Estimat o singură dată, înaintea anului de test: MAE 24,25
  - Pierderea crește în timp (+0,15 EUR/MWh în primele 3 luni, +3,70 în ultimele 3)
- O fereastră glisantă scurtă (365 de zile, MAE 25,59) este mai slabă decît întregul istoric: arborii au nevoie de multe vîrfuri din trecut pentru a învăța

- **În practică:** includeți reestimarea lunară în calendarul operațional, cu un responsabil, ca pe orice alt control.

(calcule proprii, anul de test 1 noiembrie 2025 – 31 octombrie 2026)

EMQA_L7_pit_retrain

Testul de scurgere a informației: ștergerea viitorului nu schimbă nimic

- **Testul**
  - Pentru prima zi din fiecare dintre cele 12 luni de test, toate datele de după ora 12:00 din ziua $d-1$ sînt șterse, apoi înlocuite cu 10 000 EUR/MWh
  - XGBoost, rețeaua DNN și clasificatorul de vîrfuri sînt reestimate și trebuie să dea aceleași prognoze
- **Rezultatul**
  - Arborii și clasificatorul: prognoze identice; DNN: diferențe sub 0,001 EUR/MWh (rotunjiri ale calculelor paralele)
  - Chronos: contextul este construit numai din zilele dinaintea zilei d, verificat în cod
- **Lista de verificare înainte de a avea încredere într-un model**
  - Fiecare intrare datată la momentul închiderii licitației
  - Setări alese pe un an de validare
  - Un singur an de test, deschis o singură dată, cu teste DM față de LEAR
  - Reestimări lunare și un test de perturbare ca acesta

În practică: includeți această verificare în evaluarea oricărui model, statistic sau de învățare automată.

(cursul 2; Lago et al., 2021, APEN)

Exercițiu practic: notebook-ul Jupyter, secțiunea 10

Test 1: o testare retrospectivă perfectă

- Un start-up prezintă o rețea neuronală cu rMAE 0,70 pentru România, testată prin validare încrucișată cu 5 subeșantioane amestecate
  - Ce cereți?

Răspuns

- O testare cronologică pe un an neatins, cu intrări cunoscute la ora 12:00 în ziua $d - 1$: pe datele noastre, doar amestecarea a făcut XGBoost să pară cu 5,4% mai bun.

Test 2: ce model puneți în producție

- Chronos-2 are cea mai mică MAE dintre modelele individuale
  - Combinația AW-LEAR + Chronos-2 are aceeași MAE
  - Pe care o puneți în producție?

Răspuns

- Combinația: aceeași acuratețe (DM, $p = 0{,}491$), dar dacă modelul preantrenat se degradează sau devine indisponibil, LEAR asigură în continuare jumătate din prognoză.

Test 3: interpretarea valorilor SHAP

- Consumul are o pondere SHAP mică (8,5%)
  - Putem concluziona că acesta nu influențează prețul?

Răspuns

- Nu: SHAP explică modelul, nu piața
  - Consumul intră doar cu valoarea din ziua $d - 2$, deja reflectată în prețul de ieri.

Test 4: pragul de alertă

- Mutarea a 1 MWh vă costă 60 EUR în loc de 30
  - Cum se schimbă pragul de alertă?

Răspuns

- Se dublează: C/L crește de la 0,414 la aproximativ dublul acestei valori, deci reacționați numai la vîrfurile mai sigure.

Test 5: reestimarea

- Echipa de date propune ca modelul să fie antrenat o dată pe an, pentru a economisi efort
  - Ce arată anul de test?

Răspuns

- Un model neactualizat un an a fost cu 4,2% mai puțin precis, iar diferența a crescut în ultimele luni
  - O reestimare lunară a XGBoost durează circa 13 de secunde.

Recapitulare

- Învățarea automată, evaluată corect
- Rețele neuronale profunde
- Gradient boosting și modele fundaționale
- Comparație corectă, combinare și cost
- Explicarea prognozelor
- Vîrfuri de preț, prețuri negative și un studiu de caz
- Capcane care fac un model să pară mai bun

- Calibrate, rețeaua DNN și XGBoost sînt mai precise decît în cursul 2, dar nu depășesc singure AW-LEAR
  - În medie cu acesta, îl depășesc
- Chronos-2, fără antrenare, este cel mai precis model individual (MAE 20,82, cu 7,6% sub AW-LEAR)
  - Orice model trebuie explicat, validat și reestimat

Cercetările grupului nostru: învățarea automată pe piața din România

- **Avertizarea timpurie a vîrfurilor de preț** (Andrei, Pele, Cramer, Amza & Diaconu, 2026, PICBE)
  - Ce a făcut lucrarea: a construit un sistem explicabil de inteligență artificială (AI) pentru PZU din România
  - Rezultat: prețul anterior și consumul rezidual sînt principalii factori ai vîrfurilor (studiul de caz C7)
- **Explicarea prognozelor de preț pe mai multe orizonturi** (Andrei, Pele & Cramer, 2026, PICBE)
  - Ce a făcut lucrarea: a explicat prognozele de învățare automată pentru prețurile orare din România
  - Rezultat: arată ce factori contează la fiecare orizont și în fiecare regim de preț
- **Patru generații de modele pentru prețul energiei** (Andrei, Velev, Toma, Pele & Lessmann, 2024, arXiv 2411.03372)
  - Ce a făcut lucrarea: a comparat patru generații de metode de prognoză a prețurilor energiei, de la modelele statistice la învățarea profundă
  - Utilitate: un reper pentru alegerea familiei de modele
- **Modele fundaționale pentru riscul extrem** (Jheng, Tak, Găman, Mazurencu-Marinescu-Pele & Pele, 2026, ECECSR)
  - Ce a făcut lucrarea: a folosit modele fundaționale preantrenate, fără reantrenare și cu calibrare conformală, pentru prognoza pierderilor extreme pe piețele din Europa Centrală și de Est
- Rezultatele de pe acest diapozitiv sînt cele raportate în lucrări; celelalte cifre din curs provin din calculele noastre.

(Academia de Studii Economice din București; Academia Română, Institutul de Prognoză Economică)

Lecturi și resurse suplimentare

- **epftoolbox**: rețeaua DNN și modelul LEAR din Lago et al. (2021), cu date deschise pentru evaluare — github.com/jeslago/epftoolbox.
- **XGBoost** și **shap**, documentație: xgboost.readthedocs.io, shap.readthedocs.io.
- **Chronos**, modele fundaționale: github.com/amazon-science/chronos-forecasting.
- **Interpretable Machine Learning** (C. Molnar), gratuit online: christophm.github.io.
- **Acest curs**: cod, date, notebook-uri Jupyter — github.com/danpele/EMQA.
- **Studiul de caz C7** replică pe datele cursului lucrarea despre avertizarea timpurie a vîrfurilor.
- **Exerciții practic**: notebook-ul Jupyter reproduce toate graficele și cifrele din acest curs — notebooks/.

Bibliografie (1/4)

- Anagnoste, S., Andrei, A.-V., Bolovăneanu, V., Cepoi, C.-O., Clodnitchi, R., Cramer, A.-A., Grecu, R.-A., Lessmann, S., Pele, D. T., Petukhina, A. & Strat, V. A. (2025). The role of AI in (re)shaping energy finance: A systematic literature review. *Energy Strategy Reviews*, 61, 101833. doi:10.1016/j.esr.2025.101833
- Andrei, A.-V., Pele, D.-T. & Cramer, A.-A. (2026). Multi-horizon explainability in energy price forecasting: Disentangling market dynamics and renewable intermittency in Romania's liberalized electricity market. *Proceedings of the International Conference on Business Excellence*, 20(1), 104–117. doi:10.2478/picbe-2026-0014
- Andrei, A.-V., Pele, D.-T., Cramer, A.-A., Amza, A. & Diaconu, D. (2026). Explainable AI-based early warning system for electricity price spikes: Evidence from the Romanian market. *Proceedings of the International Conference on Business Excellence*, 20(1), 4820–4836. doi:10.2478/picbe-2026-0352
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2024). Energy price modelling: A comparative evaluation of four generations of forecasting methods. arXiv:2411.03372
- Andrei, A.-V., Velev, G., Toma, F.-M., Pele, D. T. & Lessmann, S. (2026). Energy price modelling: A comparative evaluation of four generations of forecasting methods. Talk, AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026
- Ansari, A. F., Stella, L., Turkmen, C. et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. arXiv:2403.07815
- Ansari, A. F., Shchur, O., Küken, J. et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821
- Bates, J. M. & Granger, C. W. J. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. doi:10.1057/jors.1969.103
- Bergmeir, C. & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213. doi:10.1016/j.ins.2011.12.028

Bibliografie (2/4)

- Bergstra, J. & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305. jmlr.org/papers/v13/bergstra12a.html
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi:10.1023/A:1010933404324
- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3. doi:10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
- Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794. doi:10.1145/2939672.2939785
- Clodnitchi, R. (2026). The role of AI in (re)shaping energy finance: A systematic literature review. Talk, AIDA Conference, Bucharest University of Economic Studies, 3 June 2026. github.com/danpele/EMQA/resources/aida2026
- Diebold, F. X. & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. doi:10.1016/j.patrec.2005.10.010
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. doi:10.1198/073500105000000063

Bibliografie (3/4)

- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. Springer. doi:10.1007/978-0-387-84858-7
- Hsu, P.-H., Hsu, Y.-C. & Kuan, C.-M. (2010). Testing the predictive ability of technical analysis using a new stepwise test without data snooping bias. *Journal of Empirical Finance*, 17(3), 471–484. doi:10.1016/j.jempfin.2010.01.001
- Jheng, S., Tak, R., Găman, Ș., Mazurencu-Marinescu-Pele, M. & Pele, D. T. (2026). Can foundation models manage risk? Zero-shot VaR and ES forecasting with conformal calibration in CEE markets. *Economic Computation and Economic Cybernetics Studies and Research*, 60(2), 267–290. doi:10.24818/18423264/60.2.26.14
- Kingma, D. P. & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*. arXiv:1412.6980
- Kuan, C.-M. (2026). Large-scale multiple inequality testing without data snooping bias. Keynote, AIDA Conference, Bucharest University of Economic Studies, 4 June 2026. github.com/danpele/EMQA/resources/aida2026
- Lago, J., De Ridder, F. & De Schutter, B. (2018). Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221, 386–405. doi:10.1016/j.apenergy.2018.02.069
- Lago, J., Marcjasz, G., De Schutter, B. & Weron, R. (2021). Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293, 116983. doi:10.1016/j.apenergy.2021.116983
- Lundberg, S. M., Erion, G., Chen, H. et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. doi:10.1038/s42256-019-0138-9
- Marcjasz, G., Narajewski, M., Weron, R. & Ziel, F. (2023). Distributional neural networks for electricity price forecasting. *Energy Economics*, 125, 106843. doi:10.1016/j.eneco.2023.106843

Bibliografie (4/4)

- Murphy, A. H. (1977). The value of climatological, categorical and probabilistic forecasts in the cost-loss ratio situation. *Monthly Weather Review*, 105(7), 803–816. doi:10.1175/1520-0493(1977)105<0803:TVOCCA>2.0.CO;2
- Olivares, K. G., Challu, C., Marcjasz, G., Weron, R. & Dubrawski, A. (2023). Neural basis expansion analysis with exogenous variables: Forecasting electricity prices with NBEATSx. *International Journal of Forecasting*, 39(2), 884–900. doi:10.1016/j.ijforecast.2022.03.001
- Romano, J. P. & Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282. doi:10.1111/j.1468-0262.2005.00615.x
- Shapley, L. S. (1953). A value for n-person games. In *Contributions to the Theory of Games II*, 307–317. Princeton University Press. doi:10.1515/9781400881970-018
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15, 1929–1958. jmlr.org/papers/v15/srivastava14a.html
- Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030–1081. doi:10.1016/j.ijforecast.2014.08.008
- Weron, R. (2026). Machine learning for electricity price forecasting. Keynote, AIDA Conference, Bucharest University of Economic Studies, 4 June 2026. github.com/danpele/EMQA/resources/aida2026
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126. doi:10.1111/1468-0262.00152

Anexa A: propagarea înapoi a erorii și pasul Adam

$$\frac{\partial \mathcal{L}}{\partial W_2} = \boldsymbol{\delta}\, \mathbf{z}^\top, \quad \boldsymbol{\delta} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{Y}}}$$

$$\frac{\partial \mathcal{L}}{\partial W_1} = \left[(W_2^\top \boldsymbol{\delta}) \odot \phi'(\mathbf{u}) \right] \mathbf{x}^\top$$

- Regula de derivare a funcțiilor compuse, de la ieșire spre intrări
  - Pentru eroarea absolută, $\partial |y - \hat{y}| / \partial \hat{y} = -\operatorname{sign}(y - \hat{y})$.
- $\mathbf{u} = W_1 \mathbf{x} + \mathbf{b}_1$
  - $\odot$ = produs element cu element
  - Pentru softplus, $\phi'(u) = 1/(1 + e^{-u})$.

(Kingma & Ba, 2015, ICLR; Hastie et al., 2009)

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2$$

$$\theta_k = \theta_{k-1} - \eta \, \frac{m_k / (1 - \beta_1^k)}{\sqrt{v_k / (1 - \beta_2^k)} + \varepsilon}$$

- g_k = gradientul pe grupul de zile k
  - $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$ (valori implicite)
  - Fiecare pondere are propriul pas.
- Penalizarea ponderilor adaugă $\lambda\theta$ la g_k (o penalizare pătratică, aici $\lambda = 10^{-5}$).

Anexa B: de ce valoarea optimă a unei frunze este $-G/(H+\lambda)$

$$\ell\big(Y_i, F_{m-1} + f\big) \approx \ell_i + g_i f(\mathbf{x}_i) + \tfrac{1}{2} h_i f(\mathbf{x}_i)^2$$

$$\sum_j \left[G_j w_j + \tfrac{1}{2}(H_j + \lambda) w_j^2 \right] + \gamma J, \quad G_j = \textstyle\sum_{i \in R_j} g_i$$

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \qquad \text{scor} = -\tfrac{1}{2} \sum_j \frac{G_j^2}{H_j + \lambda} + \gamma J$$

- Dezvoltare Taylor de ordinul doi a funcției de pierdere în jurul prognozei curente
  - g_i, h_i = derivatele de ordinul întîi și al doilea
  - H_j = suma h_i din frunza j.
- În fiecare frunză, obiectivul este o parabolă în w_j: anulînd derivata, se obține w_j^*.
- Cîștigul unei împărțiri, de pe diapozitivul despre arborele de regresie, este scorul dinainte minus scorul de după împărțire.
- Pentru eroarea absolută, $h_i = 0$
  - XGBoost calculează atunci valorile frunzelor printr-o căutare unidimensională.

(Chen & Guestrin, 2016, KDD)

Anexa C: valori SHAP exprimate în EUR/MWh

$$\hat{P} = m + s \sinh\left(\phi_0 + \sum_j \phi_j\right), \qquad P_0 = m + s \sinh \phi_0$$

$$\phi_j^{\text{EUR}} = \phi_j \frac{\hat{P} - P_0}{\sum_k \phi_k} \;\Rightarrow\; \sum_j \phi_j^{\text{EUR}} = \hat{P} - P_0$$

- Arborii prognozează prețul transformat cu asinh
  - m, s = mediana și abaterea absolută mediană (MAD), scalată, a prețurilor de antrenare.
- Valorile SHAP se adună pe această scară
  - Pentru a raporta în euro, diferența $\hat{P} - P_0$ se împarte proporțional cu ϕ_j.
- Semnele și ordinea nu se schimbă
  - Contribuțiile se adună exact la prognoza în EUR/MWh.

(Lundberg et al., 2020, Nat. Mach. Intell.)

Anexa D: spațiile de căutare și setările alese

Setare DNN	Valori încercate	Aleasă
neuroni, stratul 1	64, 128, 256, 512	512
neuroni, stratul 2	0, 32, 64, 128, 256	niciunul
funcția de activare	ReLU, softplus	softplus
dropout	0,0; 0,1; 0,2; 0,3	0,1
rata de învățare	$3 \cdot 10^{-4}$; 10^{-3}; $3 \cdot 10^{-3}$	$3 \cdot 10^{-4}$
penalizare L1, intrări	0; 10^{-3}; 10^{-2}; 10^{-1}	0
grup (zile)	32, 64, 128	64
consum/RES/fund.	da sau nu	da/da/da

Setare XGBoost	Valori încercate	Aleasă
arbori	300, 600, 1000, 1500	1500
rata de învățare η	0,02; 0,05; 0,10	0,02
adîncimea	3, 4, 5, 6, 8	8
ponderea min. în frunză	1, 5, 20, 50	5
rînduri pe arbore	0,6; 0,8; 1,0	0,8
λ	0,1; 1,0; 10,0	0,1
funcția de pierdere	pătrat, abs., Huber	absolută

⊡ 24 de extrageri aleatoare pe model (cu valoare inițială fixată) și setarea din cursul 2; aleasă = MAE minimă în anul de validare.

(Bergstra & Bengio, 2012, JMLR)